Índice:

DEFINICIONES GENERALES PARA CONFECCIÓN DEL INFORME DE PROYECTO INTEGRADOR: 3

Redacción 3

Formal 3

Claro 3

Objetivo 3

Con citas y referencias 3

Formato 3

Imágenes / Diagramas 3

Uso de imágenes, figuras y diagramas 3

EJEMPLO DE PORTADA 5

RESUMEN - ABSTRACT (inglés y español) 6

PRESENTACIÓN DEL TEMA 8

GLOSARIO 10

DIAGNÓSTICO (PROBLEMÁTICA) 15

OBJETIVOS 21

GLOBAL 21

ESPECÍFICOS 21

TABLA DE TRAZABILIDAD (opcional - recomendada) 22

MARCO TEÓRICO 23

2. Análisis de Campo 28

2.1 Introducción 28

2.2 Importancia del análisis de campo en proyectos de ingeniería de software 29

2.3 Técnicas de recolección de información 29

2.4 Justificación del análisis de campo para el presente proyecto 30

2.5 Planificación del proceso de relevamiento 31

2.6 Objetivos del análisis de campo 31

2.7 Aporte del análisis de campo al proyecto 32

2.8 Hallazgos del Relevamiento Operativo y Reglas de Negocio 32

2.9 Logística ante Picos de Flujo y Comportamiento de Clientes 33

2.10 Infraestructura de Captura y Distribución de Cámaras 34

2.11 Viabilidad Técnica de Conexión y Extracción de Footage 35

3. Opciones Similares en el Mercado 35

3.1 Introducción 35
3.2 Soluciones orientadas a la videovigilancia inteligente 36
3.3 Plataformas de análisis para el sector retail 36
3.4 Limitaciones de las soluciones existentes 37
3.5 Oportunidad de innovación 38
3.6 Comparación entre las soluciones existentes y la propuesta del proyecto 39
4. Tecnologías Investigadas 39
4.1 Entornos de Desarrollo 39
4.1.1 Visual Studio Code 39
4.2 Desarrollo y Pruebas en Entornos Móviles 40
4.2.1 Expo Go 40
4.3 Tecnologías de Visión por Computadora e Inteligencia Artificial 41
4.3.1 YOLOv8 (You Only Look Once - Versión 8) 41
4.3.2 Gemma AI (Google Open Models) 42
4.3.3 Roboflow 43
4.4 Herramientas de Asistencia al Desarrollo y Documentación 46
4.4.1 Modelos de Lenguaje Grandes (LLMs): GPT y Claude 46
PROPUESTA DE SOLUCIÓN 54
Aspectos clave a incluir en la Propuesta de solución: 54
Alcance Funcional 54
Diseño 54
Implementación 54
Pruebas 55
BENEFICIOS POST-IMPLEMENTACIÓN 56
IMPACTO ECONÓMICO (estudio de costos) 57
IMPACTO SOCIAL 58
IMPACTO MEDIOAMBIENTAL (opcional) 59
CONCLUSIÓN 60
BIBLIOGRAFÍA / REFERENCIAS 61
ANEXOS 63

DEFINICIONES GENERALES PARA CONFECCIÓN DEL INFORME DE PROYECTO INTEGRADOR:

VER: 2.1 - 2026

Redacción

El tono de la redacción debe ser **formal, claro y objetivo**.

Formal

- Utiliza un lenguaje académico, no expresiones coloquiales o informales.

Claro

- Explica conceptos de manera precisa, evitar ambigüedades.

Objetivo

- No usar pronombres en primera persona singular (yo) o plural (nosotros). En su lugar, usa formas impersonales o en tercera persona del singular. Ejemplo: "El análisis muestra que..." en lugar de "Yo analicé...".

Con citas y referencias

- Utilizar norma APA v7 (obligatorio)

Formato

El único formato exigido es el justificado para el texto normal (párrafos).

Imágenes / Diagramas

Uso de imágenes, figuras y diagramas

Las imágenes, diagramas, capturas, gráficos o esquemas deben incluirse solo cuando ayuden a comprender el proyecto. No deben utilizarse como decoración ni reemplazar explicaciones importantes del texto.

Toda imagen debe estar mencionada previamente en el informe, por ejemplo: “Como se observa en la Figura 1…”.

Debajo de cada imagen se debe agregar:

Figura n

Descripción breve de la imagen.

Fuente: elaboración propia / adaptado de… / tomado de…

Si la imagen no es propia, debe indicarse la fuente y agregar la referencia completa en la bibliografía.

Además, cada imagen debe tener **texto alternativo** en Google Docs, describiendo brevemente la información principal que transmite. Google Docs permite agregarlo desde las opciones de imagen, y esta práctica mejora la accesibilidad del documento. (Google Help)

Regla general: toda imagen debe tener **referencia en el texto, número de figura, descripción, fuente y texto alternativo**

Universidad Católica de Córdoba

Facultad de Ingeniería

SISTEMA INTELIGENTE DE ANÁLISIS DE FLUJO Y OPTIMIZACIÓN OPERATIVA MEDIANTE COMPUTER VISION PARA TIENDAS FULL, OPTIFULL

Informe Final de Grado

Alumnos:

- Blasón, Agostina
- Nahmias, Arnon Daniel
- Ortiz Noseda, Paulina

Directores:

- Juarez, Leandro
- Porrini, Federico Eduardo
- Carreño, Ignacio Luciano

<*dia*> de Febrero de 2027

Córdoba - Argentina

RESUMEN - ABSTRACT (inglés y español)

El avance de la Inteligencia Artificial y la Visión por Computadora abre nuevas posibilidades para el sector del comercio minorista, particularmente en entornos de alta rotación como las tiendas de conveniencia FULL de estaciones de servicio YPF. Si bien estos establecimientos cuentan con infraestructura de cámaras de seguridad, su uso se limita a una función reactiva y forense, desaprovechando el potencial analítico que ofrecen los flujos de video disponibles en tiempo real.

El presente trabajo tiene como objetivo desarrollar una plataforma de software basada en Visión por Computadora que procesa video en tiempo real para automatizar la obtención de métricas operativas, detectar comportamientos de interés dentro del local y emitir alertas tempranas, transformando así un sistema de videovigilancia pasivo en una herramienta proactiva de asistencia operativa.

Para ello, se implementaron modelos de detección y seguimiento de personas sobre los flujos de video RTSP de las cámaras existentes, sin recurrir al reconocimiento facial ni a la identificación biométrica. El sistema genera mapas de calor, métricas de circulación y permanencia, y estimaciones de tiempos de espera, y clasifica cada visita para alertar sobre posibles hurtos con evidencia visual. Complementariamente, se incorporó un módulo de reconocimiento de productos en caja, basado en un modelo multimodal, que identifica el artículo presentado por el cajero y descuenta el stock tras su confirmación. Toda la información se visualiza a través de una interfaz web accesible para el personal del local.

La solución busca demostrar la viabilidad técnica de aplicar inteligencia artificial sobre infraestructura preexistente en comercios de mediana escala, aportando información objetiva y continua para optimizar la dotación de personal, mejorar el control de inventario y apoyar la toma de decisiones operativas y estratégicas.

Palabras clave: visión por computadora, retail analytics, detección de personas, mapas de calor, tiendas de conveniencia, YPF FULL.

Abstract

The advancement of Artificial Intelligence and Computer Vision opens new possibilities for the retail sector, particularly in high-turnover environments such as YPF FULL convenience stores located at service stations. Although these establishments are equipped with security camera infrastructure, its use is limited to a reactive and forensic function, failing

to leverage the analytical potential offered by real-time video streams.

This work aims to develop a software platform based on Computer Vision that processes video in real time to automate the collection of operational metrics, detect events of interest within the store, and issue early alerts — transforming a passive video surveillance system into a proactive operational assistance tool.

To achieve this, people detection and tracking models were implemented over the existing RTSP video streams, without resorting to facial recognition or biometric identification. The system generates heatmaps, circulation and dwell-time metrics, and wait-time estimations, and classifies each visit to raise alerts on possible shoplifting with visual evidence. Additionally, a checkout product recognition module based on a multimodal model identifies the item presented by the cashier and updates the stock after confirmation. All information is displayed through a web interface accessible to store staff.

The solution seeks to demonstrate the technical feasibility of applying artificial intelligence to pre-existing infrastructure in medium-scale retail environments, providing objective and continuous information to optimize staffing, improve inventory control, and support operational and strategic decision-making.

Keywords: computer vision, retail analytics, people detection, heatmaps, convenience stores, YPF FULL.

PRESENTACIÓN DEL TEMA

El avance de las tecnologías basadas en Inteligencia Artificial (IA) ha transformado radicalmente la forma en que las organizaciones gestionan sus recursos y toman decisiones comerciales, permitiendo migrar de modelos operativos reactivos hacia soluciones analíticas proactivas y automatizadas (Russell & Norvig, 2021). En el mundo del comercio minorista y, específicamente, en los negocios como las FULL, la optimización de los procesos internos, la gestión eficiente del stock y el análisis del comportamiento de los consumidores constituyen factores críticos para garantizar la competitividad y la sostenibilidad del negocio. No obstante, gran parte de la infraestructura analítica tradicional en estos entornos se limita al procesamiento de datos estructurados provenientes de sistemas transaccionales, desaprovechando fuentes de información visuales masivas e inmediatas que ya se encuentran disponibles en los establecimientos, como los circuitos cerrados de televisión (CCTV).

La relevancia de abordar esta temática radica en la oportunidad de expandir las fronteras convencionales de la videovigilancia comercial. Tradicionalmente, las cámaras de seguridad en entornos comerciales medianos se han utilizado bajo un enfoque pasivo y forense; es decir, como herramientas de consulta diferida para revisar incidentes, mermas o reclamos una vez que estos ya han acontecido. La motivación principal de este trabajo integrador surge del desafío de transformar esos flujos de video estáticos en una fuente continua de datos accionables en tiempo real, democratizando el acceso a tecnologías de automatización inteligente y adaptando modelos avanzados de IA para asistir de forma directa a los responsables de la gestión diaria del local. El entorno de las tiendas de conveniencia FULL de YPF, caracterizado por dinámicas operativas de alta rotación, exigencias estacionales de demanda y la necesidad de mantener controles de inventario rigurosos, se presenta como el escenario ideal para el diseño y validación de una solución con estas características.

Bajo este contexto, el propósito central de este proyecto integrador consiste en desarrollar una plataforma de software basada en Visión por Computadora (Computer Vision) que procese flujos de video en tiempo real para automatizar la obtención de métricas operativas, identificar patrones de comportamiento de clientes y emitir alertas tempranas sobre situaciones anómalas dentro del local. El eje del sistema se fundamenta en traducir volúmenes complejos de datos visuales en indicadores comprensibles y gráficos simplificados a través de una interfaz web, proporcionando un marco analítico objetivo e independiente de los sistemas de gestión tradicionales.

De esta manera, el proyecto no solo busca mitigar ineficiencias del día a día, sino también constituirse como una herramienta estratégica de soporte para la toma de decisiones comerciales y operativas, demostrando la viabilidad técnica y el valor añadido de la inteligencia artificial aplicada directamente a la infraestructura existente de los negocios.

GLOSARIO

Afluencia de clientes: Cantidad de personas que ingresan a un establecimiento durante un período determinado. En el contexto de este proyecto, se mide de forma automática a partir de las detecciones de las cámaras y permite identificar los horarios y días de mayor demanda.

API (Application Programming Interface): Interfaz de Programación de Aplicaciones. Conjunto de definiciones y protocolos que permiten que diferentes aplicaciones o servicios se comuniquen entre sí, facilitando el intercambio de datos y funcionalidades de manera estandarizada.

API Key (Clave de API): Credencial única que identifica a quien consume un servicio externo y autoriza sus solicitudes. En este proyecto, se utiliza para acceder a los servicios de inteligencia artificial en la nube (Claude, Gemini y Groq), que facturan o limitan su uso en función de esa clave.

BaaS (Backend-as-a-Service): Modelo de arquitectura de software que automatiza la provisión y gestión de servicios de backend (como bases de datos, autenticación y almacenamiento), permitiendo a los desarrolladores centrarse en la lógica de la aplicación y la interfaz de usuario.

BoT-SORT: Algoritmo de seguimiento multiobjeto que, además de la posición de cada objeto, utiliza descriptores de apariencia y compensa el movimiento de la cámara para mantener los identificadores entre fotogramas. Ofrece mayor estabilidad que otros algoritmos a cambio de un mayor costo computacional.

Bounding box (Caja delimitadora): Rectángulo que un modelo de detección traza alrededor de cada objeto identificado en una imagen, definido por sus coordenadas y acompañado de la clase detectada y su nivel de confianza.

Business Intelligence (BI - Inteligencia de Negocios): Conjunto de estrategias, tecnologías y herramientas utilizadas por las organizaciones para recopilar, procesar y analizar datos comerciales con el fin de transformarlos en información estructurada y de valor. En el sector minorista (retail), se emplea para consolidar métricas operativas (como el flujo de clientes, tiempos de permanencia o tasas de conversión) en tableros visuales que facilitan la toma de decisiones estratégicas y la optimización del negocio.

ByteTrack: Algoritmo de seguimiento multiobjeto que asocia las detecciones entre fotogramas consecutivos en dos etapas, aprovechando también las detecciones de baja

confianza para mantener los identificadores (*track IDs*) ante oclusiones breves. Se caracteriza por su bajo costo computacional, ya que no utiliza modelos de apariencia.

Cámara IP: Cámara de video que transmite su imagen a través de una red de datos utilizando el protocolo IP, lo que permite acceder a ella desde otros dispositivos de la red local o, con la configuración adecuada, desde internet.

Cámaras cenitales: Dispositivos de captura de video ubicados verticalmente en el punto más alto de un espacio (en el techo o cielorraso), apuntando directamente hacia el suelo en un ángulo de 90 grados. En el sector retail, este tipo de plano (plano cenital) se utiliza para evitar obstrucciones visuales entre personas y obtener una vista aérea clara que facilite el conteo preciso de clientes y el seguimiento de sus trayectorias dentro del local.

CCTV (Closed-Circuit Television): Sistema de videovigilancia compuesto por cámaras de seguridad cuya señal de video se transmite a un conjunto cerrado y privado de monitores o dispositivos de almacenamiento, a diferencia de la televisión abierta. Es ampliamente utilizado en entornos comerciales para el monitoreo y registro de actividades dentro de los establecimientos. En el contexto de este proyecto, la infraestructura CCTV instalada en la tienda FULL constituye la fuente primaria de captura de video sobre la cual se aplican las técnicas de visión por computadora e inteligencia artificial.

Centroide: Punto central de una caja delimitadora. En este proyecto, la posición de cada persona en cada fotograma se representa mediante un punto de referencia de su caja delimitadora, que se utiliza para construir trayectorias y mapas de calor.

CGNAT (Carrier-Grade NAT): Técnica utilizada por los proveedores de internet para compartir una misma dirección IP pública entre múltiples clientes. Impide recibir conexiones entrantes desde internet, por lo que dificulta el acceso remoto a dispositivos ubicados dentro de una red local.

CI/CD (Integración y Despliegue Continuos): Práctica de desarrollo de software que automatiza la compilación, la ejecución de pruebas y la publicación de cada nueva versión del sistema ante cada cambio en el repositorio, de modo que solo se publiquen versiones que superaron las verificaciones definidas.

COCO (Common Objects in Context): Conjunto de datos público de imágenes etiquetadas que abarca 80 clases de objetos de uso cotidiano, entre ellas personas, botellas, vasos y alimentos. Es el conjunto sobre el cual se encuentran preentrenados los modelos YOLOv8 utilizados en el proyecto.

Combo: Oferta comercial que agrupa varios productos (por ejemplo, una bebida y un snack)

bajo un precio único. En la tienda relevada, el cliente puede elegir entre distintas variedades de un mismo tipo de producto, lo que genera diferencias entre el stock registrado y el stock físico por variedad.

Computer Vision (Visión por Computadora): Campo de la inteligencia artificial orientado a dotar a los sistemas informáticos de la capacidad de interpretar y analizar información visual proveniente del mundo real, como imágenes o secuencias de video. En el contexto de este proyecto, constituye la base tecnológica que permite procesar los flujos de video de las cámaras de seguridad para detectar personas, productos y eventos de interés dentro del local.

Contenedor (Docker): Unidad de software que empaqueta una aplicación junto con todas sus dependencias, de manera que se ejecute de forma idéntica en cualquier entorno. Docker es la plataforma más difundida para construir y ejecutar contenedores.

Cuota de uso (Rate limit): Límite que un proveedor de servicios en la nube establece sobre la cantidad de solicitudes que pueden realizarse en un período determinado (por minuto o por día). Al alcanzarse, el servicio rechaza nuevas solicitudes hasta que la cuota se renueva.

Data Augmentation (Aumentación de datos): Técnica utilizada para incrementar artificialmente la diversidad y cantidad de los datos de entrenamiento (por ejemplo, rotando, recortando o añadiendo ruido a imágenes), lo que ayuda a que los modelos de visión por computadora sean más robustos y generalicen mejor ante condiciones reales.

Dataset: Conjunto de datos estructurados o no estructurados que se utiliza para entrenar, validar o evaluar modelos de inteligencia artificial. En el contexto de este proyecto, se refiere a las colecciones de imágenes y videos etiquetados empleados para el entrenamiento de los algoritmos de visión por computadora.

Dato biométrico: Dato personal obtenido a partir de características físicas o conductuales propias de una persona, como el rostro, la huella dactilar o el iris, que permite identificarla de manera única. El sistema desarrollado no recolecta ni almacena este tipo de datos.

Dato personal: Información de cualquier tipo referida a personas humanas determinadas o determinables (Ley 25.326, 2000). La imagen de una persona que permite identificarla constituye un dato personal.

Deep Learning (Aprendizaje Profundo): Rama de la inteligencia artificial basada en redes neuronales artificiales de múltiples capas, que permite al sistema aprender automáticamente a reconocer patrones complejos en datos (como imágenes o video) sin necesidad de programación explícita para cada regla (Goodfellow et al., 2016). Es la tecnología base

detrás de los modelos de visión utilizados en este proyecto.

Descriptor de apariencia: Conjunto de características visuales de una persona, como el color de la indumentaria, la complexión o los accesorios, que permite distinguirla de otras sin recurrir a rasgos biométricos. En este proyecto, se utiliza para sostener la identidad de cada persona dentro de una visita.

Distancia de Bhattacharyya: Medida estadística de la similitud entre dos distribuciones de probabilidad. En visión por computadora, se utiliza para comparar histogramas de color: cuanto menor es la distancia, más parecidas son las imágenes comparadas.

Distancia de Levenshtein: Cantidad mínima de inserciones, eliminaciones o sustituciones de caracteres necesarias para transformar una cadena de texto en otra. Es la base de las técnicas de coincidencia difusa que toleran errores de escritura o de lectura.

DNS dinámico (DDNS): Servicio que asocia un nombre de dominio fijo a una dirección IP pública que cambia periódicamente, permitiendo localizar un equipo desde internet aunque su dirección varíe.

Edge Computing (Computación en el borde): Modelo de arquitectura donde el procesamiento de datos se realiza en el lugar donde se generan (en este caso, dentro del local o en un servidor local) en lugar de depender exclusivamente de servidores en la nube, lo cual resulta crítico para reducir la latencia y garantizar la privacidad (Shi et al., 2016).

Expo Go: Entorno de pruebas (sandbox) y plataforma de desarrollo para aplicaciones móviles construidas con React Native, que permite ejecutar prototipos rápidamente en dispositivos físicos.

FastAPI: Framework web moderno y de alta velocidad basado en Python para la construcción de APIs REST, que se destaca por su soporte de manejo asíncrono.

FFmpeg: Conjunto de herramientas de código abierto para la conversión, el recorte y la codificación de archivos de audio y video. En este proyecto se utiliza para generar los clips de evidencia de las alertas.

Fine-tuning (Ajuste fino): Proceso mediante el cual un modelo de inteligencia artificial preentrenado en un conjunto de datos general se entrena adicionalmente sobre un conjunto de datos específico. Esto permite adaptar el modelo para mejorar su desempeño en una tarea particular sin necesidad de entrenarlo desde cero.

Flask: Microframework de desarrollo web basado en Python, utilizado para la construcción y

exposición de la API REST del sistema.

Flujo secundario (Substream): Segunda transmisión de video que genera un grabador o una cámara IP, con menor resolución y tasa de bits que el flujo principal. Se emplea para visualización remota y análisis automático cuando el ancho de banda disponible es limitado.

Fotograma (Frame) y FPS: Cada una de las imágenes fijas que componen una secuencia de video. La cantidad de fotogramas que se capturan o procesan por segundo se expresa en FPS (*frames per second*) y determina la fluidez del video y la carga de procesamiento del sistema.

Franquicia: Modelo de negocio en el que una empresa (en este caso, YPF) cede a un tercero el derecho de operar un establecimiento bajo su marca, a cambio de cumplir con lineamientos comerciales y operativos definidos por la empresa.

Góndola: Mueble de exhibición con estantes en el que se ubican los productos al alcance del cliente dentro del salón de ventas. Junto con las heladeras exhibidoras, constituye una de las principales zonas de interacción entre los clientes y la mercadería.

GPU (Graphics Processing Unit): Unidad de Procesamiento Gráfico. Hardware especializado diseñado para acelerar el procesamiento de imágenes y cálculos matemáticos paralelos, fundamental para ejecutar eficientemente modelos de inteligencia artificial y deep learning.

Hash (Función de hash): Función que transforma un dato, como una contraseña, en una cadena de longitud fija de la cual no es posible recuperar el valor original. Permite verificar una contraseña sin almacenarla en texto plano.

Hik-Connect: Aplicación oficial de Hikvision diseñada para gestionar sistemas de seguridad de forma remota. Permite ver cámaras en vivo, recibir alertas en tiempo real y controlar dispositivos como alarmas o videoporteros desde el celular o la computadora.

Histograma de color HSV: Representación de la distribución de colores de una imagen en el espacio HSV (tono, saturación y brillo). Al separar el tono del brillo, resulta menos sensible a los cambios de iluminación que otros espacios de color y permite comparar la apariencia de dos personas.

Inferencia: Proceso en el cual un modelo de inteligencia artificial ya entrenado aplica lo aprendido para realizar predicciones o identificaciones sobre nuevos datos en tiempo real (por ejemplo, detectar una persona en un fotograma de video).

IP (Internet Protocol): Protocolo de Internet. Conjunto de reglas que rige el formato de los datos enviados a través de una red. En el contexto de videovigilancia, las cámaras IP permiten transmitir video a través de redes locales o internet.

Latido (Heartbeat): Señal periódica que un proceso emite para indicar que continúa en ejecución. En este proyecto, permite distinguir un análisis de video que se interrumpió de uno que continúa activo en otro equipo.

LiDAR (Light Detection and Ranging): Tecnología de teledetección que mide la distancia a los objetos emitiendo pulsos de luz láser y calculando el tiempo que tarda el reflejo en volver al sensor. Este componente permite generar mapas tridimensionales de alta precisión del entorno en tiempo real, utilizándose en analítica comercial para rastrear el movimiento y comportamiento de las personas en el espacio físico de manera completamente anónima.

LLM (Large Language Model): Tipo de inteligencia artificial entrenado con grandes volúmenes de texto para comprender, generar y razonar sobre lenguaje natural, utilizado en este proyecto como herramienta de asistencia técnica y análisis de información.

LoRA (Low-Rank Adaptation): Técnica eficiente de ajuste fino que permite adaptar modelos de inteligencia artificial de gran escala a tareas específicas, modificando únicamente una pequeña cantidad de parámetros adicionales. Esta técnica reduce significativamente los requisitos de memoria y cómputo en comparación con el reentrenamiento completo del modelo.

LPU (Language Processing Unit): Arquitectura de hardware diseñada para la aceleración de modelos de lenguaje, optimizada para un procesamiento determinista y de baja latencia mediante un motor de flujo tensorial que elimina los cuellos de botella de memoria tradicionales.

Mapa de Calor (Heatmap): Representación visual que utiliza una escala de colores para indicar la densidad o frecuencia de un fenómeno en una superficie determinada. En el contexto de este proyecto, se aplica sobre el plano del local para identificar las zonas de mayor circulación y permanencia de clientes, facilitando la optimización de la distribución del espacio y la dotación de personal.

MediaMTX: Servidor y proxy de medios de código abierto empleado para la recepción, retransmisión y gestión de flujos de video bajo protocolos como RTSP.

Merma: Pérdida de mercadería originada por rotura, vencimiento, deterioro, consumo no registrado o hurto, que provoca una diferencia entre el stock registrado y el stock disponible.

MJPEG (Motion JPEG): Formato de video en el que cada fotograma se transmite como una imagen JPEG independiente. Es simple y compatible con la mayoría de los navegadores y bibliotecas de visión, aunque requiere más ancho de banda que los formatos con compresión entre fotogramas.

Modelo multimodal: Modelo de inteligencia artificial capaz de procesar e interpretar más de un tipo de información, como texto e imágenes, dentro de una misma consulta. En este proyecto, se utiliza para describir la apariencia de las personas y para leer los envases de los productos en caja.

NAT (Network Address Translation): Mecanismo de los routers que traduce las direcciones IP privadas de una red local a una dirección pública para salir a internet. Por defecto bloquea las conexiones iniciadas desde el exterior hacia los equipos de la red interna.

Nodo de captura: Equipo instalado dentro del establecimiento y conectado a su red local, cuya función es retransmitir de forma segura los flujos de video del grabador hacia los equipos de análisis ubicados fuera del local. En este proyecto, el nodo es una tableta Microsoft Surface Pro 3 con Ubuntu.

NVR (Network Video Recorder): Grabador de Video en Red. Sistema de software o hardware que registra y almacena videos provenientes de cámaras IP en una unidad de almacenamiento digital, permitiendo la gestión y visualización de grabaciones.

Oclusión: Situación en la que un objeto o una persona queda total o parcialmente oculto detrás de otro elemento de la escena, como otra persona, una góndola o una columna. Constituye una de las principales dificultades para la detección y el seguimiento en video.

OpenCV (Open Source Computer Vision Library): Biblioteca de código abierto orientada al procesamiento de imágenes y visión por computadora en tiempo real.

PaaS (Platform as a Service): Modelo de servicio en la nube en el que un proveedor administra la infraestructura necesaria para ejecutar aplicaciones (servidores, red y certificados), de modo que el equipo de desarrollo solo se ocupa de publicar su código. Render es un ejemplo de este tipo de plataforma.

Pérdida desconocida (Shrinkage): Diferencia entre el inventario registrado y el inventario real que no puede atribuirse a una causa conocida al momento de detectarse. Suele originarse en hurtos, errores de registro o mermas no informadas.

Permanencia (Dwell time): Tiempo que una persona permanece dentro del local o en una

zona específica. Es un indicador utilizado en retail para analizar el comportamiento de los clientes y el uso del espacio.

Planograma: Diagrama o modelo visual que representa de forma detallada la distribución y ubicación exacta de los productos en las góndolas, estantes o exhibidores de un punto de venta. Se utiliza en el sector comercial para estandarizar la presentación visual, asegurar el cumplimiento de acuerdos con las marcas y optimizar la exposición de los artículos de acuerdo con las estrategias de marketing y rotación de inventario.

Privacidad por diseño (Privacy by Design): Enfoque que propone incorporar la protección de la privacidad desde las primeras etapas del diseño de un sistema, en lugar de agregarla como un control posterior (Cavoukian, 2009).

Prompt: Instrucción o conjunto de instrucciones en lenguaje natural que se envía a un modelo de lenguaje para indicarle la tarea a realizar y el formato de la respuesta esperada.

PyTorch: Biblioteca de aprendizaje automático de código abierto basada en Python, ampliamente utilizada para el desarrollo y entrenamiento de modelos de Deep Learning.

React: Biblioteca de JavaScript basada en componentes para el desarrollo de interfaces de usuario interactivas y tableros de control (dashboards).

Reidentificación de personas (ReID): Tarea de reconocer a un mismo individuo en distintos momentos o en distintas cámaras cuando su seguimiento continuo se interrumpe. Puede resolverse a partir de la apariencia general de la persona, sin recurrir al reconocimiento facial.

Reposición: Tarea de trasladar mercadería desde el depósito hacia las góndolas y heladeras del salón para cubrir los productos vendidos o faltantes.

Retail Analytics: Conjunto de técnicas y herramientas de análisis de datos aplicadas al entorno del comercio minorista, con el objetivo de obtener información útil sobre el comportamiento de los clientes, el rendimiento operativo y la gestión de inventario. En este proyecto, se emplea para transformar los datos visuales capturados por las cámaras en métricas e indicadores accionables para la toma de decisiones.

Roboflow: Plataforma de software como servicio (SaaS) orientada a la centralización, anotación, control de versiones y aumentación de conjuntos de datos (datasets) para visión artificial.

ROI (Region of Interest - Región de Interés): Área delimitada dentro de un fotograma o

imagen sobre la cual se focalizan los procesos de análisis o detección. En este proyecto, las regiones de interés se definen como polígonos sobre la imagen de cada cámara (entrada, salida, caja, góndola, entre otras) y se denominan zonas.

RTSP (Real Time Streaming Protocol): Protocolo de red utilizado para controlar la transmisión de audio y video en tiempo real a través de una red IP (Schulzrinne et al., 1998). Es ampliamente empleado en sistemas de videovigilancia para acceder al flujo de video generado por cámaras de seguridad. En el contexto de este proyecto, RTSP permite obtener las secuencias de video de las cámaras instaladas en la estación de servicio para su posterior procesamiento mediante técnicas de visión por computadora e inteligencia artificial.

SaaS (Software as a Service): Modelo de distribución de software donde una aplicación es alojada por un proveedor externo y puesta a disposición de los usuarios a través de internet (como la plataforma utilizada para la gestión de datasets).

Seguimiento multiobjeto (Multi-Object Tracking): Tarea de visión por computadora que consiste en asociar las detecciones de varios objetos a lo largo de fotogramas consecutivos, asignando a cada uno un identificador que permite reconstruir su trayectoria.

SKU (Stock Keeping Unit): Código que identifica de manera única cada artículo de un catálogo, diferenciando sus variantes de marca, sabor o tamaño. Por ejemplo, dos sabores de una misma gaseosa corresponden a SKU distintos.

Stock teórico y stock físico: El stock teórico es la cantidad de mercadería que debería existir según los registros del sistema de gestión; el stock físico es la cantidad efectivamente disponible en el depósito y el salón. La diferencia entre ambos revela errores de registro, mermas o hurtos.

Supabase: Plataforma de desarrollo tipo BaaS (Backend-as-a-Service) basada en un motor relacional PostgreSQL, utilizada para la persistencia de datos y almacenamiento de objetos.

Tailscale: Servicio de red privada virtual (VPN) en malla basado en el protocolo WireGuard, que establece túneles cifrados seguros entre dispositivos sin necesidad de reconfigurar los routers locales.

Tasa de conversión: Proporción de visitantes de un establecimiento que concretan una compra respecto del total de personas que ingresaron. Es uno de los principales indicadores de desempeño comercial en retail.

Token: Unidad mínima de texto (una palabra, parte de una palabra o un signo) con la que trabajan los modelos de lenguaje. Los proveedores de estos modelos suelen facturar su uso

en función de la cantidad de tokens procesados.

Umbral de confianza: Valor mínimo de probabilidad que debe alcanzar una detección para ser aceptada como válida. Un umbral alto reduce los falsos positivos pero puede omitir objetos reales, mientras que un umbral bajo produce el efecto contrario.

VPN (Virtual Private Network): Red Privada Virtual. Tecnología de red que crea una conexión segura y cifrada a través de una red menos segura (como internet), permitiendo acceder a recursos privados (como la infraestructura de cámaras de la tienda) de forma segura.

WireGuard: Protocolo de red privada virtual de código abierto que establece túneles cifrados entre dispositivos con baja latencia y una configuración reducida. Constituye la base tecnológica sobre la que opera Tailscale.

YOLOv8: Arquitectura de red convolucional de una sola etapa optimizada para la detección de objetos en tiempo real con alta velocidad de inferencia. Se ofrece en distintos tamaños (Nano, Small, Medium, Large y XLarge) que permiten balancear velocidad y precisión.

YPF FULL: Formato de tienda de conveniencia operado bajo la red de estaciones de servicio YPF en Argentina. Se caracteriza por una oferta de productos de alta rotación, lineamientos corporativos estrictos en cuanto a la disposición de mercadería (planogramas) y dinámicas operativas con picos estacionales de afluencia de clientes.

Zero-shot: Capacidad de un modelo de inteligencia artificial para resolver una tarea sobre categorías que no formaron parte de su entrenamiento específico. En este proyecto, permite reconocer productos leyendo su envase sin haber entrenado un modelo con imágenes de cada artículo.

DIAGNÓSTICO (PROBLEMÁTICA)

La situación que da origen a este proyecto se sitúa en el entorno operativo de las tiendas FULL de estaciones de servicio YPF, un modelo de negocio con dinámicas de alta rotación, picos estacionales de clientes y lineamientos corporativos sumamente estructurados. A pesar de contar con sistemas de gestión y cámaras de seguridad físicas, se detecta una falta de automatización inteligente para procesar la información del entorno en tiempo real. Actualmente, menos del 10% de las franquicias logra un control operativo y de stock verdaderamente profesional, dependiendo casi en su totalidad de procesos manuales y respuestas reactivas ante los problemas cotidianos. En este escenario, surge la oportunidad de expandir las fronteras convencionales de la tecnología en el ámbito comercial mediante el aprovechamiento estratégico de la Inteligencia Artificial aplicada a los negocios.

Actualmente, el uso de la IA en el mercado se ha concentrado en plataformas de software analítico o herramientas predictivas basadas puramente en datos numéricos de facturación. La propuesta busca romper con este enfoque clásico al llevar la inteligencia artificial directamente al monitoreo de cámaras de seguridad, un área donde su aplicación en tiempo real aún no está masificada ni aprovechada en todo su potencial dentro de comercios de mediana escala. La idea diferencial del proyecto consiste en transformar un sistema de videovigilancia pasivo en una herramienta dinámica de asistencia operativa. Al dotar a las cámaras de la capacidad de comprender el entorno de forma autónoma, el sistema se convierte en un aliado directo para el encargado o el personal de la tienda, ayudando a quien lo necesite a captar con precisión cualquier evento, métrica o patrón de comportamiento que se desee analizar, optimizando así los recursos del negocio y simplificando la toma de decisiones diarias.

Estado del arte (contexto actual)

El entorno comercial de la tienda se rige por planogramas estrictos definidos por YPF, los cuales determinan la ubicación exacta de cada producto en góndolas, exhibidores y heladeras para cumplir con acuerdos comerciales y de marketing. Sin embargo, el control del cumplimiento de este diseño y la reposición de mercadería es puramente visual y manual. El personal operativo recorre las góndolas para verificar los faltantes a ojo y luego realiza el traspaso de mercadería desde el depósito interno mediante un escáner y una tablet.

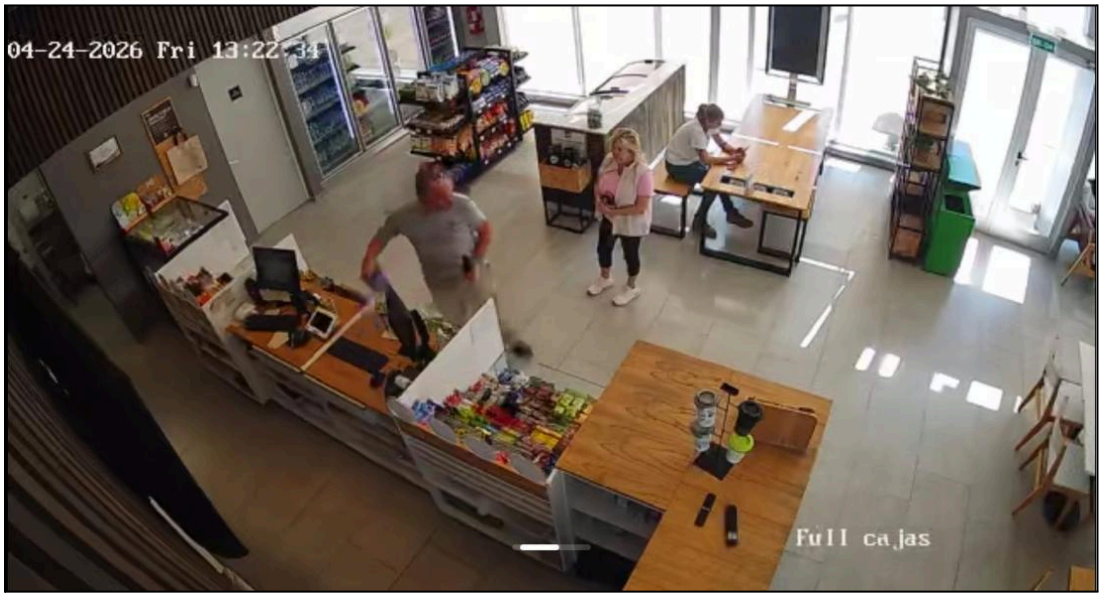


Figura 1: Cámara dentro de la tienda, que graba la zona de la caja, desde un ángulo superior derecho - Cámara 4

Fuente: elaboración propia a partir de capturas de la aplicación Hik-Connect.

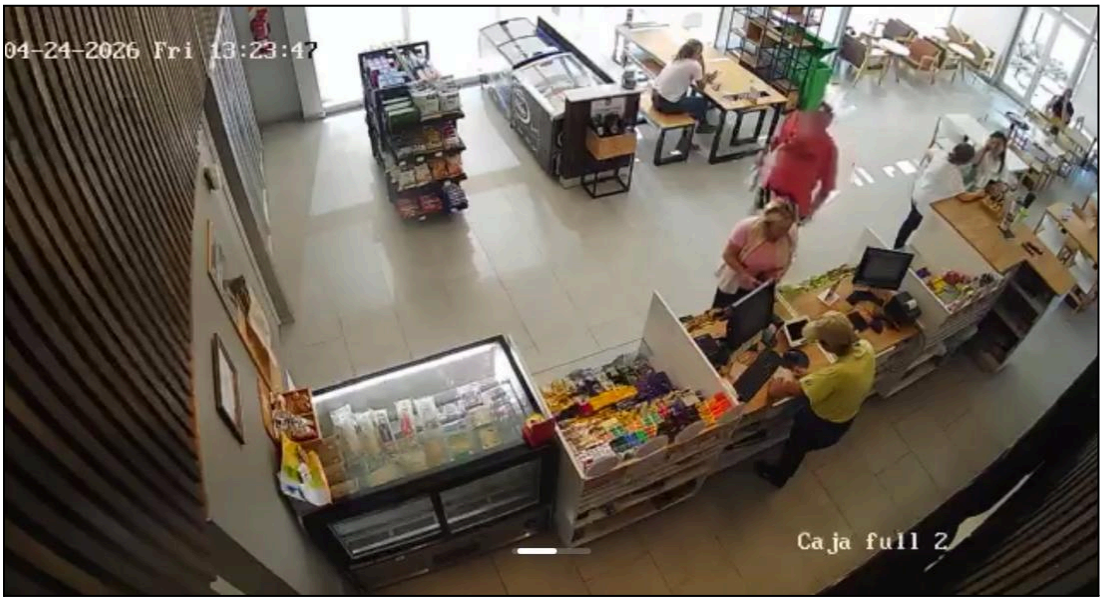


Figura 2: Cámara dentro de la tienda, que graba la zona de la caja, desde un ángulo superior izquierdo - Cámara 3

Fuente: elaboración propia a partir de capturas de la aplicación Hik-Connect.

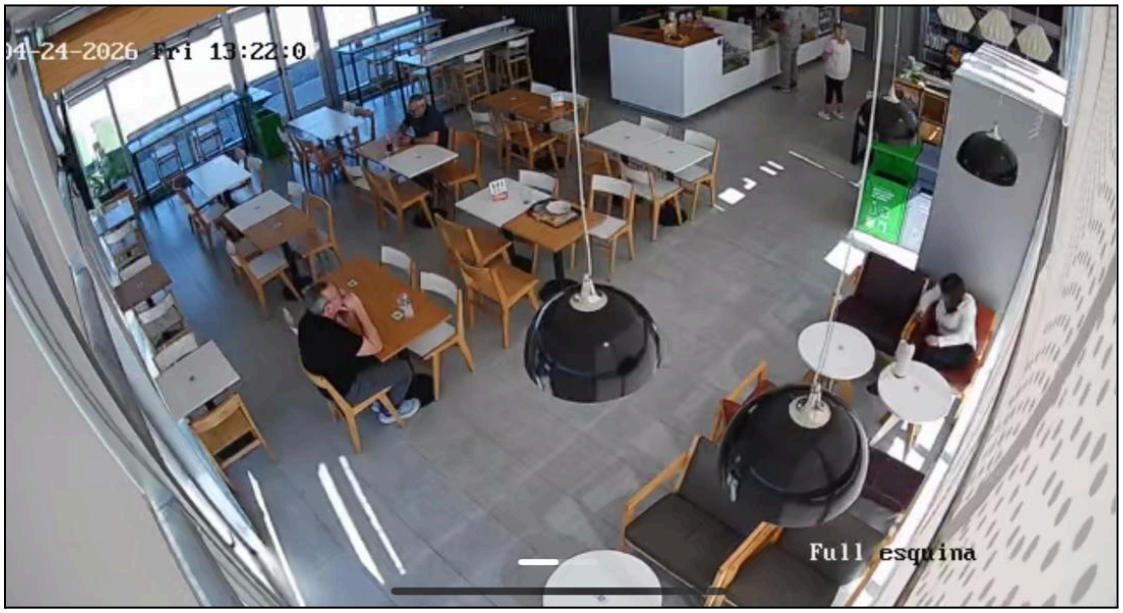


Figura 3: Cámara dentro de la tienda, en la zona del salón, que graba desde un ángulo superior izquierdo - Cámara 2

Fuente: elaboración propia a partir de capturas de la aplicación Hik-Connect.

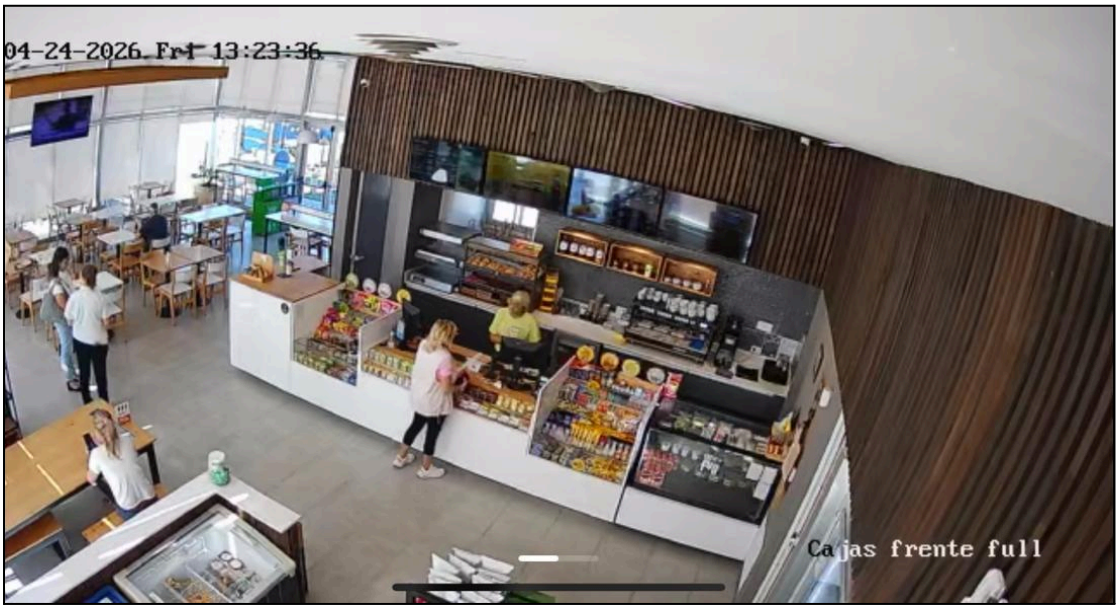


Figura 4: Cámara dentro de la tienda, que graba la zona de la caja, desde un ángulo superior el frente de la caja - Cámara 1

Fuente: elaboración propia a partir de capturas de la aplicación Hik-Connect.

Como se puede observar en las figuras 1, 2, 3 y 4, la estación de servicio dispone de un circuito de cámaras de video distribuidas en el salón y la caja, pero carece de un centro de monitoreo permanente. Las cámaras se utilizan de forma reactiva: se revisan a través de

aplicaciones móviles únicamente cuando ya ocurrió un incidente, como la pérdida de un objeto por parte de un cliente, un error en la facturación de una tarjeta o la sospecha de un hurto consumado. Toda la información visual disponible se desaprovecha en el día a día para la gestión operativa en vivo.

Impacto

La falta de herramientas predictivas y de análisis en tiempo real afecta directamente a los encargados, al personal de caja y a la rentabilidad general del negocio de la siguiente manera:

Uno de los principales inconvenientes detectados es la dificultad para identificar diferencias entre el stock registrado en el sistema y la mercadería efectivamente disponible en góndolas. Estas diferencias pueden originarse por errores operativos, productos mal registrados durante la venta, reposiciones incorrectas o pérdidas ocasionadas por hurtos (National Retail Federation, 2023). En la actualidad, estas situaciones suelen detectarse únicamente cuando se realiza una reposición, un control de inventario o cuando el faltante ya es evidente para el personal.

Por otro lado, existen dificultades para conciliar el stock teórico con el real debido a la venta de combos. Con frecuencia, se registra en el sistema una variedad de bebida o producto genérico pero el cliente retira otro de igual valor de la heladera, desconfigurando el inventario analítico. Asimismo, la preparación de productos como el café a clientes habituales a veces genera dinero sobrante o mermas que no se facturan formalmente en el sistema de manera inmediata, impactando en el balance diario de caja.

Al mismo tiempo, la empresa carece de métricas objetivas relacionadas con el comportamiento de los clientes dentro del local, lo que se traduce en una falta de información precisa sobre la cantidad de personas que ingresan, las zonas de mayor circulación y la concentración en determinados sectores. Esta carencia analítica agrava la saturación operativa que sufre la tienda ante picos imprevistos de flujo de clientes, una situación recurrente durante fines de semana largos, temporadas de viajes de estudio o la llegada de colectivos con contingentes de más de 40 personas en simultáneo. Al no disponer de registros históricos ni alertas en tiempo real sobre estos flujos, y al contar con personal reducido en horas pico, la alta afluencia colapsa la capacidad del salón, generando largas colas e incrementando los tiempos de espera principalmente en la entrega de pedidos ya abonados en cafetería y cocina. Al no poder relacionar el flujo real de personas con el tiempo de permanencia y el volumen de ventas final, el negocio pierde la capacidad de

prever estos escenarios, lo que eleva la impaciencia de los usuarios y satura el espacio físico disponible, demostrando la necesidad de contar con datos visuales traducidos en métricas comerciales para optimizar las decisiones operativas.

Oportunidades

En este contexto surge la oportunidad de desarrollar una solución que aproveche la infraestructura de cámaras ya instalada para automatizar la obtención de información operativa relevante y transformar este escenario reactivo en un sistema proactivo y eficiente que genere valor añadido. La implementación de mecanismos de detección y análisis de eventos mediante Computer Vision permitiría mejorar el control sobre productos, identificar situaciones potencialmente anómalas, obtener indicadores de comportamiento de clientes y proporcionar información útil para optimizar los procesos internos de la tienda.

La infraestructura de cámaras ya instalada en la tienda representa la base tecnológica para transicionar de una gestión puramente reactiva a un modelo proactivo y eficiente que genere valor añadido. Mediante la implementación de mecanismos de visión por computadora, es posible automatizar el análisis del flujo de personas procesando los flujos de video RTSP existentes en tiempo real. Este sistema registrará de manera continua las trayectorias y los tiempos de permanencia de los clientes sin recurrir en ningún momento a la identificación biométrica o al reconocimiento facial, garantizando el cumplimiento de los principios de privacidad por diseño. A través de este procesamiento visual, la plataforma generará automáticamente mapas de calor y métricas de circulación detalladas que permitirán comprender con exactitud qué zonas del salón atraen mayor atención, facilitando la toma de decisiones estratégicas como la optimización de la dotación del personal de cocina y atención en función de los picos de visitas identificados.

Paralelamente, el análisis inteligente de los patrones de movimiento dota a la tienda de herramientas avanzadas para la prevención de pérdidas y la emisión de alertas tempranas. Al evaluar las trayectorias dentro del local, el software puede detectar de manera proactiva comportamientos potencialmente sospechosos, tales como un desplazamiento directo desde las góndolas críticas y de mayor riesgo de hurto —como el sector de dulces o productos de alto valor— hacia la puerta de salida sin efectuar el recorrido correspondiente por el área de cajas. Cuando esto ocurre, el sistema notifica de forma instantánea a través de la interfaz web para que el personal operativo pueda intervenir preventivamente o, en su defecto, cuente con un registro certero para validar los descuadres de inventario al final de la jornada.

De esta manera, el proyecto busca convertir un recurso actualmente subutilizado en una fuente de información estratégica capaz de aportar valor tanto a nivel operativo como de gestión.

OBJETIVOS

GLOBAL

Desarrollar una solución basada en Visión por Computadora e Inteligencia Artificial que permita aprovechar la infraestructura de cámaras existente en una tienda FULL de una estación de servicio para obtener información operativa relevante, automatizar la detección de eventos de interés y generar métricas que contribuyan a la toma de decisiones y a la optimización de los procesos internos.

ESPECÍFICOS

- Investigar el dominio del problema mediante trabajo de campo, relevando necesidades operativas y características del entorno de una estación de servicio.
- Analizar y seleccionar modelos de visión por computadora adecuados para detección de productos y personas.
- Implementar un módulo de captura de video mediante protocolo RTSP.
- Desarrollar un sistema de reconocimiento de productos para asistir en el control de stock.
- Implementar un sistema de detección y seguimiento de personas para registrar trayectorias y analizar la circulación dentro del local.
- Generar mapas de calor, métricas de flujo y estimaciones de tiempos de espera en caja.
- Implementar un módulo de análisis que transforme los datos recolectados en información útil (métricas, indicadores y reportes).
- Desarrollar una interfaz web para la visualización de métricas, reportes y alertas.
- Implementar un mecanismo de detección de comportamientos sospechosos basado en trayectorias (por ejemplo, movimientos hacia la salida sin pasar por caja).

TABLA DE TRAZABILIDAD (opcional - recomendada)

La Tabla 1 vincula cada objetivo específico con los requerimientos que lo materializan, los módulos que lo implementan y la evidencia que respalda su cumplimiento. La evidencia se amplía en la sección de Pruebas.

Tabla 1

Trazabilidad entre objetivos específicos, requerimientos y evidencia de cumplimiento

Objetivo específico	**Requerimientos**	**Implementación**	**Evidencia de cumplimiento**
1. Investigar el dominio del problema mediante trabajo de campo	—	—	Secciones 2.8 a 2.11 del Marco Teórico; guía de entrevista (Anexos)
2. Analizar y seleccionar modelos de visión por computadora para la detección de productos y personas	—	—	Secciones 4.3 y 4.5 del Marco Teórico; selección tecnológica en la Propuesta; justificación del enfoque en el Módulo 8
3. Implementar un módulo de captura de video mediante RTSP	RF-04, RF-05, RNF-05, RNF-06	Módulo 2	Pruebas unitarias de las fuentes de video; pruebas de la infraestructura de captura remota
4. Desarrollar un sistema de reconocimiento de productos para asistir en el control de stock	RF-21 a RF-25	Módulo 8	Pruebas de matching y de detección de escena estable; Figuras 10, 15 y 17
5. Implementar la detección y el seguimiento de personas	RF-06 a RF-10	Módulo 3	Pruebas unitarias del seguimiento; validación sobre grabaciones reales del NVR
6. Generar mapas de calor, métricas de flujo y estimaciones de tiempos de espera en caja	RF-11 a RF-14, RF-27	Módulos 6 y 9	Pruebas de cálculo de estadísticas y del mapa de calor; Figuras 8 y 9
7. Implementar un módulo de análisis que transforme los datos en	RF-26 a RF-30	Módulos 7 y 9	Pruebas de persistencia y de rangos de fechas; Figura 12

información útil			
8. Desarrollar una interfaz web para la visualización de métricas, reportes y alertas	RF-01 a RF-03, RF-26, RF-28, RNF-07, RNF-09	Módulos 1 y 10	Pruebas de inicio de sesión; prueba de integración del sistema completo; Figuras 5 a 12
9. Implementar la detección de comportamientos sospechosos basada en trayectorias	RF-15 a RF-20	Módulos 4 y 5	Pruebas unitarias de clasificación de visitas y de evidencia; Figuras 11 y 16

Fuente: elaboración propia.

MARCO TEÓRICO

1. Contexto General del Problema

1.1 Introducción

La transformación digital ha impulsado cambios significativos en la forma en que las organizaciones gestionan sus operaciones, analizan información y toman decisiones. En distintos sectores económicos, la incorporación de tecnologías basadas en datos ha permitido automatizar procesos, optimizar recursos y mejorar la eficiencia operativa.

Dentro de este contexto, los comercios minoristas enfrentan el desafío constante de administrar grandes volúmenes de productos, atender flujos variables de clientes y mantener niveles adecuados de servicio. La necesidad de obtener información precisa y oportuna sobre lo que ocurre dentro de los establecimientos ha dado lugar al desarrollo de nuevas herramientas tecnológicas destinadas a mejorar la supervisión y el control de las operaciones.

Las estaciones de servicio modernas han evolucionado considerablemente durante los últimos años. Además de la venta de combustibles, muchas de ellas incorporan tiendas de conveniencia que ofrecen alimentos, bebidas, productos de consumo masivo y servicios complementarios. Esta diversificación ha convertido a estos establecimientos en espacios comerciales complejos que requieren mecanismos de gestión cada vez más sofisticados.

Dentro de Argentina, YPF constituye una de las principales empresas del sector energético y posee una extensa red de estaciones de servicio distribuidas a lo largo del país. Como parte de su estrategia comercial, la empresa desarrolló las tiendas FULL, concebidas como espacios de conveniencia orientados a complementar la experiencia de los clientes mediante la venta de productos alimenticios, cafetería, bebidas, snacks y otros artículos de consumo inmediato.

1.2 Las tiendas FULL como entorno operativo

Las tiendas FULL operan en un contexto caracterizado por una alta variabilidad en la cantidad de clientes que ingresan diariamente. A diferencia de otros comercios tradicionales, estas tiendas reciben consumidores con perfiles muy diversos, incluyendo viajeros, transportistas, turistas, trabajadores y residentes locales.

La demanda de productos no se distribuye de manera uniforme a lo largo del día. Existen horarios de mayor afluencia, períodos vacacionales, fines de semana largos y eventos particulares que generan incrementos significativos en la cantidad de personas que visitan el establecimiento.

Esta variabilidad provoca desafíos operativos relacionados con la atención al cliente, la disponibilidad de productos, la reposición de mercadería y el control general de las operaciones comerciales.

Además, debido a que gran parte de los productos comercializados corresponden a artículos de consumo rápido, la rotación de inventario suele ser elevada. Esto obliga a realizar tareas constantes de control y reposición para garantizar que los productos se encuentren disponibles para los clientes en todo momento.

Como consecuencia, la eficiencia operativa se convierte en un factor crítico para mantener la calidad del servicio y la rentabilidad del negocio.

1.3 Importancia del control operativo en comercios minoristas

La gestión eficiente de un comercio minorista requiere disponer de información confiable sobre múltiples aspectos de la operación diaria.

Entre los elementos más relevantes se encuentran:

- Disponibilidad de productos.
- Estado de las góndolas.
- Flujo de clientes.
- Tiempos de permanencia dentro del local.
- Utilización de espacios.
- Identificación de comportamientos anómalos.
- Detección de pérdidas de mercadería.
- Análisis de sectores de mayor interés comercial.

Tradicionalmente, gran parte de esta información se obtiene mediante observación directa del personal o a través de controles periódicos realizados de manera manual.

Si bien estos procedimientos permiten mantener un nivel básico de supervisión, presentan limitaciones relacionadas con la disponibilidad de recursos humanos, la subjetividad de las observaciones y la imposibilidad de monitorear simultáneamente múltiples eventos que ocurren en diferentes sectores del establecimiento.

A medida que aumenta la complejidad operativa, también se incrementa la necesidad de contar con herramientas capaces de proporcionar información objetiva, actualizada y accesible para los responsables de la gestión.

1.4 Sistemas de videovigilancia en comercios

La mayoría de los establecimientos comerciales modernos dispone de sistemas de videovigilancia compuestos por cámaras distribuidas estratégicamente en diferentes sectores.

Originalmente, estas cámaras fueron incorporadas con fines de seguridad física, prevención de incidentes y registro de eventos.

Sin embargo, los avances tecnológicos han ampliado significativamente las posibilidades de utilización de estos sistemas (Szeliski, 2022).

Actualmente, las imágenes capturadas por las cámaras pueden utilizarse para obtener información relacionada con la operación del negocio, permitiendo transformar registros visuales en datos útiles para la gestión.

Las cámaras representan una fuente permanente de información sobre lo que ocurre dentro de un establecimiento. No obstante, en muchos casos, esta información permanece desaprovechada debido a que únicamente se consulta cuando ocurre algún incidente específico o cuando es necesario revisar eventos pasados.

Como resultado, grandes volúmenes de información potencialmente valiosa permanecen almacenados sin generar beneficios concretos para la organización.

1.5 Procedimientos actuales del dominio

En los entornos comerciales como las tiendas de conveniencia, diversos procesos continúan realizándose mediante métodos manuales o semi manuales.

Uno de los procedimientos más frecuentes corresponde al control de stock. Habitualmente, los empleados realizan recorridos visuales por las góndolas para identificar productos faltantes y determinar qué artículos deben ser repuestos.

Posteriormente, la información observada es utilizada para efectuar las tareas de reposición desde el depósito o para generar pedidos de mercadería.

Otro procedimiento habitual consiste en la supervisión general del local. La

identificación de comportamientos inusuales, acumulaciones de personas o situaciones potencialmente problemáticas depende principalmente de la observación directa realizada por el personal durante su jornada laboral.

Del mismo modo, el análisis del flujo de clientes suele efectuarse mediante estimaciones aproximadas basadas en la experiencia de los encargados, sin contar necesariamente con métricas objetivas que permitan cuantificar patrones de circulación o permanencia dentro del establecimiento.

La detección de pérdidas de mercadería también suele realizarse de forma reactiva. En muchos casos, las diferencias entre el stock esperado y el stock disponible son detectadas únicamente cuando se realizan controles posteriores o cuando surge la necesidad de reponer determinados productos.

Asimismo, la revisión de grabaciones provenientes de las cámaras de seguridad generalmente ocurre después de identificar alguna irregularidad, transformando a las cámaras en herramientas de consulta posterior más que en instrumentos activos de análisis operativo.

1.6 Estudios y tendencias actuales

Diversos estudios relacionados con el sector retail destacan la creciente adopción de tecnologías basadas en Inteligencia Artificial, análisis de datos y visión por computadora para mejorar la eficiencia operativa (National Retail Federation, 2023; Underhill, 2009).

Grandes cadenas comerciales utilizan actualmente sistemas capaces de analizar automáticamente imágenes y videos para realizar conteo de personas, medir tiempos de espera, detectar faltantes en góndolas, analizar recorridos de clientes y optimizar la disposición de productos dentro de los establecimientos.

Estas soluciones permiten transformar información visual en indicadores de negocio que facilitan la toma de decisiones estratégicas y operativas.

La tendencia actual apunta hacia el desarrollo de establecimientos inteligentes capaces de aprovechar la infraestructura tecnológica existente para generar información en tiempo real sin necesidad de incrementar significativamente los costos operativos.

Este enfoque busca maximizar el valor obtenido a partir de recursos ya instalados, especialmente en aquellos casos donde los sistemas de videovigilancia se encuentran disponibles pero subutilizados.

1.7 Relevancia de la problemática

La importancia de esta problemática radica en que afecta directamente la eficiencia operativa, la disponibilidad de productos, la experiencia de los clientes y la capacidad de gestión de los responsables del negocio.

La falta de información precisa sobre lo que ocurre dentro del establecimiento dificulta la identificación temprana de situaciones que podrían corregirse de manera preventiva.

Por otra parte, la creciente disponibilidad de tecnologías de análisis visual abre nuevas oportunidades para aprovechar recursos ya existentes y generar información de valor sin modificar significativamente la infraestructura física de los establecimientos.

En consecuencia, resulta relevante investigar alternativas que permitan transformar los sistemas tradicionales de videovigilancia en herramientas capaces de contribuir activamente a la gestión operativa y al análisis del funcionamiento de los comercios modernos.

2. Análisis de Campo

2.1 Introducción

En los proyectos de desarrollo de software orientados a resolver problemáticas específicas de una organización, el estudio del contexto real de trabajo constituye una etapa indispensable para comprender el funcionamiento del dominio donde será implementada la solución. Si bien el análisis bibliográfico y el estudio del estado del arte permiten conocer las tecnologías disponibles y las tendencias existentes, estos recursos no siempre reflejan las necesidades particulares de una empresa, sus procesos internos ni las dificultades que enfrentan diariamente los usuarios.

Por este motivo, resulta necesario complementar la investigación documental con un análisis de campo, entendido como un conjunto de técnicas de recolección de información aplicadas directamente sobre el entorno donde se desarrollará el proyecto. Su finalidad consiste en obtener evidencia empírica acerca de los procesos actuales, identificar problemas concretos, conocer las necesidades de los usuarios y validar que la solución propuesta responda a situaciones reales y no únicamente a supuestos teóricos.

En proyectos que involucran automatización de procesos, visión por computadora e

integración con infraestructura existente, como ocurre en el presente Trabajo Final de Carrera, el análisis de campo adquiere una importancia aún mayor. La eficacia de una solución basada en inteligencia artificial depende, en gran medida, del conocimiento detallado del entorno donde será utilizada, de las características físicas del establecimiento, del flujo de trabajo del personal y de las limitaciones operativas presentes en la organización.

2.2 Importancia del análisis de campo en proyectos de ingeniería de software

El desarrollo de sistemas de información modernos se encuentra cada vez más orientado hacia el usuario y hacia la comprensión profunda del contexto de aplicación. Una solución técnicamente correcta puede resultar poco útil si no responde a las necesidades reales de quienes la utilizarán o si no contempla las particularidades del proceso que busca optimizar.

Por esta razón, distintas metodologías de ingeniería de software incluyen actividades de relevamiento y análisis del dominio antes de iniciar el diseño del sistema (Sommerville, 2016; Pressman & Maxim, 2020). Estas actividades permiten comprender cómo se ejecutan actualmente los procesos, cuáles son las dificultades existentes, qué información necesitan los usuarios para tomar decisiones y cuáles son las oportunidades de mejora que pueden abordarse mediante el uso de tecnologías informáticas.

El análisis de campo permite reducir la incertidumbre durante las etapas iniciales del proyecto, ya que proporciona información obtenida directamente de las personas involucradas en la operación diaria. Asimismo, facilita la identificación de requerimientos funcionales y no funcionales, ayuda a delimitar el alcance del sistema y disminuye el riesgo de desarrollar funcionalidades que posteriormente no resulten útiles para la organización.

En proyectos relacionados con visión por computadora, este tipo de relevamiento también permite conocer aspectos técnicos que difícilmente podrían inferirse únicamente mediante documentación, como la ubicación de las cámaras, las condiciones de iluminación, los recorridos habituales de los usuarios, la distribución física de los espacios y la calidad de las imágenes disponibles para el procesamiento automático.

2.3 Técnicas de recolección de información

Existen diversas técnicas utilizadas para realizar un análisis de campo. La elección de cada una depende del tipo de proyecto, de los objetivos perseguidos y del tipo de información que se desea obtener.

Las **entrevistas** constituyen una de las herramientas más utilizadas cuando se busca comprender en profundidad el funcionamiento de una organización. Permiten obtener información cualitativa acerca de los procedimientos cotidianos, las dificultades operativas, las expectativas de los usuarios y las oportunidades de mejora identificadas por quienes desarrollan sus actividades diariamente (Hernández Sampieri & Mendoza Torres, 2018).

La **observación directa** consiste en analizar el entorno donde se desarrollan las actividades, registrando la interacción entre las personas, los procesos y la infraestructura disponible. Esta técnica resulta especialmente útil para identificar situaciones que muchas veces los propios usuarios consideran rutinarias y, por lo tanto, no mencionan durante una entrevista (Hernández Sampieri & Mendoza Torres, 2018).

Otra técnica utilizada en algunos proyectos corresponde al análisis documental, mediante el estudio de manuales operativos, procedimientos internos, diagramas de procesos y documentación institucional que permita comprender el funcionamiento del dominio de estudio.

La combinación de varias técnicas suele proporcionar una visión más completa del problema, permitiendo contrastar la información obtenida desde diferentes perspectivas.

2.4 Justificación del análisis de campo para el presente proyecto

El desarrollo del sistema OptiFull requiere comprender con precisión el funcionamiento operativo de una tienda FULL perteneciente a la red de estaciones de servicio YPF. La propuesta tecnológica plantea reutilizar la infraestructura de videovigilancia existente para obtener información que contribuya a optimizar distintos procesos internos relacionados con la gestión operativa del establecimiento.

Para lograr este objetivo resulta insuficiente conocer únicamente el funcionamiento técnico de los algoritmos de visión por computadora. También es necesario comprender cómo se realizan actualmente las tareas de control de stock, reposición de mercadería, supervisión del local y utilización de las cámaras de seguridad.

Asimismo, deben analizarse aspectos propios del entorno físico, como la distribución de góndolas, la ubicación de las cámaras, la circulación de clientes, las zonas de mayor actividad y las limitaciones propias del establecimiento.

El análisis de campo permite identificar cuáles son los procesos que podrían beneficiarse mediante la incorporación de herramientas de inteligencia artificial y cuáles continúan dependiendo exclusivamente de la intervención humana.

De esta manera, la solución propuesta puede diseñarse considerando las necesidades reales de la organización, evitando incorporar funcionalidades que no aporten valor al negocio y priorizando aquellas que representen un beneficio concreto para la operación diaria.

2.5 Planificación del proceso de relevamiento

Para el desarrollo del presente proyecto se planificó un proceso de relevamiento compuesto por entrevistas semiestructuradas y observaciones presenciales realizadas en una tienda FULL de YPF.

Las entrevistas fueron dirigidas principalmente al personal encargado de la operación del establecimiento, debido a que poseen un conocimiento detallado de los procedimientos diarios, las tareas de reposición, el manejo del stock, la atención al cliente y el uso de los sistemas disponibles.

El formato semiestructurado permitió disponer de una guía de preguntas previamente definida, manteniendo al mismo tiempo la flexibilidad necesaria para profundizar sobre temas que surgieron durante la conversación y que resultaban relevantes para el proyecto.

Paralelamente, se realizaron recorridos por las instalaciones con el objetivo de observar la distribución física del local, la ubicación de las góndolas, la disposición de los productos, el flujo habitual de clientes y la localización de las cámaras de seguridad. Esta observación permitió comprender las condiciones reales bajo las cuales funcionará el sistema y evaluar la viabilidad de utilizar las imágenes capturadas para implementar algoritmos de detección de objetos y análisis de comportamiento.

Como complemento del relevamiento, también se recopiló información sobre la infraestructura tecnológica existente, incluyendo la cantidad aproximada de cámaras instaladas, los sectores cubiertos por cada una de ellas y la forma en que actualmente son utilizadas por el personal del establecimiento.

El relevamiento se llevó a cabo en una tienda FULL perteneciente a una estación de servicio YPF ubicada en la localidad de Piquillín, provincia de Córdoba. Se organizó en tres visitas presenciales, cada una con un objetivo diferente, que acompañaron el avance del proyecto desde la comprensión del dominio hasta la puesta en marcha de la captura en vivo. La Tabla 2 resume las visitas realizadas.

Tabla 2

Visitas realizadas a la estación de servicio

Visita	Fecha	Técnica / actividad	Resultado
1	24 de abril de 2026	Entrevista semiestructurada y recorrido de observación por el salón, la caja, la cocina y el depósito	Relevamiento de procesos, problemas operativos e infraestructura de cámaras (secciones 2.8 a 2.10)
2	Finales de julio de 2026	Extracción de grabaciones del grabador de video en red (NVR) mediante unidades de almacenamiento externas	Grabaciones de una semana de cuatro cámaras, utilizadas para el desarrollo y la calibración del sistema (sección 2.11)
3	24 de septiembre de 2026	Instalación y configuración del nodo de captura remota (Microsoft Surface Pro 3 con Tailscale y MediaMTX)	Acceso en vivo a los flujos de video desde fuera del establecimiento (sección 4.7 y Anexos)

Fuente: elaboración propia.

La información obtenida en la primera visita fue registrada en un documento de trabajo compartido por el equipo. Este documento constituyó la base para la redacción del diagnóstico y para la definición posterior de los requerimientos del sistema. Las visitas siguientes no tuvieron como finalidad la realización de entrevistas, sino la obtención del material de video y la instalación de la infraestructura necesaria para el análisis en tiempo real.

2.6 Objetivos del análisis de campo

El proceso de relevamiento fue diseñado con el propósito de obtener información que permitiera comprender el dominio del problema desde una perspectiva operativa y tecnológica.

Entre los principales objetivos perseguidos se encuentran:

- Comprender el funcionamiento diario de una tienda FULL y los procesos vinculados al control de mercadería.
- Identificar los procedimientos que actualmente se realizan de forma manual o requieren supervisión permanente del personal.
- Conocer la infraestructura tecnológica disponible para determinar la factibilidad de reutilizar las cámaras existentes.

- Analizar el uso actual del sistema de videovigilancia y detectar oportunidades para ampliar su utilidad mediante técnicas de visión por computadora.
- Identificar las principales necesidades y expectativas del personal respecto de una posible herramienta de asistencia operativa.
- Obtener información que permita definir los requerimientos funcionales y no funcionales del sistema propuesto.
- Validar que la solución planteada responda a necesidades reales del establecimiento y pueda integrarse con sus procesos habituales.

2.7 Aporte del análisis de campo al proyecto

La información obtenida mediante el análisis de campo constituye uno de los principales insumos para el desarrollo del presente Trabajo Final de Carrera.

El conocimiento adquirido durante el relevamiento permitirá fundamentar las decisiones de diseño adoptadas durante el desarrollo del sistema, establecer el alcance funcional del proyecto e identificar aquellos procesos que pueden beneficiarse mediante la incorporación de técnicas de visión por computadora e inteligencia artificial.

Asimismo, este proceso contribuye a disminuir el riesgo asociado al desarrollo de soluciones desvinculadas de la realidad operativa de la organización, favoreciendo la construcción de un sistema alineado con las necesidades del negocio y con las posibilidades que ofrece la infraestructura tecnológica existente.

En consecuencia, el análisis de campo representa un puente entre los conceptos teóricos desarrollados en el marco conceptual y la implementación práctica de la solución propuesta, proporcionando el conocimiento necesario para diseñar un sistema técnicamente viable, funcionalmente útil y adaptado al contexto específico de las tiendas FULL de YPF.

2.8 Hallazgos del Relevamiento Operativo y Reglas de Negocio

La entrevista realizada durante la primera visita a la gerente de la tienda y a los propietarios de la estación permitió registrar información crítica sobre la administración del inventario y las dinámicas comerciales que rigen el salón:

- **Rigidez de los Planogramas:** Según detalló la encargada, la disposición de las góndolas y exhibidores está completamente estandarizada por lineamientos corporativos que definen qué marcas y rangos de precios ocupan cada estante. Sin embargo, la gestión de faltantes ante la falta de stock de un producto específico (por ejemplo, golosinas o chocolates particulares) se resuelve de manera manual y

artesanal, rellenando los espacios vacíos con productos sustitutos de la misma marca o expandiendo el stock de los artículos adyacentes para evitar el impacto visual de una góndola vacía.

- **Productos Críticos y Unidades de Mayor Rentabilidad:** Se identificó que el núcleo del negocio y los productos que generan el mayor margen de ganancia no son los artículos de almacén cerrados, sino los de elaboración propia, específicamente la cafetería y el sector de comida (como hamburguesas y minutas). Por el contrario, los artículos empaquetados de alto costo y alta rotación en góndola (como papas Pringles o chocolates) representan los puntos de mayor vulnerabilidad para el negocio debido a la recurrencia de hurtos que no son detectados a tiempo.

- **Descuadres analíticos por Combos Comerciales:** Un problema operativo recurrente revelado en la entrevista es el desfase entre el stock teórico de los sistemas de gestión y el stock físico real debido a la venta de combos. Con frecuencia, los clientes abonan un combo que incluye una bebida genérica en caja, pero retiran de las heladeras una variedad o sabor diferente de igual valor. El sistema procesa la transacción de forma correcta a nivel monetario, pero altera la trazabilidad analítica de las existencias, lo que obliga al personal a realizar reajustes manuales posteriores mediante tablets y escáneres al reponer desde el depósito.

- **Mermas No Facturadas en Cafetería:** En el sector de cafetería, la interacción con clientes asiduos o de alta frecuencia genera dinámicas donde se preparan productos cuyos tickets no se emiten de manera inmediata, o se generan variaciones en el volumen de mermas (por ejemplo, picos de producción de café estimados visualmente por turno). Esto provoca que al final de la jornada existan descuadres o sobrantes de dinero en caja que no reflejan con exactitud el flujo real de insumos consumidos.

2.9 Logística ante Picos de Flujo y Comportamiento de Clientes

El análisis cualitativo del comportamiento de los usuarios permitió tipificar dos escenarios críticos de saturación y ocupación del espacio:

- **Colapso Operativo por Contingentes:** La encargada señaló que el mayor desafío logístico ocurre durante fines de semana largos o temporadas de viajes de estudio y turismo, momentos en los que la tienda recibe colectivos con más de 40 pasajeros en simultáneo. Este flujo masivo e imprevisto satura el salón de ventas. Al contar con una dotación de personal calculada para la operación estándar, se producen cuellos de botella críticos: las colas en caja se extienden y se generan demoras significativas

en la entrega de pedidos ya abonados en las áreas de cafetería y cocina, elevando la disconformidad del cliente.

- **Ocupación Pasiva del Salón:** Se detectó la presencia frecuente de clientes que utilizan el establecimiento como espacio de conectividad y oficina remota (viajantes, trabajadores de la zona). Si bien consumen un desayuno inicial básico, permanecen ocupando mesas y recursos de la tienda (conectividad, espacio físico) por varias horas sin generar transacciones adicionales. El personal carece de herramientas automatizadas para medir estos tiempos de permanencia y su impacto en la rotación de mesas disponibles para los clientes de paso.

2.10 Infraestructura de Captura y Distribución de Cámaras

Uno de los principales objetivos del análisis de campo fue auditar el Circuito Cerrado de Televisión (CCTV) existente para evaluar la cobertura espacial y la viabilidad del procesamiento de video. La tienda dispone de un despliegue de cámaras distribuidas estratégicamente según criterios de seguridad física tradicionales:

- **Salón de Ventas (Full):** Cuenta con cuatro cámaras enfocadas en las áreas de mayor tránsito, góndolas de exhibición y la línea de cajas. El análisis visual permitió registrar fotográficamente los ángulos de visión para proyectar la oclusión de objetos y el solapamiento de trayectorias de los clientes.
- **Área de Elaboración (Cocina):** Está cubierta por dos dispositivos orientados al control de la preparación de pedidos.
- **Zona de Proveedores:** Dispone de una cámara ubicada en el sector exterior de descarga de mercadería para la verificación física de remitos cerrados.
- **Puntos Ciegos:** Se constató la ausencia total de dispositivos de captura dentro del depósito interno de stock , delegando el control de esa zona exclusivamente a registros logísticos digitales.

2.11 Viabilidad Técnica de Conexión y Extracción de Footage

La planificación del procesamiento de video requirió una evaluación técnica junto al administrador de los sistemas de seguridad del establecimiento. Para resolver el desafío del procesamiento en tiempo real sin interferir con la red operativa local de la estación, se analizaron dos enfoques de conectividad:

1. **Conexión Remota en Tiempo Real:** Se evaluó la implementación de una Red

Privada Virtual (VPN) de acceso gratuito para establecer un túnel seguro hacia la infraestructura local, permitiendo la retransmisión de los flujos de video mediante el protocolo RTSP (*Real-Time Streaming Protocol*) hacia un servidor externo de procesamiento.

2. **Extracción de Footage para Entrenamiento de Modelos:** Con el propósito de construir el dataset de validación y entrenamiento, durante la segunda visita al establecimiento (finales de julio de 2026) se ejecutó un procedimiento manual de exportación de las grabaciones correspondientes a una semana completa de las cuatro cámaras seleccionadas, utilizando discos de estado sólido (SSD) externos. Este proceso requirió el acceso directo al Grabador de Video de Red (NVR), la validación mediante patrones de seguridad físicos del dispositivo, la conexión de unidades de almacenamiento masivo externo y la transcodificación de los formatos nativos del firmware a contenedores de video estándar para su posterior tratamiento computacional.

3. **Relevamiento con el proveedor del servicio de videovigilancia:** La administración del sistema CCTV del establecimiento se encuentra tercerizada en un técnico externo a la estación de servicio. En las comunicaciones mantenidas con dicho proveedor se constató que el grabador pertenece a la línea Hikvision y expone sus flujos de video bajo el esquema rtsp://<usuario>:<contraseña>@<dirección>:<puerto>/Streaming/Channels/<id>/. El identificador combina el número de canal y el tipo de flujo: por ejemplo, 101 corresponde al flujo principal de la cámara 1 y 102 a su flujo secundario de menor resolución. Asimismo, el proveedor planteó dos alternativas para acceder a los flujos desde fuera del establecimiento. La primera consiste en publicar el grabador hacia internet mediante un servicio de DNS dinámico (No-IP o DuckDNS) junto con la apertura de puertos en el router. La segunda consiste en emplear una red privada virtual de tipo malla (Tailscale), que no requiere modificar la configuración del router. Ambas alternativas se analizan en la sección 4.7.

3. Opciones Similares en el Mercado

3.1 Introducción

Durante los últimos años, el crecimiento de la Inteligencia Artificial, la visión por computadora y el Internet de las Cosas (IoT) ha impulsado el desarrollo de numerosas soluciones orientadas al monitoreo inteligente de entornos comerciales. Actualmente, existe

una amplia variedad de plataformas que utilizan cámaras, sensores y algoritmos de análisis de imágenes para automatizar tareas relacionadas con la seguridad, el control operativo y la obtención de información de negocio.

El incremento en la capacidad de procesamiento de imágenes, junto con el desarrollo de modelos de aprendizaje profundo (Deep Learning), ha permitido que muchas empresas incorporen sistemas capaces de detectar personas, vehículos, objetos y distintos eventos de interés en tiempo real. Estas tecnologías han encontrado aplicaciones en sectores como la seguridad electrónica, el comercio minorista, la logística, la industria y las ciudades inteligentes.

No obstante, las soluciones disponibles presentan enfoques muy diferentes según el problema que buscan resolver. Mientras algunas plataformas priorizan la seguridad patrimonial y la prevención de incidentes, otras se orientan al análisis del comportamiento de los clientes o a la gestión del negocio mediante indicadores comerciales.

Por este motivo, resulta necesario analizar las principales alternativas disponibles en el mercado, identificar sus características, evaluar sus ventajas y limitaciones y comprender qué necesidades permanecen parcialmente cubiertas.

3.2 Soluciones orientadas a la videovigilancia inteligente

El mercado de la videovigilancia ha experimentado una evolución significativa con la incorporación de algoritmos de Inteligencia Artificial. Fabricantes de cámaras y desarrolladores de software han comenzado a integrar funciones de análisis automático de imágenes que permiten detectar distintos eventos sin necesidad de supervisión humana constante.

Las funcionalidades más comunes incluyen:

- Detección de movimiento.
- Conteo de personas.
- Reconocimiento automático de matrículas vehiculares (LPR).
- Detección de intrusiones.
- Cruce de líneas virtuales.
- Reconocimiento facial.
- Identificación de objetos abandonados.
- Generación de alertas automáticas ante eventos de seguridad.

Estas herramientas se encuentran principalmente orientadas a mejorar la vigilancia

física de instalaciones comerciales, industriales y urbanas, reduciendo el tiempo necesario para revisar grabaciones y facilitando la actuación del personal de seguridad.

Si bien muchas de estas plataformas utilizan técnicas avanzadas de visión por computadora, el objetivo principal continúa siendo la protección patrimonial y la prevención de incidentes, dejando en un segundo plano el análisis operativo del negocio.

Entre los fabricantes de cámaras, Hikvision ofrece para el sector comercial modelos con algoritmos de aprendizaje profundo para el conteo de personas, la detección de colas y la generación de mapas de calor. Estas funciones requieren cámaras específicas de la marca, como modelos de doble lente con visión estereoscópica o cámaras de tipo ojo de pez, gestionadas desde su plataforma HikCentral (Hikvision, s. f.).

En el campo específico de la prevención de pérdidas, Veesion propone un software que analiza las imágenes de las cámaras ya instaladas en el comercio para reconocer gestos asociados al hurto, como ocultar un producto en la ropa o en un bolso. Ante un gesto sospechoso, envía al personal una notificación con el fragmento de video correspondiente. Según el fabricante, el sistema no utiliza reconocimiento facial, ya que analiza únicamente movimientos corporales (Veesion, s. f.). Sin embargo, su función se limita a la detección de hurtos y no ofrece métricas operativas del local.

3.3 Plataformas de análisis para el sector retail

Además de las soluciones tradicionales de videovigilancia, durante los últimos años surgieron plataformas especializadas en analítica para comercios minoristas.

Estos sistemas permiten obtener indicadores relacionados con el comportamiento de los clientes, entre ellos:

- Conteo de visitantes.
- Tiempo de permanencia dentro del establecimiento.
- Mapas de calor.
- Análisis de recorridos.
- Medición de tiempos de espera.
- Conversión entre visitantes y compradores.
- Evaluación del rendimiento de sectores comerciales.

La información generada permite a los responsables del negocio comprender cómo interactúan los clientes con el espacio físico y tomar decisiones relacionadas con la distribución de productos, la asignación de personal y la optimización de la experiencia de

compra.

Entre las plataformas más difundidas se encuentra RetailNext, que comercializa un sensor propio de techo (Aurora) para el conteo anónimo de visitantes, el análisis de comportamiento y la exclusión del personal en las métricas. Se ofrece bajo un modelo de suscripción mensual por sensor (RetailNext, s. f.). De forma similar, ShopperTrak, de Sensormatic Solutions, utiliza contadores cenitales en los accesos y en el interior de las tiendas, complementados con tecnologías de localización. Sus indicadores de tráfico se orientan a la planificación del personal y a la comparación con el desempeño del mercado (Sensormatic Solutions, s. f.).

Otras soluciones se enfocan en procesos puntuales del comercio. Trax procesa imágenes de las góndolas, obtenidas mediante aplicaciones móviles, cámaras de estantería o robots, para detectar faltantes y verificar el cumplimiento del planograma (Trax, s. f.). Everseen, por su parte, analiza con visión por computadora las transacciones en el punto de venta para detectar productos no escaneados y otras irregularidades en las cajas, tanto atendidas como de autoservicio (Everseen, s. f.).

Sin embargo, una gran parte de estas soluciones se encuentra orientada a grandes cadenas comerciales y supermercados, donde la inversión en infraestructura tecnológica forma parte de la estrategia corporativa. En muchos casos requieren la instalación de cámaras cenitales especializadas, sensores tridimensionales, dispositivos LiDAR o equipamiento propietario diseñado específicamente para tareas analíticas.

Como consecuencia, su implementación suele representar un costo elevado, dificultando su adopción en comercios de menor escala o franquicias que ya disponen de un sistema de cámaras destinado exclusivamente a tareas de seguridad.

3.4 Limitaciones de las soluciones existentes

A partir del análisis del mercado puede observarse que las soluciones comerciales disponibles presentan diversas limitaciones cuando se pretende reutilizar la infraestructura existente para obtener información operativa del negocio.

Una de las principales características del mercado actual es que la mayoría de los sistemas de videovigilancia con Inteligencia Artificial se encuentran fuertemente orientados hacia la seguridad física y patrimonial. Sus funcionalidades priorizan la detección de intrusiones, el reconocimiento de matrículas vehiculares, la identificación de personas o el análisis forense de incidentes, dejando en segundo plano la generación de métricas útiles para la gestión cotidiana del comercio.

Por otra parte, las plataformas especializadas en Business Intelligence para el sector retail suelen requerir infraestructura adicional distinta de las cámaras convencionales. Es frecuente que estos sistemas utilicen sensores propietarios, cámaras cenitales estereoscópicas o dispositivos específicamente diseñados para tareas de analítica comercial, lo que incrementa considerablemente los costos de implementación y mantenimiento.

Esta situación limita el acceso de pequeños y medianos comercios a tecnologías avanzadas de análisis visual, aun cuando ya disponen de una infraestructura de videovigilancia instalada y operativa.

Asimismo, muchas de las soluciones existentes ofrecen métricas estandarizadas que no siempre responden a las necesidades particulares de cada organización. La posibilidad de adaptar los indicadores a los procesos específicos del negocio suele ser reducida o requiere desarrollos personalizados que incrementan aún más el costo de implementación.

3.5 Oportunidad de innovación

A partir del análisis realizado, se identifica una oportunidad para desarrollar soluciones que aprovechen la infraestructura de videovigilancia ya instalada y la transformen en una herramienta de apoyo para la gestión operativa del negocio.

En lugar de incorporar nuevos dispositivos o reemplazar el sistema de cámaras existente, resulta posible reutilizar los flujos de video generados por las cámaras IP para obtener información de valor mediante técnicas modernas de visión por computadora e Inteligencia Artificial.

Este enfoque propone un cambio de paradigma respecto del uso tradicional de la videovigilancia. Mientras que la mayoría de las plataformas comerciales continúan enfocándose principalmente en la seguridad, la propuesta consiste en utilizar las mismas imágenes para asistir al personal en tareas operativas, generar indicadores de negocio y proporcionar información que facilite la toma de decisiones.

En el contexto de las tiendas FULL de YPF, este enfoque permite analizar variables como el flujo de clientes, la interacción con las góndolas, la disponibilidad visual de productos, el tiempo de permanencia en determinadas áreas y la generación de alertas sobre situaciones relevantes, aprovechando la infraestructura tecnológica ya disponible y reduciendo la necesidad de realizar inversiones adicionales en hardware especializado.

3.6 Comparación entre las soluciones existentes y la propuesta del proyecto

En función del análisis realizado, puede observarse que las soluciones disponibles en el mercado presentan diferencias importantes respecto de la propuesta desarrollada en este proyecto.

La Tabla 3 sintetiza las características de las soluciones analizadas, considerando los criterios relevantes para el contexto de una tienda de conveniencia que ya dispone de un sistema de cámaras.

Tabla 3

Comparación de soluciones existentes en el mercado

Solución	**Enfoque principal**	**Infraestructura requerida**	**Métricas de flujo y mapas de calor**	**Detección de posibles hurtos**	**Reconocimiento de productos**	**Reconocimiento facial**
Hikvision (cámaras con IA)	Videovigilancia y analítica básica	Cámaras específicas de la marca	Sí	No es su foco	No	Disponible en otras líneas de la marca
Veesion	Prevención de hurtos	Cámaras existentes	No	Sí, por gestos	No	No
RetailNext	Analítica de tráfico y comportamiento	Sensor propio de techo	Sí	Módulo adicional	No	No
ShopperTrak (Sensormatic)	Conteo de tráfico y planificación de personal	Contadores cenitales propios	Sí (conteo)	No	No	No
Trax	Control de góndola y planograma	Celulares, cámaras de estante o robots	No	No	Sí, en góndola	No
Everseen	Pérdidas en caja	Cámaras sobre el punto de venta	No	Sí, en caja	Sí, en la transacción	No

OptiFull	Asistencia operativa integral	Cámaras existentes y un nodo de captura de bajo costo	Sí	Sí, por trayectoria	Sí, en caja	No

Fuente: elaboración propia a partir de la información publicada por cada fabricante.

Las plataformas tradicionales de videovigilancia se destacan por sus capacidades de monitoreo y seguridad, pero ofrecen escaso soporte para el análisis operativo del negocio. Por su parte, las soluciones comerciales orientadas al sector retail proporcionan métricas de comportamiento de clientes y análisis comercial, aunque generalmente requieren infraestructura especializada y elevados costos de implementación.

La propuesta de **OptiFull** busca posicionarse como una alternativa que combine las ventajas de ambos enfoques. Mediante el uso de modelos de visión por computadora y aprendizaje profundo, el sistema pretende reutilizar las cámaras IP existentes para generar indicadores operativos y comerciales sin necesidad de modificar significativamente la infraestructura instalada.

De esta manera, el proyecto apunta a cubrir un espacio poco explorado por las soluciones tradicionales: transformar un sistema concebido originalmente para tareas de seguridad en una herramienta de apoyo para la gestión operativa, el monitoreo inteligente y la obtención de información estratégica adaptada a las necesidades específicas de una tienda FULL.

4. Tecnologías Investigadas

Con el objetivo de desarrollar una solución tecnológica capaz de integrar modelos de visión por computadora para la detección de objetos, el rastreo de flujos y la generación de información analítica visual en tiempo real, se realizó un análisis exhaustivo de distintas herramientas disponibles en el mercado. En este apartado se presentan las tecnologías evaluadas para cada componente del sistema, detallando sus características fundamentales, ventajas, limitaciones y la justificación técnica de su análisis dentro del marco del proyecto.

Es crucial destacar que, en cumplimiento con la naturaleza de este Marco Teórico, las herramientas aquí descritas constituyen el espectro de tecnologías investigadas y viables, sentando las bases conceptuales para la posterior arquitectura del sistema.

4.1 Entornos de Desarrollo

4.1.1 Visual Studio Code

Para la construcción, depuración y mantenimiento del código fuente del proyecto, se evaluaron diversos entornos de desarrollo integrado (IDE) y editores de texto avanzados. Se priorizaron criterios de rendimiento, modularidad, soporte multiplataforma y compatibilidad con sistemas de control de versiones (Visual Studio Code, s. f.).

Visual Studio Code (VS Code) se destaca como una de las opciones más robustas debido a su arquitectura ligera basada en componentes y su capacidad de transformarse en un entorno de desarrollo completo mediante un ecosistema de extensiones especializadas. Su soporte nativo para la sintaxis de múltiples lenguajes y su terminal integrada facilitan la centralización de las tareas de desarrollo en un único espacio de trabajo.

- **Ventajas:**
    - **Eficiencia en el Consumo de Recursos:** Menor uso de memoria RAM y tiempo de CPU en comparación con entornos de desarrollo integrados tradicionales de gran envergadura.
    - **Ecosistema Extensible:** Disponibilidad de extensiones críticas para el análisis estático de código (linters), formateadores y herramientas de depuración avanzadas.
    - **Integración Nativa con Git:** Facilita la gestión de ramas, confirmaciones (*commits*) y resolución de conflictos directamente desde la interfaz gráfica.
    - **Polivalencia Tecnológica:** Excelente compatibilidad y resaltado de sintaxis para Python, JavaScript, entornos web y de ejecución móvil.
- **Desventajas:**
    - **Dependencia de Configuración:** Al ser un editor base, requiere de una inversión inicial de tiempo para configurar manualmente el entorno de desarrollo y depuración requerido.
    - **Sobrecarga por Extensiones:** La instalación desmedida de complementos de terceros puede degradar el rendimiento y la estabilidad del entorno.

4.2 Desarrollo y Pruebas en Entornos Móviles

4.2.1 Expo Go

En el análisis de desarrollo de aplicaciones basadas en arquitecturas híbridas (como React Native), uno de los desafíos principales radica en la velocidad del ciclo de compilación, despliegue y pruebas en dispositivos reales, tanto para sistemas operativos Android como iOS (Expo, s. f.).

Expo Go es un entorno de ejecución (*sandbox*) y una plataforma de herramientas que permite a los desarrolladores abrir y probar aplicaciones móviles en dispositivos físicos a través de una red local o internet, eliminando la necesidad de pasar por los flujos de compilación nativos de Android Studio o Xcode durante las fases tempranas y medias del desarrollo.

- **Ventajas:**
    - **Actualización Inmediata (*Hot Reloading*):** Refleja las modificaciones del código fuente en el dispositivo de prueba de forma casi instantánea al guardar el archivo.
    - **Abstracción del Entorno Nativo:** Permite el desarrollo de prototipos móviles funcionales en sistemas operativos que no disponen de herramientas de compilación específicas (por ejemplo, desarrollar para iOS desde entornos que no sean macOS).
    - **Simplificación de Pruebas:** Facilita el acceso a sensores y hardware estándar del dispositivo (cámara, almacenamiento local, conectividad) mediante un conjunto de APIs unificadas.
- **Desventajas:**
    - **Restricciones de Código Nativo:** No permite la inclusión de módulos nativos personalizados escritos en Java/Kotlin o Objective-C/Swift que no estén pre-integrados en el cliente de Expo.
    - **Volumen del Paquete de Producción:** El uso de las abstracciones de Expo suele incrementar el tamaño final de los binarios de la aplicación en comparación con un desarrollo nativo puro.

4.3 Tecnologías de Visión por Computadora e Inteligencia Artificial

4.3.1 YOLOv8 (You Only Look Once - Versión 8)

La extracción de métricas analíticas a partir de transmisiones de video en tiempo real requiere modelos de aprendizaje profundo capaces de resolver la tarea de detección de objetos (*object detection*) con una latencia extremadamente baja.

YOLOv8 representa una de las evoluciones más eficientes dentro de las arquitecturas de red convolucionales de una sola etapa (*single-stage detectors*) (Redmon et al., 2016; Jocher et al., 2023). Al procesar el fotograma completo en una única pasada hacia adelante (*forward pass*), el modelo predice directamente las cajas delimitadoras (*bounding boxes*) y las probabilidades de clase, lo que lo vuelve ideal para flujos de video continuos.

- **Ventajas:**
    - **Inferencia de Alta Velocidad:** Optimizado para alcanzar altas tasas de

fotogramas por segundo (FPS) incluso en hardware con capacidades computacionales moderadas.

- **Estructura Multitarea:** Además de la detección tradicional, ofrece soporte nativo para segmentación de instancias y seguimiento de objetos (*tracking*).
- **Flexibilidad de Escala:** Dispone de diferentes tamaños de arquitectura (Nano, Small, Medium, Large, XLarge), permitiendo balancear la precisión matemática frente al costo computacional según el entorno de despliegue.

- **Desventajas:**
  - **Requerimientos de Hardware:** Para procesos de inferencia crítica o entrenamiento, depende fuertemente de unidades de procesamiento gráfico (GPU) con soporte para aceleración por hardware (Cuda).
  - **Sensibilidad al Contexto:** Puede presentar dificultades en la detección de objetos a escalas muy reducidas o bajo condiciones extremas de oclusión y baja iluminación.
  - **Licenciamiento restrictivo:** la implementación oficial de YOLOv8 (biblioteca Ultralytics) se distribuye bajo la licencia AGPL-3.0 (Ultralytics, s. f.). Esta licencia obliga a publicar el código fuente de cualquier software que la incorpore y se ofrezca como servicio a través de una red. Para un uso comercial cerrado, es necesario adquirir una licencia empresarial del fabricante.

4.3.2 Gemma AI (Google Open Models)

Dentro del espectro de la visión artificial avanzada y los modelos fundacionales, la investigación actual tiende a la incorporación de modelos abiertos y eficientes para tareas complementarias de análisis de contexto, clasificación avanzada de escenas o procesamiento multimodal en el *edge computing* (*computación en el borde*).

Gemma es una familia de modelos abiertos desarrollados por Google, construidos a partir de la misma investigación y tecnología utilizadas para la creación de los modelos Gemini (Gemma Team, 2024). En el ámbito de la visión y la IA aplicada, sus variantes ligeras están diseñadas para operar de manera eficiente en hardware local o servidores intermedios, proporcionando capacidades de razonamiento conceptual sobre las detecciones o indexación semántica de los eventos capturados por las cámaras.

- **Ventajas:**
  - **Naturaleza Abierta y Desplegable:** Al ser modelos de pesos abiertos (*open-weights*), permiten un despliegue local completo, garantizando la privacidad de los datos y eliminando la dependencia de llamadas a APIs comerciales externas.

- **Alta Eficiencia Computacional:** Diseñado específicamente para ofrecer un rendimiento académico e ingenieril óptimo en arquitecturas con restricciones de hardware.
- **Facilidad de Ajuste Fino (*Fine-Tuning*):** Permite la especialización del modelo en tareas muy puntuales del dominio del proyecto mediante técnicas de bajo costo computacional (como LoRA) (Hu et al., 2021).

- **Desventajas:**
  - **Ecosistema en Desarrollo:** Al ser una tecnología más reciente en comparación con otros estándares de la industria, la comunidad y las herramientas de integración periféricas están en proceso de consolidación.
  - **Limitación de Escala:** Las versiones optimizadas para ejecución local poseen una capacidad de representación menor ante escenarios hiper-complejos en comparación con modelos comerciales masivos basados en la nube.

4.3.3 Roboflow

El rendimiento de cualquier modelo de visión por computadora está directamente condicionado por la calidad, estructura y volumen del conjunto de datos (*dataset*) utilizado durante su entrenamiento o validación. La preparación de estos datos suele ser una de las etapas más costosas del ciclo de vida del proyecto (Roboflow, s. f.).

Roboflow es una plataforma de software como servicio (SaaS) diseñada para centralizar la gestión de imágenes orientadas a visión artificial. Automatiza las tareas de anotación, control de versiones de los conjuntos de datos, aplicación de técnicas de *Data Augmentation* (*aumentación de datos*) y conversión de formatos de anotación entre diferentes especificaciones de la industria.

- **Ventajas:**
  - **Normalización y Conversión Automática:** Capacidad de exportar el dataset directamente al formato requerido por YOLOv8 (coordenadas relativas de texto) o arquitecturas alternativas sin necesidad de escribir scripts de conversión manuales.
  - **Técnicas de Aumentación de Datos:** Permite generar variaciones artificiales de las imágenes (rotaciones, cambios de brillo, ruido) para mejorar la capacidad de generalización del modelo entrenado.
  - **Gestión de Versiones:** Facilita el aislamiento de diferentes iteraciones del dataset para realizar pruebas comparativas rigurosas.
- **Desventajas:**
  - **Dependencia del Proveedor:** Al ser una herramienta basada en la nube, el

acceso a los datos y las capacidades de procesamiento están sujetas a la conectividad a internet y a las políticas de servicio de la plataforma.

- **Restricciones en Planes Gratuitos:** Limitaciones en el volumen de almacenamiento de imágenes o en la aplicación de transformaciones complejas bajo licencias de uso académico.

4.3.4 Google Gemini API

Siguiendo con el análisis de las tecnologías alternativas investigadas, otra de las opciones evaluadas para complementar las capacidades del sistema de visión por computadora es la **API de Google Gemini**. Esta herramienta se contempló como una posible solución de respaldo para las tareas de análisis e identificación de objetos en imágenes y videos. A diferencia de los modelos especializados exclusivamente en detección (como las arquitecturas tradicionales de deep learning), Gemini aporta la capacidad de interpretar el contenido visual mediante razonamiento multimodal, proporcionando descripciones semánticas, clasificación de elementos complejos y una contextualización profunda de las escenas capturadas.

La eventual integración de esta herramienta se analizó mediante el consumo de su API oficial utilizando una clave de acceso (API Key). El flujo teórico consistiría en enviar imágenes o fragmentos de video capturados por el sistema para recibir respuestas estructuradas que enriquezcan los datos obtenidos por los algoritmos principales. En el marco de la investigación, esta estrategia se consideró de gran utilidad para validar resultados dudosos, identificar objetos de difícil clasificación y generar descripciones del entorno analizado.

- **Ventajas:**
  - **Capacidad Multimodal:** Analiza simultáneamente imágenes y texto, permitiendo identificar objetos, interpretar escenas y responder consultas sobre el contenido visual.
  - **Integración Sencilla:** La disponibilidad de una API REST facilita su incorporación dentro de aplicaciones desarrolladas en distintos lenguajes de programación.
  - **Actualización Continua:** Google mantiene y mejora periódicamente el modelo sin requerir modificaciones en la infraestructura del proyecto.
  - **Razonamiento Contextual:** Puede inferir relaciones entre objetos y describir situaciones que van más allá de una simple clasificación.
- **Desventajas:**
  - **Dependencia de Internet:** Requiere conexión permanente para consumir la

API y procesar las solicitudes.

- **Límite de Consumo:** Su utilización está sujeta a solicitudes diarias, teniendo 20 como límite (Google, s. f.).
- **Dependencia del Proveedor:** El funcionamiento del sistema queda condicionado a la disponibilidad y políticas del servicio de Google.
- **Mayor Latencia:** Al tratarse de un servicio en la nube, el tiempo de respuesta es superior al de modelos ejecutados localmente.

4.3.5 Groq

Dentro del análisis de tecnologías para el procesamiento acelerado de inferencias, se investigó la plataforma Groq, la cual introduce un paradigma disruptivo basado en la arquitectura LPU (Language Processing Unit). A diferencia de las unidades de procesamiento gráfico (GPU) tradicionales que utilizan arquitecturas de procesamiento paralelo masivo, la LPU de Groq emplea un motor de inferencia de flujo tensorial diseñado para eliminar los cuellos de botella de la memoria, permitiendo un procesamiento secuencial determinista de alta velocidad para modelos de lenguaje y tareas de razonamiento lógico (Groq, s. f.).

- **Ventajas:** Su principal fortaleza radica en la baja latencia y el alto rendimiento (throughput) de tokens por segundo, lo que garantiza una respuesta casi instantánea en la ejecución de modelos de lenguaje de gran escala (LLM). Este determinismo en el tiempo de computación facilita la integración en sistemas que requieren sincronización precisa de datos de texto o metadatos procesados.
- **Desventajas:** En el contexto específico de la visión por computadora, la tecnología LPU presenta limitaciones significativas, ya que su arquitectura está optimizada para datos secuenciales y no para el procesamiento matricial denso requerido por los flujos de video o imágenes. Asimismo, su catálogo de modelos multimodales de visión es más acotado y cambia con frecuencia, ya que los modelos se dan de baja periódicamente.

4.3.6 Claude API (Anthropic)

Dentro del abanico de modelos fundacionales multimodales evaluados para el análisis semántico y la interpretación de eventos complejos, se investigó la integración de la API comercial de Claude (desarrollada por Anthropic). Esta alternativa se planteó como un motor de razonamiento avanzado capaz de recibir secuencias de metadatos o fotogramas clave enviados desde el sistema de seguimiento local para procesar lógica temporal, clasificar comportamientos de las personas en el establecimiento e inferir conductas

sospechosas (como el desvío hacia la salida sin previo paso por la zona de cajas) (Anthropic, s. f.).

El modelo conceptual de implementación se basa en el consumo de su API paga mediante claves de autenticación (*API Keys*). A través de esta conexión, el pipeline de visión por computadora envía resúmenes estructurados o datos visuales para que Claude ejecute un análisis interpretativo guiado por prompts diseñados a medida, devolviendo respuestas estructuradas en formatos estándar (como JSON) para su consumo inmediato por parte de la lógica de negocio.

Ventajas:

- **Razonamiento Lógico-Temporal Superior:** Presenta un rendimiento excepcional en la comprensión de secuencias de eventos interconectados y en el cumplimiento estricto de reglas de negocio complejas expresadas en lenguaje natural.
- **Respuestas Estructuradas Confiables:** Demuestra una baja tasa de alucinación y una alta precisión al generar salidas JSON con esquemas definidos, simplificando la integración directa con el backend del sistema.
- **Ventana de Contexto Extensa:** Su arquitectura está optimizada para procesar volúmenes masivos de datos contextuales e historial de eventos sin perder la trazabilidad de la secuencia analizada.
- **Capacidad Multimodal de Alta Fidelidad:** Permite interpretar texto e imágenes simultáneamente, facilitando la validación visual en casos donde las métricas locales generan ambigüedad.

Desventajas:

- **Modelo de Costo por Uso (Pay-per-Use):** Al tratarse de un servicio comercial tarifado según el volumen de tokens consumidos (tanto de entrada como de salida), su escalamiento para análisis ininterrumpido a alta frecuencia puede incrementar significativamente los costos operativos.
- **Latencia de Red:** La dependencia de una arquitectura basada en la nube introduce un retardo en los tiempos de respuesta que desaconseja su uso para decisiones de seguridad en tiempo real estricto (sub-segundo).
- **Dependencia de Conectividad Externa:** El sistema requiere acceso ininterrumpido a internet y queda sujeto a la cuota, disponibilidad operativa y políticas de servicio de Anthropic.

4.3.7 Algoritmos de Seguimiento Multiobjeto: ByteTrack y BoT-SORT

Un detector de objetos analiza cada fotograma de manera independiente, por lo que no sabe si la persona detectada en un cuadro es la misma que la del cuadro anterior. Para construir trayectorias es necesario un algoritmo de seguimiento multiobjeto (*multi-object tracking*), que asocia las detecciones entre fotogramas consecutivos y asigna a cada objeto un identificador (*track ID*). En el marco de la investigación se analizaron dos de los algoritmos más difundidos, ambos integrados en la biblioteca Ultralytics y configurables mediante archivos YAML.

ByteTrack se basa en el principio de que las detecciones de baja confianza también contienen información útil. En lugar de descartarlas, realiza la asociación en dos etapas: primero vincula las detecciones de alta confianza con las trayectorias existentes y luego intenta recuperar, con las de baja confianza, los objetos parcialmente ocultos. Para predecir la posición de cada objeto utiliza un filtro de Kalman, y para asociar las detecciones emplea la superposición entre cajas (IoU), sin recurrir a modelos de apariencia (Zhang et al., 2022).

BoT-SORT extiende ese esquema con dos mecanismos adicionales: la compensación del movimiento de la cámara y la incorporación de descriptores de apariencia obtenidos mediante una red de reidentificación. De este modo, el parecido visual también interviene en la asociación (Aharon et al., 2022).

Ventajas:

- **Bajo costo computacional (ByteTrack):** al no ejecutar una red neuronal adicional, agrega una carga mínima al proceso de detección.
- **Robustez ante oclusiones parciales:** el aprovechamiento de las detecciones de baja confianza reduce la pérdida de trayectorias cuando una persona queda parcialmente tapada.
- **Mayor estabilidad de identidades (BoT-SORT):** el uso de la apariencia disminuye los intercambios de identificador entre personas que se cruzan.

Desventajas:

- **Identificadores de corto plazo:** ambos algoritmos pierden la identidad cuando el objeto desaparece durante varios fotogramas, y le asignan uno nuevo al reaparecer.
- **Sin continuidad entre cámaras:** ninguno de los dos vincula a una misma persona vista por cámaras distintas.
- **Costo adicional (BoT-SORT):** la extracción de descriptores de apariencia incrementa el tiempo de procesamiento, lo que resulta relevante en equipos sin GPU.

4.3.8 Reidentificación de Personas (ReID)

La reidentificación de personas (*person re-identification*) es la tarea de reconocer a un mismo individuo en distintos momentos o en distintas cámaras, cuando el seguimiento continuo se interrumpe (Ye et al., 2022). A diferencia del reconocimiento facial, la reidentificación puede resolverse a partir de la apariencia general de la persona (vestimenta, complexión, accesorios), sin recurrir a rasgos biométricos. Se analizaron tres enfoques:

1. **Descriptores de color.** Consisten en calcular un histograma de color de una región de la persona, por ejemplo el torso, en el espacio HSV, que separa el tono de la luminosidad y es por lo tanto menos sensible a los cambios de iluminación. Dos histogramas se comparan mediante una medida de similitud entre distribuciones, como la distancia de Bhattacharyya, disponible en OpenCV (Swain & Ballard, 1991; Bhattacharyya, 1943).
2. **Redes neuronales de reidentificación.** Generan un vector numérico (*embedding*) que representa la apariencia de la persona, y comparan esos vectores entre sí. Requieren modelos entrenados específicamente para esta tarea.
3. **Modelos multimodales en la nube.** Reciben la imagen recortada de la persona y devuelven una descripción estructurada de sus atributos visibles (por ejemplo, color de la prenda superior e inferior, complexión y accesorios), que luego puede compararse con la de otras detecciones.

Ventajas:

- **Privacidad:** los tres enfoques permiten mantener la identidad de una persona sin utilizar datos biométricos.
- **Costo nulo y respuesta inmediata (descriptores de color):** se calculan localmente en milisegundos.
- **Interpretabilidad (modelos multimodales):** los atributos devueltos son legibles por una persona y no requieren entrenamiento previo.

Desventajas:

- **Ambigüedad:** dos personas con ropa de colores similares pueden confundirse, especialmente con los descriptores de color.
- **Requerimientos de entrenamiento y GPU (redes de ReID):** su desempeño depende de que el modelo haya sido entrenado en condiciones similares a las del entorno real.
- **Costo, latencia y dependencia del proveedor (modelos multimodales):** cada consulta implica una llamada a un servicio externo con cuota limitada.

4.3.9 Enfoques para el Reconocimiento de Productos

El reconocimiento automático de productos de consumo masivo presenta una dificultad particular: los catálogos contienen cientos de artículos, y muchos de ellos solo se diferencian por detalles del envase, como el color de la etiqueta, el sabor o el tamaño. Se analizaron dos enfoques.

Detector entrenado por producto (SKU). Consiste en ajustar un modelo de detección, como YOLOv8, con imágenes etiquetadas de cada producto del catálogo, preparadas por ejemplo con Roboflow. Cada artículo constituye una clase del modelo.

Modelo multimodal sin entrenamiento previo (*zero-shot*). Consiste en enviar la imagen del producto a un modelo multimodal de propósito general, que lee el envase y devuelve sus datos (marca, variante y tamaño) en un formato estructurado. Esos datos se buscan luego en el catálogo de la tienda.

Ventajas:

- **Velocidad y funcionamiento local (detector entrenado):** una vez entrenado, se ejecuta sin conexión a internet y sin costo por consulta.
- **Sin entrenamiento ni fotografías por producto (*zero-shot*):** incorporar un artículo nuevo solo requiere darlo de alta en el catálogo.
- **Distinción por texto (*zero-shot*):** al leer la etiqueta, puede diferenciar variantes visualmente parecidas, como dos sabores de una misma marca.

Desventajas:

- **Costo de preparación y mantenimiento (detector entrenado):** requiere un conjunto de imágenes etiquetadas por cada SKU y un nuevo entrenamiento cada vez que se agrega un producto o cambia un envase.
- **Confusión entre variantes similares (detector entrenado):** su precisión disminuye entre productos de envase casi idéntico.
- **Costo por uso y latencia (*zero-shot*):** cada reconocimiento implica una llamada a un servicio en la nube, por lo que conviene limitar la cantidad de consultas.

4.3.10 Coincidencia Difusa de Texto

Cuando un dato leído automáticamente debe buscarse en un catálogo, rara vez coincide de forma exacta con el registro almacenado: puede contener errores de lectura, abreviaturas o diferencias de escritura. Para resolverlo se emplean técnicas de coincidencia difusa (*fuzzy matching*), que miden cuán parecidas son dos cadenas de texto. La medida más

difundida es la distancia de Levenshtein, que cuenta la cantidad mínima de inserciones, eliminaciones o sustituciones de caracteres necesarias para transformar una cadena en otra (Levenshtein, 1966).

Entre las bibliotecas disponibles en Python se analizó **RapidFuzz** (Bachmann, s. f.), una implementación de código abierto escrita en C++ que ofrece la distancia de Levenshtein y otras medidas de similitud derivadas.

Ventajas:

- **Tolerancia a errores:** permite encontrar el producto correcto aunque la lectura contenga errores menores.
- **Rendimiento:** su implementación en C++ permite comparar un texto contra un catálogo completo en milisegundos.
- **Licencia permisiva:** se distribuye bajo licencia MIT.

Desventajas:

- **Sesgo en palabras cortas:** las medidas expresadas en porcentaje penalizan en exceso las diferencias en palabras cortas, por lo que suele ser necesario definir criterios propios según la longitud.
- **Ausencia de comprensión semántica:** compara caracteres, no significados, por lo que no reconoce sinónimos ni equivalencias de unidades (por ejemplo, “500 ml” y “0,5 L”).

4.4 Herramientas de Asistencia al Desarrollo y Documentación

4.4.1 Modelos de Lenguaje Grandes (LLMs): GPT y Claude

Durante los procesos de investigación tecnológica, diseño arquitectónico, generación de scripts auxiliares y redacción de documentación técnica, se analizaron los Modelos de Lenguaje Grandes (LLMs) comerciales como herramientas de optimización del flujo de trabajo de ingeniería.

Modelos como GPT (OpenAI) y Claude (Anthropic) actúan de manera complementaria en el entorno de desarrollo. Mientras que las arquitecturas GPT ofrecen respuestas ágiles enfocadas en la sintaxis de código y la resolución de errores puntuales de compilación, los modelos de la familia Claude destacan por su alta capacidad de razonamiento lógico, análisis de arquitecturas complejas de software y procesamiento de extensos documentos de especificaciones técnicas.

- **Ventajas:**

- **Reducción del Tiempo de Búsqueda:** Agilizan la localización de errores sintácticos o la comprensión de firmas de métodos en librerías con documentación fragmentada.
- **Capacidad de Refactorización:** Asisten en la optimización de algoritmos rutinarios y en la traducción de lógica matemática a código estructurado.

- **Desventajas:**
  - **Riesgo de Alucinación:** Los modelos de lenguaje generativos pueden producir respuestas sintácticamente correctas pero conceptualmente erróneas o desactualizadas, requiriendo una estricta validación humana.
  - **Opacidad Comercial:** Al operar bajo modelos propietarios de caja negra basados en la nube, no es posible auditar internamente sus pesos ni asegurar su disponibilidad offline.

4.5 Análisis de tecnologías para Mapas de Calor

En el ámbito del procesamiento de video para analítica espacial, la representación visual de la acumulación geométrica de datos —comúnmente denominada mapas de calor o *heat maps*— constituye el mecanismo principal para la interpretación de flujos de tránsito. En el presente apartado se exponen y evalúan comparativamente las distintas tecnologías, librerías y enfoques algorítmicos analizados para resolver la persistencia, el suavizado espacial y la visualización de la intensidad de ocupación en un entorno web y de procesamiento en tiempo real.

4.5.1 Enfoques de Procesamiento de Matrices y Matrices de Píxeles

4.5.1.1 Manipulación Nativa con NumPy y OpenCV

Este enfoque se basa en el tratamiento directo de los fotogramas del flujo de video como matrices multidimensionales (N-dimensional arrays). La acumulación de la presencia de objetos detectados por el modelo de visión artificial se realiza mediante la adición de intensidades sobre una matriz de acumulación inicializada en cero, con las mismas dimensiones del cuadro de origen (W x H) (Harris et al., 2020; Bradski, 2000).

- **Ventajas:**
  - **Independencia de Terceros:** Al ser librerías base del pipeline de visión por computadora, no introduce sobrecarga por dependencias externas adicionales.
  - **Rendimiento Crítico:** Las operaciones vectorizadas de NumPy se ejecutan

sobre subrutinas optimizadas en C, garantizando una latencia mínima en arquitecturas de tiempo real.

- **Control de Bajo Nivel:** Permite la manipulación directa de canales de color, opacidad y máscaras bit a bit (*bitwise operations*), facilitando la exportación directa de capas con transparencia (PNG con canal alfa).

- **Desventajas:**
  - **Complejidad en Mantenimiento:** El cálculo del decaimiento temporal y el diseño del kernel de suavizado deben ser implementados y optimizados manualmente por el desarrollador.
  - **Salida Estática:** Produce imágenes bidimensionales rasterizadas fijas, lo que restringe la posibilidad de exploración dinámica por parte de un usuario final en una interfaz cliente.

4.5.1.2 Algoritmos de Suavizado con SciPy (scipy.ndimage)

Como alternativa a la generación manual de funciones de dispersión, se analizó el submódulo de procesamiento de imágenes multidimensionales de SciPy, específicamente enfocado en filtros lineales y transformaciones espaciales. La función gaussian_filter permite aplicar una convolución matemática exacta basada en una distribución gaussiana sobre la matriz de acumulación (Virtanen et al., 2020).

- **Ventajas:**
  - **Precisión Matemática:** Implementa el filtrado mediante técnicas de separación de kernels, garantizando una distribución estadística rigurosa del peso del suavizado.
  - **Parametrización Simple:** El radio de dispersión de la influencia de cada coordenada se controla de forma directa mediante la desviación estándar (σ).

- **Desventajas:**
  - **Dependencia Adicional:** Introduce una librería de gran envergadura al entorno de ejecución (*runtime*) si el resto del software solo requiere álgebra elemental.
  - **Límites Funcionales:** No resuelve el problema de la detección ni del tracking; actúa exclusivamente como un optimizador en la etapa de postprocesamiento de la matriz numérica.

4.5.2 Soluciones Integradas de Visión por Computadora

4.5.2.1 Módulo Ultralytics Solutions (Heatmap)

La suite de soluciones empaquetadas de Ultralytics proporciona abstracciones de alto nivel diseñadas para conectarse directamente con las salidas de inferencia de modelos de la familia YOLO. Integra en un único ciclo de ejecución el rastreo de objetos (*object tracking*) y la persistencia acumulativa de coordenadas sobre el fotograma (Jocher et al., 2023).

- **Ventajas:**
    - **Bajo Costo de Desarrollo:** Abstrae por completo la lógica de acumulación y renderizado, requiriendo un volumen mínimo de líneas de código.
    - **Acoplamiento Nativo:** Sincroniza de manera eficiente los identificadores de tracking (track_ids) con la lógica de persistencia del mapa de calor, evitando desfases temporales.
- **Desventajas:**
    - **Rigidez de Diseño:** Presenta severas limitaciones para personalizar los estilos visuales, comportamientos de desvanecimiento de color o la extracción aislada de la matriz de calor sin el fotograma original de fondo.
    - **Vulnerabilidad por Dependencia:** Cualquier modificación en la firma de métodos de la librería o actualizaciones del motor YOLO puede forzar reestructuraciones drásticas del código cliente.

4.5.3 Tecnologías de Visualización e Interactividad Web

4.5.3.1 Renderizado Basado en Datos con Plotly (go.Heatmap)

Plotly es una librería declarativa orientada a la construcción de gráficos interactivos de calidad científica (Plotly Technologies, s. f.). A través de su componente Heatmap (basado en la especificación web de Plotly.js), permite proyectar datos numéricos estructurados (coordenadas bidimensionales y valores de intensidad Z) directamente en un navegador web.

- **Ventajas:**
    - **Interactividad Nativa:** Proporciona de forma automática herramientas de inspección en el cliente web, tales como *zoom* dinámico, herramientas de

paneo y despliegue de información contextual (*tooltips*) al posicionar el cursor sobre zonas específicas.

- **Arquitectura Desacoplada:** Trabaja con abstracciones de datos tabulares o matrices dispersas ligeras, optimizando el ancho de banda al evitar el envío constante de imágenes estáticas pesadas a través de la red.
- **Compatibilidad Multiplataforma:** Capacidad innata de conversión a estructuras JSON utilizables tanto en dashboards estáticos como en aplicaciones basadas en micro frames web.

- **Desventajas:**
  - **Inviabilidad en Tiempo Real Continuo:** No está diseñada para procesar flujos de video ni renderizar matrices densas a frecuencias de 30 cuadros por segundo sin saturar el hilo de ejecución del cliente web.
  - **Dependencia de Datos Previos:** Requiere que el procesamiento analítico de coordenadas concluya o se agrupe en intervalos temporales específicos antes de generar la estructura de visualización.

4.5.4 Cuadro Comparativo de Tecnologías Investigadas de Mapas de Calor

Para evaluar de manera integral el espectro de alternativas analizadas, se presenta la siguiente Tabla comparativa (Tabla 4) basada en los requerimientos funcionales del dominio del problema:

Criterio de Evaluación	**NumPy + OpenCV**	**Ultralytics Solutions**	**SciPy Gaussian**	**Plotly (go.Heatmap)**
Entorno de Ejecución	Servidor / Pipeline de Video	Servidor / Pipeline de Video	Servidor / Posprocesamiento	Cliente / Interfaz de Usuario
Tipo de Salida	Imagen Rasterizada (PNG/Mat)	Video Anotado / Streaming	Matriz Numérica Suavizada	Componente Web Interactivo
Consumo de Recursos	Muy Bajo (Optimizado en C)	Medio-Alto (Inferencia + Render)	Bajo (Operaciones Matemáticas)	Medio (Renderizado en Browser)

Interactividad (Zoom/Hover)	Nula (Estática)	Nula (Estática)	Nula (Estructura de Datos)	Nativa y Completa
Nivel de Flexibilidad	Máximo (Control por Píxel)	Mínimo (Caja Negra)	Alto (Configuración de σ)	Alto (Estilos Web / Escalas)

Tabla 4: Comparación de tecnologías investigadas para mapas de calor
Fuente: elaboración propia.

4.6 Tecnologías de Bases de Datos

Para el almacenamiento de datos relacionales y la persistencia de métricas operativas generadas por el sistema, se han evaluado dos enfoques arquitectónicos de gestión de bases de datos en la nube. Esta evaluación se centra en la eficiencia de costos, la robustez de la arquitectura y la escalabilidad de la solución en un entorno de producción.

4.6.1 Supabase: Arquitectura Backend-as-a-Service (BaaS) basada en PostgreSQL

Supabase constituye una plataforma de código abierto que proporciona un ecosistema integral de herramientas sobre un motor de base de datos relacional PostgreSQL. Su arquitectura se fundamenta en un modelo de infraestructura *serverless*, lo que permite una integración ágil de servicios de autenticación, almacenamiento de objetos y persistencia de datos en una única plataforma unificada.

1. **Capacidad de Almacenamiento y Escalabilidad:** El nivel de entrada de la plataforma ofrece una cuota de 500 MB para datos estructurados y 1 GB de almacenamiento de objetos (*Object Storage*), lo cual resulta suficiente para el registro histórico de trayectorias y el almacenamiento de los mapas de calor generados (Supabase, s. f.).

2. **Disponibilidad y Costos Operativos:** La plataforma opera bajo un modelo de costos de $0 USD para proyectos de investigación. Se destaca un mecanismo de optimización de recursos que suspende la instancia ante periodos prolongados de inactividad, requiriendo un procedimiento de reactivación manual para restablecer el servicio.

4.6.2 Soluciones de Bases de Datos Gestionadas (Managed Databases)

Como alternativa para entornos que requieran una disponibilidad continua y un

control total sobre el motor de base de datos (por ejemplo, MySQL o PostgreSQL), se analizaron los servicios de bases de datos gestionadas proporcionados por proveedores como DigitalOcean.

3. **Arquitectura y Estabilidad:** Este enfoque despliega una instancia dedicada de la base de datos, garantizando que el servicio permanezca activo sin interrupciones por inactividad. La arquitectura permite desacoplar el almacenamiento de datos textuales de los binarios pesados (imágenes), sugiriendo el uso complementario de Firebase Storage (Google) para aprovechar su capa gratuita de 5 GB.

4. **Modelo de Costos:** El despliegue en un nodo de nivel de entrada representa una inversión operativa aproximada de $15 USD mensuales, proporcionando recursos computacionales garantizados para el procesamiento de consultas analíticas complejas.

4.7 Tecnologías de Conectividad Remota y Retransmisión de Video

Para el acceso a los flujos de video desde fuera del establecimiento se han evaluado distintas tecnologías de retransmisión, redes privadas y acceso remoto. Los flujos RTSP del grabador solo son accesibles desde la red local de la tienda, por lo que esta evaluación se centra en la seguridad de la conexión, el consumo de ancho de banda, los costos operativos y la viabilidad de operar sin modificar la infraestructura de red existente.

4.7.1 MediaMTX: Servidor de Retransmisión de Flujos de Video

MediaMTX constituye un servidor y proxy de medios de código abierto que permite leer, retransmitir y publicar flujos de video en distintos protocolos (RTSP, RTMP, HLS, WebRTC y SRT). Su configuración se realiza mediante un archivo YAML, en el que cada flujo de origen se asocia a una ruta propia que los clientes pueden consumir (bluenviron, s. f.).

1. **Consumo de Recursos y Ancho de Banda:** Se distribuye como un binario único sin dependencias externas. Mediante el parámetro sourceOnDemand solo solicita video a la cámara cuando un cliente se conecta, y permite que varios consumidores lean el mismo flujo manteniendo una única conexión con el grabador.
2. **Limitaciones Operativas:** Carece de interfaz gráfica, por lo que toda la configuración se realiza editando el archivo de texto. Además, no transcodifica por sí mismo: modificar la resolución o el códec del flujo requiere herramientas adicionales como FFmpeg.

4.7.2 Tailscale: Red Privada Virtual en Malla basada en WireGuard

Tailscale constituye un servicio de red privada virtual en malla construido sobre el protocolo WireGuard (Tailscale, s. f.; Donenfeld, 2017). Asigna a cada dispositivo una dirección IP privada fija dentro del rango 100.x.y.z y establece túneles cifrados entre ellos, atravesando NAT y firewalls sin necesidad de abrir puertos en el router.

1. **Conectividad y Seguridad:** No requiere modificar la configuración de red del establecimiento y cifra el tráfico de extremo a extremo entre los dispositivos. Asimismo, permite que varios usuarios accedan en simultáneo al mismo equipo.
2. **Disponibilidad y Costos Operativos:** La plataforma dispone de un plan gratuito para uso personal. Se destaca que, por defecto, las claves de los dispositivos caducan periódicamente, por lo que en equipos desatendidos debe deshabilitarse esa caducidad. Cuando no logra una conexión directa, enruta el tráfico por servidores de retransmisión (DERP), lo que incrementa la latencia.

4.7.3 AnyDesk y TeamViewer: Herramientas de Acceso Remoto de Escritorio

Como complemento para la administración de equipos ubicados fuera del alcance físico del equipo de trabajo, se analizaron herramientas de escritorio remoto como AnyDesk y TeamViewer, que permiten visualizar y controlar gráficamente un equipo a distancia (AnyDesk Software GmbH, s. f.; TeamViewer, s. f.).

1. **Modalidad de Acceso:** Permiten el acceso desatendido mediante una contraseña fija, sin que una persona deba aceptar la conexión en el equipo remoto, y se ejecutan como servicio iniciándose automáticamente con el sistema operativo.
2. **Limitaciones de Uso:** Las versiones gratuitas, destinadas a uso personal, admiten una sola sesión simultánea. En distribuciones Linux con servidor gráfico Wayland presentan restricciones de captura de pantalla, y no resultan adecuadas para transmitir flujos de video de forma continua hacia procesos de análisis.

4.7.4 DNS Dinámico con Redirección de Puertos (Port Forwarding)

Como alternativa que no requiere software de red adicional en los equipos clientes, se analizó la publicación directa del grabador hacia internet mediante servicios de DNS dinámico como No-IP o DuckDNS, que asocian un nombre de dominio a la dirección IP pública variable del establecimiento.

1. **Arquitectura y Requisitos:** Este enfoque redirige puertos del router hacia el grabador, permitiendo que los clientes accedan directamente a sus flujos. Requiere permisos administrativos sobre la red del establecimiento, que no siempre están disponibles.

2. **Riesgos y Limitaciones:** El grabador queda accesible públicamente, lo que incrementa la superficie de ataque, dado que los dispositivos de videovigilancia son objetivos frecuentes de ataques automatizados (Antonakakis et al., 2017). Además, puede resultar inviable si el proveedor de internet aplica CGNAT y comparte la IP pública entre varios clientes (Perreault et al., 2013).

4.7.5 Captura con Cámara de Smartphone y Procesamiento con FFmpeg

Cuando el circuito de cámaras existente no cubre un sector con la resolución necesaria, una alternativa de bajo costo es utilizar un teléfono inteligente como cámara IP. Aplicaciones como **IP Camera Lite** (iOS) transmiten la imagen de la cámara del teléfono a través de la red Wi-Fi local, en formato **MJPEG** (*Motion JPEG*) sobre HTTP. Este formato envía el video como una secuencia de imágenes JPEG independientes.

Por otra parte, **FFmpeg** es un conjunto de herramientas de código abierto para la conversión, el recorte y la codificación de audio y video. Permite transformar los formatos propietarios de los grabadores a contenedores estándar y generar clips a partir de una secuencia de imágenes (FFmpeg, s. f.) .

Ventajas:

- **Costo y flexibilidad (smartphone):** reutiliza un dispositivo disponible y puede reubicarse fácilmente.
- **Simplicidad (MJPEG):** cada cuadro es una imagen completa, lo que facilita su lectura desde cualquier navegador o biblioteca de visión.
- **Compatibilidad (FFmpeg):** soporta prácticamente todos los formatos y códecs de video.

Desventajas:

- **Mayor consumo de ancho de banda (MJPEG):** al no comprimir entre cuadros, requiere más ancho de banda que formatos como H.264.
- **Dependencia del dispositivo:** la transmisión depende de la batería, la temperatura y la conexión Wi-Fi del teléfono.
- **Uso por línea de comandos (FFmpeg):** su configuración requiere conocer una gran cantidad de parámetros.

4.8 Análisis Comparativo de Tecnologías de Desarrollo (Backend y Frontend)

4.8.1 Tecnologías de Backend: Python vs. Node.js

El procesamiento de flujos de video y la ejecución de modelos de Inteligencia Artificial requieren una infraestructura de servidor capaz de gestionar tareas intensivas de cómputo y alta concurrencia. En este ámbito, **Python** se destaca por su integración nativa con librerías críticas como PyTorch (Paszke et al., 2019), TensorFlow y OpenCV. Frameworks como *FastAPI* introducen un manejo asíncrono basado en estándares de tipado de Python, permitiendo una gestión eficiente de peticiones concurrentes sin bloquear el hilo principal, a diferencia de opciones más tradicionales como *Flask*, que requieren configuraciones adicionales para escenarios de alta carga.

Como contraparte, **Node.js** (mediante *Express*) ofrece un modelo de entrada/salida no bloqueante sumamente eficiente para aplicaciones de red masivas. No obstante, su ecosistema para visión por computadora es significativamente menos maduro que el de Python, obligando frecuentemente a utilizar puentes de comunicación o microservicios externos para interactuar con modelos de deep learning, lo que puede incrementar la latencia y la complejidad arquitectónica del sistema.

Flask, por su parte, es un microframework web para Python construido sobre la biblioteca Werkzeug. Su núcleo es mínimo y deja al desarrollador la elección de los componentes adicionales. Permite organizar las rutas de una API en módulos independientes mediante *Blueprints* y, en producción, se ejecuta sobre un servidor WSGI como Gunicorn. Su modelo es principalmente sincrónico, lo que lo vuelve menos adecuado que FastAPI para escenarios de alta concurrencia, pero suficiente y más simple para APIs que solo consultan información ya almacenada (Pallets, s. f.).

4.8.2 Tecnologías de Frontend: React, Vue y Angular

La visualización de métricas en tiempo real demanda un framework con alta capacidad de respuesta y modularidad de componentes. **React.js**, complementado con *Next.js*, proporciona un modelo de renderizado híbrido y un DOM virtual que optimiza la actualización de elementos visuales complejos, como tableros de control y mapas de calor. Su arquitectura basada en componentes facilita el mantenimiento y la escalabilidad de interfaces dinámicas (Meta Open Source, s. f.).

Por otro lado, **Angular** ofrece un entorno integral (*opinionated*) con herramientas robustas para proyectos corporativos de gran escala, aunque su curva de aprendizaje y el peso de su ejecución pueden resultar excesivos para interfaces de monitoreo ágil. **Vue.js** se presenta como una alternativa equilibrada con un rendimiento de renderizado comparable al de React, pero su ecosistema de librerías para visualización de datos científicos es menos

extenso, lo que podría limitar la personalización avanzada de los indicadores operativos (Angular, s. f.).

En cuanto a las herramientas de construcción, Vite se presenta como una alternativa a los marcos de trabajo completos como Next.js para aplicaciones de página única (SPA). Ofrece un servidor de desarrollo que actualiza la interfaz casi instantáneamente al guardar un archivo y empaqueta el código optimizado para producción. A diferencia de Next.js, no incorpora renderizado del lado del servidor, lo que simplifica la arquitectura cuando la aplicación consume una API independiente (Vite, s. f.).

4.9 Tecnologías de Contenedores, Despliegue e Integración Continua

Para la publicación de una aplicación web y la verificación automática de cada versión se analizaron tres tecnologías complementarias.

Docker permite empaquetar una aplicación junto con todas sus dependencias en una imagen que se ejecuta de forma idéntica en cualquier entorno, como un contenedor aislado. Las construcciones en varias etapas (*multi-stage builds*) permiten compilar en una etapa y conservar en la imagen final solo lo necesario para la ejecución (Docker Inc., s. f.).

Render es una plataforma como servicio (PaaS) que despliega aplicaciones web a partir de una imagen Docker o de un repositorio, y gestiona automáticamente el certificado HTTPS y la infraestructura (Render, s. f.).

GitHub Actions es el servicio de automatización integrado en GitHub. Permite definir, mediante archivos YAML, flujos de integración y despliegue continuos (CI/CD) que se ejecutan ante cada cambio del repositorio: compilación, pruebas, análisis estático y publicación (GitHub, s. f.).

Ventajas:

- **Reproducibilidad (Docker):** elimina las diferencias entre el entorno de desarrollo y el de producción.
- **Simplicidad operativa (Render):** no requiere administrar servidores y permite mantener entornos separados de calidad y producción.
- **Calidad automatizada (GitHub Actions):** garantiza que solo se publiquen versiones que superaron las pruebas.

Desventajas:

- **Curva de aprendizaje (Docker):** requiere conocer la construcción de imágenes y

la gestión de contenedores.

- **Limitaciones de los planes gratuitos (Render):** los servicios gratuitos se suspenden tras un período de inactividad, lo que demora la primera respuesta posterior.
- **Límites de uso (GitHub Actions):** los repositorios privados disponen de una cantidad limitada de minutos de ejecución gratuitos.

5. Marco Legal y Ético

5.1 Introducción

Los sistemas de videovigilancia y, en particular, aquellos que incorporan técnicas de análisis automático de imágenes, operan sobre información referida a personas. Por este motivo, su diseño y su utilización deben enmarcarse en la normativa de protección de datos personales vigente y en un conjunto de principios éticos que resguarden la intimidad y la dignidad de clientes y trabajadores. Este apartado sintetiza el marco normativo argentino aplicable y los principios que orientan el uso responsable de la visión por computadora en entornos comerciales.

5.2 Protección de datos personales en Argentina

El derecho a la protección de los datos personales cuenta con reconocimiento constitucional a través de la acción de hábeas data (Constitución de la Nación Argentina, 1994, art. 43). Su regulación específica se encuentra en la Ley 25.326 de Protección de los Datos Personales (2000), cuya autoridad de aplicación es actualmente la Agencia de Acceso a la Información Pública (AAIP).

La ley define como dato personal a la información de cualquier tipo referida a personas humanas determinadas o determinables. Además, distingue la categoría de datos sensibles, que comprende aquellos que revelan origen racial y étnico, opiniones políticas, convicciones religiosas, filosóficas o morales, afiliación sindical e información referente a la salud o a la vida sexual (Ley 25.326, 2000, art. 2). Entre los principios que establece, resultan especialmente relevantes para los sistemas de análisis de video los siguientes:

- **Calidad y proporcionalidad:** los datos recolectados deben ser ciertos, adecuados, pertinentes y no excesivos en relación con la finalidad para la que se obtuvieron. Además, deben destruirse cuando dejen de ser necesarios para esa finalidad (art. 4).
- **Consentimiento e información:** el tratamiento requiere, como regla general, el consentimiento libre, expreso e informado del titular, y este debe ser informado de la existencia del tratamiento, su finalidad y su responsable (arts. 5 y 6).

- **Seguridad y confidencialidad:** el responsable debe adoptar las medidas técnicas y organizativas necesarias para garantizar la seguridad de los datos y evitar su adulteración, pérdida o acceso no autorizado (arts. 9 y 10).
- **Transferencia internacional:** se prohíbe la transferencia de datos personales a países u organismos que no proporcionen niveles de protección adecuados, salvo las excepciones previstas por la propia ley (art. 12).

En el plano internacional, Argentina aprobó el Convenio 108 del Consejo de Europa para la protección de las personas con respecto al tratamiento automatizado de datos de carácter personal (Ley 27.483, 2018). Este convenio refuerza los principios de minimización y de limitación de la finalidad.

5.3 Videovigilancia e imágenes de personas

La imagen de una persona que permite identificarla constituye un dato personal. En este sentido, la entonces Dirección Nacional de Protección de Datos Personales, mediante la Disposición 10/2015, estableció las condiciones de licitud para la recolección y el tratamiento de imágenes digitales de personas mediante sistemas de videovigilancia. Entre ellas, se destaca la obligación de informar a las personas sobre la existencia de cámaras mediante carteles visibles, en los que se identifique al responsable del tratamiento y el modo de ejercer los derechos de acceso, rectificación y supresión.

De manera complementaria, el Código Civil y Comercial de la Nación protege la intimidad personal y el derecho a la propia imagen (arts. 52 y 53). En el ámbito laboral, la Ley de Contrato de Trabajo exige que los sistemas de control del personal salvaguarden la dignidad del trabajador (Ley 20.744, art. 70).

Un aspecto particularmente sensible es el cambio de finalidad. Las cámaras de un comercio se instalan habitualmente con fines de seguridad, por lo que su reutilización para obtener métricas operativas o comerciales constituye un tratamiento con una finalidad distinta. Este nuevo tratamiento debe evaluarse a la luz de los principios de proporcionalidad y de información al titular.

5.4 Privacidad por diseño

El enfoque de privacidad por diseño (*Privacy by Design*) propone incorporar la protección de la privacidad desde las primeras etapas del desarrollo de un sistema, en lugar de agregarla como un control posterior. Sus siete principios fundacionales incluyen la anticipación de riesgos, la privacidad como configuración predeterminada, la protección durante todo el ciclo de vida de los datos y la transparencia hacia los usuarios (Cavoukian,

2009). En los sistemas de visión por computadora, este enfoque se traduce en prácticas concretas: evitar el reconocimiento facial y la identificación biométrica, minimizar los datos almacenados, priorizar métricas agregadas por sobre los registros individuales y difuminar los rostros en las imágenes que se conservan o se comparten.

5.5 Consideraciones éticas del análisis automático de comportamiento

Más allá del cumplimiento normativo, la aplicación de inteligencia artificial al análisis del comportamiento de las personas plantea desafíos éticos propios:

- **Errores y falsos positivos:** un sistema que señala posibles hurtos puede equivocarse. Una alerta errónea, si se actúa sobre ella sin verificación, puede derivar en un trato injusto hacia un cliente. Por este motivo, se recomienda que las decisiones finales permanezcan siempre a cargo de una persona (*human in the loop*).
- **Sesgos de los modelos:** los modelos entrenados sobre conjuntos de datos generales pueden presentar un desempeño desigual según las condiciones de iluminación, la vestimenta o las características físicas de las personas.
- **Transparencia y proporcionalidad:** la vigilancia debe limitarse a lo necesario para la finalidad declarada, y las personas observadas deben poder conocer su existencia.
- **Uso de servicios de terceros:** el envío de imágenes a servicios de inteligencia artificial en la nube implica que los datos son procesados por proveedores externos, frecuentemente ubicados en otros países, lo que debe considerarse en relación con la transferencia internacional de datos.

PROPUESTA DE SOLUCIÓN

La solución desarrollada, denominada OptiFull, responde a la problemática expuesta en el Diagnóstico: el circuito de cámaras de la tienda FULL se utiliza de manera exclusivamente reactiva y forense, mientras que los procesos de control de stock, supervisión del salón y análisis del flujo de clientes dependen de la observación manual del personal. La propuesta consiste en convertir ese sistema de videovigilancia pasivo en una herramienta de asistencia operativa. Para ello, se procesan con técnicas de Visión por Computadora los flujos de video que el grabador del establecimiento ya genera, y los resultados se presentan como indicadores, mapas de calor y alertas dentro de una interfaz web.

El principio rector de la solución es la reutilización de la infraestructura existente. En línea con la Oportunidad de Innovación identificada en la sección 3.5, el sistema no incorpora hardware propietario de analítica comercial, como cámaras cenitales estereoscópicas o sensores LiDAR, cuyo costo se señaló como limitante en la sección 3.4. En su lugar, consume los flujos RTSP del grabador Hikvision relevado en la sección 2.11. La única incorporación física es un nodo de captura de bajo costo (una tableta Microsoft Surface Pro 3 con Ubuntu), cuya función se limita a vincular la red interna de la tienda con los equipos de análisis, sin exponer el grabador a internet.

Sobre esa base, la solución se organiza en tres grandes bloques funcionales que se corresponden con las necesidades relevadas en el análisis de campo (secciones 2.8 a 2.10):

- **Análisis del salón:** detección y seguimiento de personas, generación de mapas de calor y métricas de circulación, y clasificación del recorrido de cada visita en compra normal, tránsito sin compra o posible hurto.
- **Asistencia en caja:** reconocimiento del producto que la cajera presenta frente a la cámara del mostrador y descuento del stock correspondiente, con confirmación humana en los casos ambiguos.
- **Visualización y gestión:** tablero web con indicadores, reportes exportables, alertas y control de acceso por usuario.

La selección tecnológica surge de la evaluación realizada en el Marco Teórico. Se adoptó YOLOv8 (sección 4.3.1) para la detección de personas, en dos variantes según la fuente de video. Para las grabaciones exportadas del NVR se empleó la variante Nano, por su menor costo computacional. Para los flujos RTSP en vivo se empleó la variante Small, ya que la menor resolución del flujo secundario y el ángulo elevado de las cámaras exigen un modelo de mayor capacidad para detectar a las personas (ver Módulo 3). La detección se

complementa con el algoritmo ByteTrack para el seguimiento entre fotogramas. Los modelos multimodales en la nube analizados en las secciones 4.3.4 a 4.3.6 (Gemini, Groq y Claude) se incorporaron solamente en las tareas que requieren interpretación semántica: la reidentificación de personas entre cámaras y la lectura de marca, variante y tamaño de los productos en caja. Como consecuencia de la latencia de red y del costo por uso señalados en esas secciones, su invocación se restringe a los casos en que las heurísticas locales resultan insuficientes. La persistencia se resolvió con Supabase (sección 4.6.1), y el acceso remoto a los flujos de video se resolvió combinando MediaMTX y Tailscale (sección 4.7). Esta combinación se prefirió frente a la publicación del grabador mediante DNS dinámico, debido a los riesgos de seguridad y a la posible presencia de CGNAT señalados en la sección 4.7.4. El seguimiento se resolvió con ByteTrack (sección 4.3.7), por su menor costo computacional frente a BoT-SORT en equipos sin GPU. Para la reidentificación se combinaron los descriptores de color con los modelos multimodales (sección 4.3.8), y para el reconocimiento de productos se optó por el enfoque *zero-shot* complementado con coincidencia difusa mediante RapidFuzz (secciones 4.3.9 y 4.3.10). El despliegue se automatizó con Docker, Render y GitHub Actions (sección 4.9).

En el plano del desarrollo, se optó por Python para los procesos de análisis, conforme a lo expuesto en la sección 4.8.1. La interfaz web se construyó con React, en consonancia con la sección 4.8.2. Respecto de FastAPI, también analizado en el Marco Teórico, se priorizó Flask para la API REST, dado que el servidor web no ejecuta procesamiento de visión. Su función se limita a consultar y agregar información ya persistida, por lo que el manejo asíncrono de alta concurrencia no constituye un requisito del sistema.

Asimismo, la solución se diseñó bajo el criterio de privacidad por diseño, en concordancia con el marco legal y ético expuesto en la sección 5. Ningún componente realiza reconocimiento facial ni almacena identificadores biométricos. La identidad de cada persona dentro de una visita se sostiene con descriptores de apariencia no biométricos, como el color de la indumentaria, la complexión y los accesorios. La información que se presenta al personal es mayoritariamente agregada (flujo, permanencia, mapas de calor). Las imágenes individuales se conservan solo como evidencia de las alertas de posible hurto y en la confirmación de posibles empleados. Además, el sistema se limita a alertar: la decisión de intervenir corresponde siempre al personal, lo que mitiga el impacto de eventuales falsos positivos.

No obstante, para una puesta en producción se identifican aspectos que requieren medidas adicionales:

- la señalización en el local que informe sobre el análisis automático de las imágenes, conforme a la Disposición 10/2015;
- la definición de un plazo de conservación de las evidencias y de las imágenes de personas, con su eliminación automática al vencer;
- la evaluación de la transferencia internacional de datos que implica enviar recortes de imágenes a los proveedores de inteligencia artificial en la nube, o bien el difuminado de los rostros antes de su envío;
- la información a los trabajadores sobre la clasificación automática de empleados.

Alcance Funcional

El alcance funcional de OptiFull se definió a partir de las necesidades relevadas en el análisis de campo (secciones 2.8 a 2.11) y de los objetivos específicos planteados. En este apartado se identifican los actores que interactúan con el sistema, se especifican los requerimientos funcionales y no funcionales agrupados por módulo, se describen las interacciones principales mediante historias de usuario y se delimitan las funcionalidades que quedan fuera del alcance del proyecto.

Actores del sistema

Del relevamiento realizado surgen dos perfiles de usuario con necesidades de información diferentes, a los que se suma un actor no humano que ejecuta los procesos de análisis automático:

- **Administrador (dueño o gerente de la tienda):** responsable de la gestión del local y de la toma de decisiones operativas y estratégicas. Requiere acceso a la totalidad de la información generada: indicadores, mapas de calor, reportes históricos, alertas y estado del stock.
- **Usuario operativo (empleado o cajero):** personal que atiende el salón y la caja. Requiere únicamente la información vinculada a su tarea diaria: el reconocimiento y la confirmación de productos en caja y la atención de alertas.
- **Sistema de análisis (actor automático):** conjunto de procesos que analizan de manera continua los flujos de video de las cámaras y registran sus resultados en la base de datos, sin intervención humana.

La Tabla 5 resume las secciones de la interfaz web a las que accede cada perfil.

Sección	Administrador	Usuario operativo

Dashboard operativo	✓	—
Productos en caja	✓	✓
Reportes	✓	—
Alertas	✓	✓
Configuración	✓	—

Tabla 5: Permisos de acceso por perfil de usuario.
Fuente: elaboración propia.

Requerimientos Funcionales

Módulo de Autenticación y Control de Acceso

- **RF-01:** El sistema debe permitir el inicio de sesión mediante nombre de usuario o correo electrónico y contraseña.
- **RF-02:** El sistema debe asignar a cada usuario un rol (administrador o usuario operativo) y restringir las secciones visibles de la interfaz según dicho rol, redirigiendo a cada perfil a su sección inicial correspondiente.
- **RF-03:** El sistema debe bloquear temporalmente el acceso de una cuenta tras una cantidad determinada de intentos fallidos consecutivos.

Módulo de Captura de Video

- **RF-04:** El sistema debe obtener los flujos de video de las cámaras del establecimiento mediante el protocolo RTSP. Además, debe admitir el procesamiento de grabaciones exportadas del NVR para el análisis diferido y la calibración.
- **RF-05:** El sistema debe permitir el acceso a los flujos de video desde equipos ubicados fuera de la red local de la tienda, a través del nodo de captura.

Módulo de Detección y Seguimiento de Personas

- **RF-06:** El sistema debe detectar personas en los flujos de video de cada cámara del salón.
- **RF-07:** El sistema debe asignar y mantener un identificador estable por persona mientras permanece en escena, incluso ante oclusiones breves.
- **RF-08:** El sistema debe reidentificar a una misma persona cuando reaparece en otra cámara del mismo sector físico o tras una interrupción prolongada de su seguimiento,

a partir de descriptores de apariencia no biométricos.

- **RF-09:** El sistema debe distinguir clientes de empleados. La clasificación se realiza de forma automática, en función de la permanencia y la posición dentro del local, y el administrador puede confirmarla o corregirla manualmente desde la interfaz.
- **RF-10:** El sistema debe informar la cantidad de clientes presentes en la tienda en el momento de la consulta, mientras haya un análisis en vivo en curso.

Módulo de Mapas de Calor

- **RF-11:** El sistema debe acumular la densidad de circulación de personas por cámara y generar un mapa de calor normalizado para cada sesión de análisis.
- **RF-12:** El sistema debe combinar los mapas de calor de sesiones sucesivas de una misma cámara en un mapa acumulado histórico.
- **RF-13:** El sistema debe proyectar la circulación sobre el plano del local y permitir su consulta por cámara, por zona y por período, con un reproductor cronológico por franja horaria.
- **RF-14:** El sistema debe calcular estadísticas derivadas de cada mapa, tales como el punto de máxima concentración, el porcentaje de área activa y la zona de mayor circulación.

Módulo de Zonificación y Clasificación de Comportamiento

- **RF-15:** El sistema debe permitir definir, para cada cámara, zonas de interés (entrada, salida, caja, góndola, depósito u otra) y registrar la secuencia de zonas recorridas en cada visita.
- **RF-16:** El sistema debe detectar si una persona tomó un producto de una góndola o heladera durante su visita.
- **RF-17:** El sistema debe clasificar automáticamente cada visita finalizada en una de tres categorías:
    - **Compra normal:** la persona se acercó a la zona de caja.
    - **Posible hurto:** la persona tomó un producto y se retiró sin acercarse a pagar.
    - **Tránsito sin compra:** la persona no realizó ninguna de las dos acciones anteriores.

Módulo de Alertas

- **RF-18:** El sistema debe generar una alerta cuando una visita sea clasificada como posible hurto.
- **RF-19:** El sistema debe adjuntar a cada alerta de posible hurto una evidencia visual. La evidencia está compuesta por fotogramas clave y un clip breve de dos momentos:

cuando la persona tomó el producto y cuando se retiró del local. En ambos, la persona involucrada aparece señalada.

- **RF-20:** El sistema debe presentar las alertas en un listado actualizado periódicamente y permitir marcarlas como resueltas.

Módulo de Reconocimiento de Productos en Caja

- **RF-21:** El sistema debe identificar, mediante una cámara orientada al mostrador, el producto que el cajero presenta, extrayendo su marca, variante y tamaño. La identificación no debe requerir imágenes de referencia de cada producto ni reentrenamiento ante la incorporación de nuevos artículos.
- **RF-22:** El sistema debe analizar la imagen únicamente cuando la escena del mostrador se encuentre estable y difiera de la última escena analizada.
- **RF-23:** El sistema debe vincular el producto identificado con el catálogo de la tienda mediante un puntaje de similitud combinado. Según el resultado:
    - reconocimiento con alta confianza: solicita una confirmación simple;
    - candidatos ambiguos: presenta entre dos y tres opciones para que el cajero elija;
    - producto no reconocido: habilita la carga manual.
- **RF-24:** El sistema debe descontar el stock y registrar la transacción únicamente después de la confirmación del cajero.
- **RF-25:** El sistema debe permitir iniciar y detener el reconocimiento de productos en caja desde la interfaz web y seleccionar productos del catálogo para su carga manual cuando no sean reconocidos automáticamente.

Módulo de Reportes

- **RF-26:** El sistema debe presentar en el dashboard los indicadores operativos principales: personas detectadas, permanencia promedio, personas en tienda y alertas, con su tendencia. Los indicadores se filtran por período (día actual, últimos 7 días, últimos 30 días o rango personalizado).
- **RF-27:** El sistema debe generar reportes de las siguientes métricas:
    - flujo de personas por día de la semana;
    - permanencia promedio por día y por zona;
    - congestión por día y hora;
    - tiempo de espera en caja por franja horaria;
    - tasa de conversión de compra;
    - personas por zona;
    - productos más detectados, de mayor rotación y con menor stock.

- **RF-28:** El sistema debe permitir exportar los reportes en formato PDF, Excel, CSV o imagen PNG, seleccionando las métricas, las cámaras y el rango de fechas.

Módulo de Persistencia

- **RF-29:** El sistema debe almacenar sesiones de análisis, personas, trayectorias, visitas, eventos, alertas, mapas de calor, productos y transacciones en una base de datos relacional compartida por todos los módulos.
- **RF-30:** El sistema debe ejecutar, al finalizar cada análisis, una auditoría automática que recalcule zonas, fusione registros duplicados de una misma persona entre cámaras o entre videos consecutivos y reclasifique empleados.

Requerimientos No Funcionales

- **RNF-01 (Privacidad):** Ningún componente del sistema debe realizar reconocimiento facial ni almacenar identificadores biométricos. La reidentificación se basa exclusivamente en descriptores de apariencia no biométricos, como el color de la indumentaria, la complexión y los accesorios.
- **RNF-02 (Costo operativo):** El uso de servicios de inteligencia artificial en la nube debe limitarse a los casos en que el procesamiento local resulte insuficiente, mediante filtros previos de estabilidad de escena y límites de frecuencia de invocación. El objetivo es mantener el costo mensual dentro de un presupuesto acotado.
- **RNF-03 (Desacoplamiento):** Los procesos de análisis de video, de reconocimiento de productos y el servidor web deben poder ejecutarse, actualizarse y reiniciarse de manera independiente, comunicándose exclusivamente a través de la base de datos compartida.
- **RNF-04 (Veracidad de la información):** La interfaz debe indicar la ausencia de datos (“—”) cuando una métrica no disponga de información real, sin mostrar valores de ejemplo o estimados.
- **RNF-05 (Seguridad de acceso remoto):** El acceso a los flujos de video desde fuera del establecimiento no debe requerir exponer el grabador a internet ni abrir puertos en el router de la estación de servicio.
- **RNF-06 (Operación desatendida):** El nodo de captura instalado en la tienda debe funcionar de manera continua sin intervención presencial y restablecer automáticamente sus servicios tras un reinicio.
- **RNF-07 (Seguridad de credenciales):** Las contraseñas deben almacenarse cifradas mediante una función de hash. Ante credenciales incorrectas, el sistema debe responder con un mensaje genérico que no permita deducir qué usuarios existen.

- **RNF-08 (Tolerancia a fallos):** El análisis de video debe poder ejecutarse aun sin conexión a la base de datos (modo de solo consola). Además, el almacenamiento de mapas de calor debe recurrir al disco local cuando el almacenamiento remoto no esté disponible.
- **RNF-09 (Usabilidad):** La interfaz debe permitir la navegación entre secciones sin recargar la página y ofrecer modo claro y oscuro.

Historias de Usuario

Como complemento de los requerimientos, se presentan las historias de usuario (Cohn, 2004) que describen las interacciones principales de cada actor con el sistema:

- **HU-01:** Como administrador, quiero visualizar en qué zonas del local se concentra la circulación de clientes, para reorganizar la exhibición de productos y la dotación de personal. *(RF-11 a RF-14)*
- **HU-02:** Como administrador, quiero conocer los días y horarios de mayor congestión y el tiempo de espera en caja, para anticipar los picos de afluencia, como la llegada de contingentes, y reforzar la atención. *(RF-26, RF-27)*
- **HU-03:** Como usuario operativo, quiero recibir una alerta con evidencia visual cuando un cliente se retire con un producto sin pasar por caja, para intervenir a tiempo o justificar diferencias de inventario. *(RF-17 a RF-20)*
- **HU-04:** Como usuario operativo, quiero que el sistema reconozca el producto que apoyo frente a la cámara de caja y me pida solo una confirmación, para registrar la venta sin buscarlo manualmente en el sistema. *(RF-21 a RF-24)*
- **HU-05:** Como administrador, quiero exportar reportes de las métricas del local en PDF o Excel, para analizarlos y compartirlos fuera del sistema. *(RF-28)*
- **HU-06:** Como administrador, quiero indicar si una persona detectada es empleado, para que las métricas de clientes no incluyan al personal. *(RF-09)*
- **HU-07:** Como administrador, quiero que cada usuario acceda solo a las secciones que necesita, para proteger la información de gestión del negocio. *(RF-01 a RF-03)*

Fuera de Alcance

Las siguientes funcionalidades quedan explícitamente excluidas del proyecto:

- Reconocimiento facial o identificación biométrica de clientes o empleados.
- Predicción de demanda o generación automática de pedidos de reposición. El sistema registra el consumo real a través de las transacciones confirmadas, pero no proyecta necesidades futuras.
- Integración directa con el sistema de facturación o punto de venta oficial de YPF.

- Análisis de zonas sin cobertura de cámaras, como el depósito interno de mercadería (ver “Puntos Ciegos”, sección 2.10).
- Entrenamiento de un modelo propio de detección de productos por SKU. Esta decisión se justifica en la sección de Implementación.
- Intervención automática ante un posible hurto. El sistema se limita a alertar y aportar evidencia; la decisión de actuar corresponde siempre al personal.
- Visualización del inventario completo de la tienda o control de existencias en góndola. El sistema registra los descuentos de stock derivados de las ventas confirmadas en caja, pero no ofrece una pantalla de gestión de inventario.
- Las funcionalidades anunciadas con fines comerciales en la página de bienvenida que no se encuentran especificadas en los requerimientos de esta sección, entre ellas la alerta por longitud de fila en caja y la detección de faltantes en góndola. Su desarrollo se contempla como una línea de trabajo futura.

Diseño

El diseño de OptiFull se elaboró con el propósito de traducir los requerimientos del Alcance Funcional en una estructura de software concreta, antes de abordar su implementación. En este apartado se presentan cuatro perspectivas complementarias:

- **Funcional:** las pantallas, que describen cómo interactúan los usuarios con el sistema.
- **Estructural y dinámica:** los diagramas UML, que representan los componentes y su colaboración.
- **Organizativa:** la arquitectura, que define la disposición de los componentes a nivel macro y la infraestructura que los soporta.
- **Reutilización:** los patrones de diseño aplicados para resolver problemas recurrentes de manera estandarizada.

Pantallas

La interfaz de usuario de OptiFull es una aplicación web de página única (Single Page Application) desarrollada con React y empaquetada con Vite. Se accede desde cualquier navegador, sin instalar software adicional en los equipos de la tienda. Su diseño responde a tres criterios derivados del análisis de campo:

- **Densidad de información:** el encargado debe poder evaluar el estado del local en un único vistazo, por lo que se priorizan tableros con indicadores agrupados por

sobre la navegación en profundidad.

- **Lectura inmediata:** se utiliza una paleta neutra con colores semánticos reservados para estados que requieren atención (rojo para situaciones críticas, ámbar para advertencias, verde para estados normales) y tipografía monoespaciada para los valores numéricos, lo que facilita su comparación.
- **Veracidad de los datos:** en concordancia con el RNF-04, cuando una métrica no dispone de información real se muestra el símbolo "—" acompañado de una leyenda explicativa ("sin datos en este período", "sin cámara en vivo"), en lugar de valores de ejemplo.

La aplicación se divide en dos zonas: un área pública, compuesta por la página de bienvenida y la pantalla de inicio de sesión, y un área privada, el panel operativo, al que se accede luego de autenticarse.

Página de bienvenida

Constituye la puerta de entrada al sistema. En la Figura 5 se presenta la propuesta de valor de OptiFull, resumida en el lema "Tus cámaras en acción, nuestra solución", y se organiza en tres bloques. El primero expone los problemas operativos que el sistema aborda. El segundo explica el funcionamiento general de la solución a partir de las cámaras ya instaladas. El tercero ofrece un formulario para solicitar una demostración. Desde esta pantalla, el usuario accede al inicio de sesión o, si ya tiene una sesión activa, directamente al panel operativo.

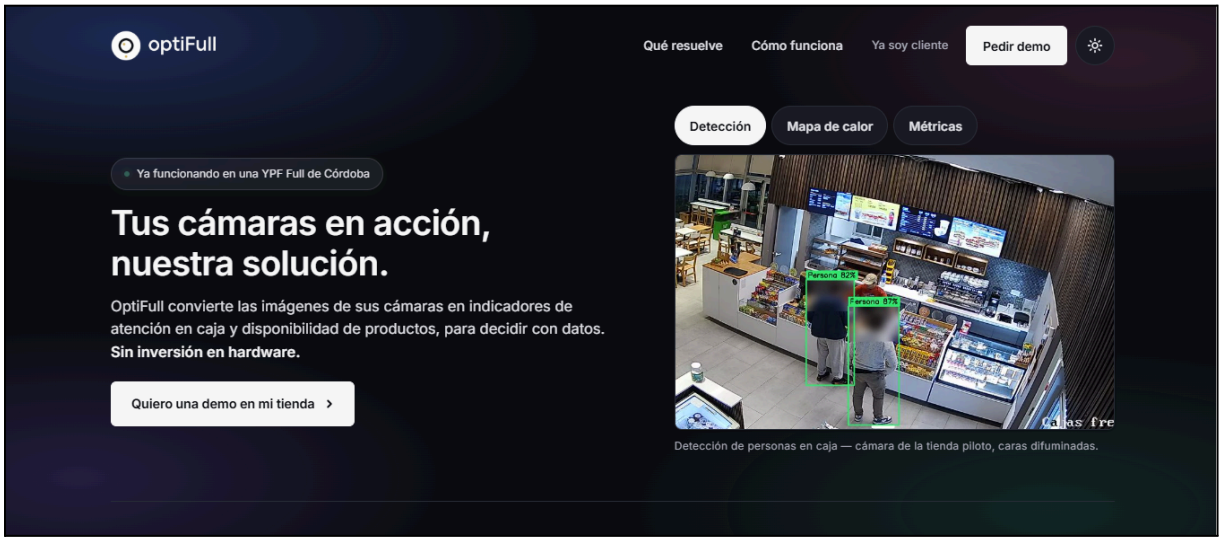


Figura 5: Página de bienvenida de OptiFull.
Fuente: elaboración propia.

Cabe aclarar que los contenidos de esta página cumplen una función comercial y de presentación del producto. Por ese motivo, describen también funcionalidades proyectadas para versiones futuras, como el aviso por longitud de fila en caja o la detección de faltantes en góndola. Estas funcionalidades no forman parte del alcance del presente proyecto (ver Fuera de Alcance).

Inicio de sesión

Como se observa en la Figura 6, esta pantalla solicita el nombre de usuario o correo electrónico y la contraseña. Ante campos incompletos, indica el error junto al campo correspondiente. Ante credenciales incorrectas, muestra un mensaje genérico que no revela si el usuario existe (RNF-07). Una vez autenticado, el usuario es dirigido a la sección inicial de su rol: el Dashboard para el administrador y la sección de Productos para el usuario operativo.

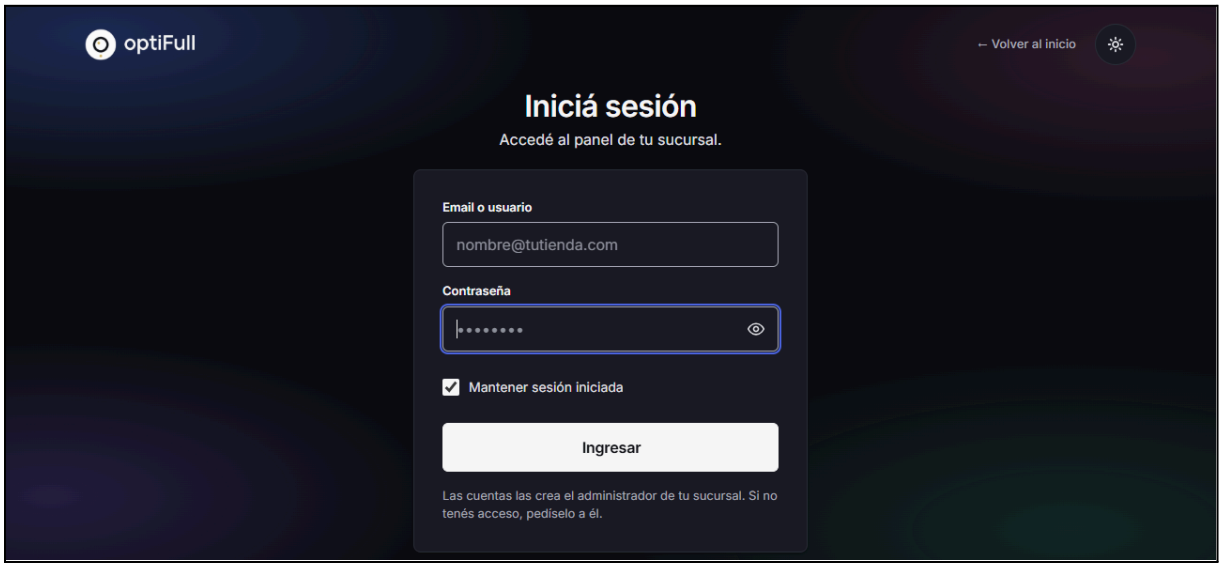


Figura 6: Pantalla de inicio de sesión de OptiFull.
Fuente: elaboración propia.

Estructura general del panel operativo

Todas las secciones del área privada comparten una misma estructura, compuesta por:

- **Barra lateral de navegación:** agrupa las secciones en tres categorías (Monitoreo, Análisis y Sistema) y muestra únicamente las secciones habilitadas para el rol del usuario (RF-02). Puede contraerse para ampliar el área de trabajo e incluye la opción de cerrar sesión.
- **Barra superior:** presenta la ruta de navegación (por ejemplo, “Monitoreo › Alertas”), la hora actual y el selector de modo claro u oscuro (RNF-09).

- **Área de contenido:** se compone de un encabezado con el título de la sección, una descripción breve y las acciones principales, seguido del contenido propio de la sección.

La navegación entre secciones se realiza sin recargar la página. Las acciones del usuario, como resolver una alerta o confirmar un producto, se confirman mediante notificaciones breves y no intrusivas. En la figura 7, se demuestra la estructura general del panel.

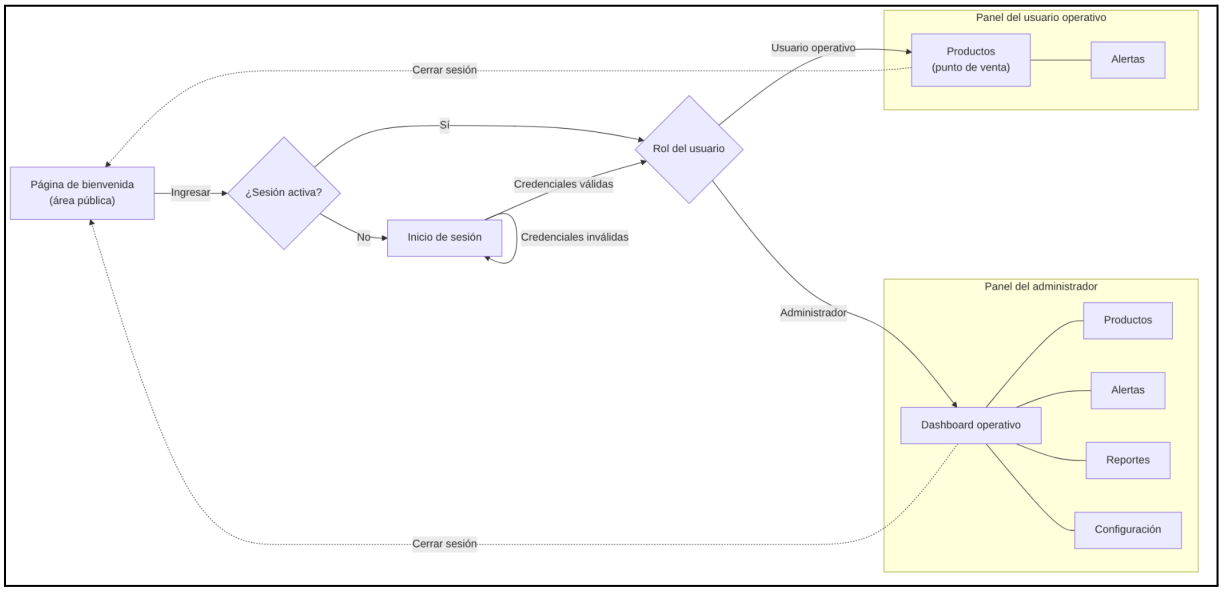


Figura 7: Flujo de navegación entre el área pública y el panel operativo según el rol del usuario.
Fuente: elaboración propia.

Dashboard operativo

Es la pantalla principal del administrador y concentra la información necesaria para el seguimiento diario del local (RF-26). Como se observa en las Figura 8 y 9, se organiza en cuatro áreas:

1. **Filtro de período:** permite seleccionar el día actual, los últimos 7 días, los últimos 30 días o un rango personalizado de fechas, además de forzar la actualización de los datos. Un subtítulo indica si hay un análisis en vivo en curso o si se muestran datos almacenados.
2. **Indicadores principales:** cuatro tarjetas muestran las personas presentes en la tienda en ese momento (RF-10), la permanencia promedio y máxima, la cantidad de

alertas activas con el detalle de las críticas, y la franja horaria pico con su promedio de personas simultáneas.

3. **Consola espacial:** presenta el plano del local con la circulación de clientes superpuesta (RF-13). Ofrece tres modos de visualización: *Calor* (densidad de circulación), *Trayectorias* (flujos de desplazamiento entre zonas) y *Zonas* (regiones de interés delimitadas). Incluye un control de opacidad y un reproductor cronológico que recorre las franjas horarias del día, con la posibilidad de ver los últimos 30 minutos o el acumulado hasta la hora seleccionada y de filtrar por sector (todo el local, caja o góndolas). Junto al plano, el panel *Analítica de zonas* ordena las zonas según la permanencia promedio y muestra el porcentaje de afluencia de cada una.
4. **Métricas complementarias:** paneles de conversión de compra (proporción de visitantes que compraron frente a los que no), tendencia semanal de flujo y permanencia, y horario de congestión por día y hora.

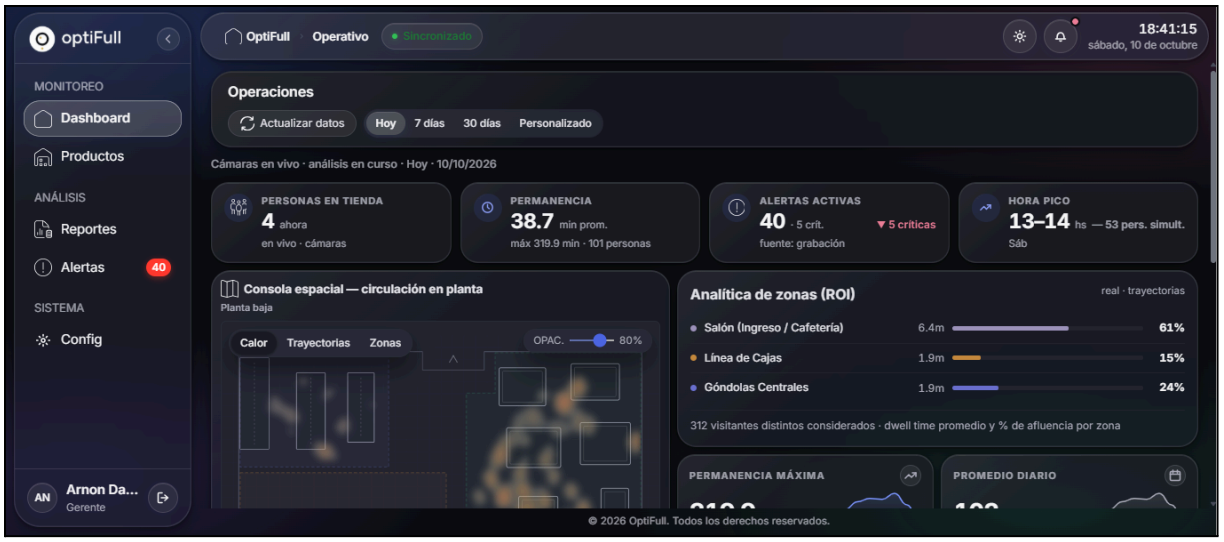


Figura 8: Dashboard operativo con indicadores en vivo y consola espacial en modo Calor.
Fuente: elaboración propia.

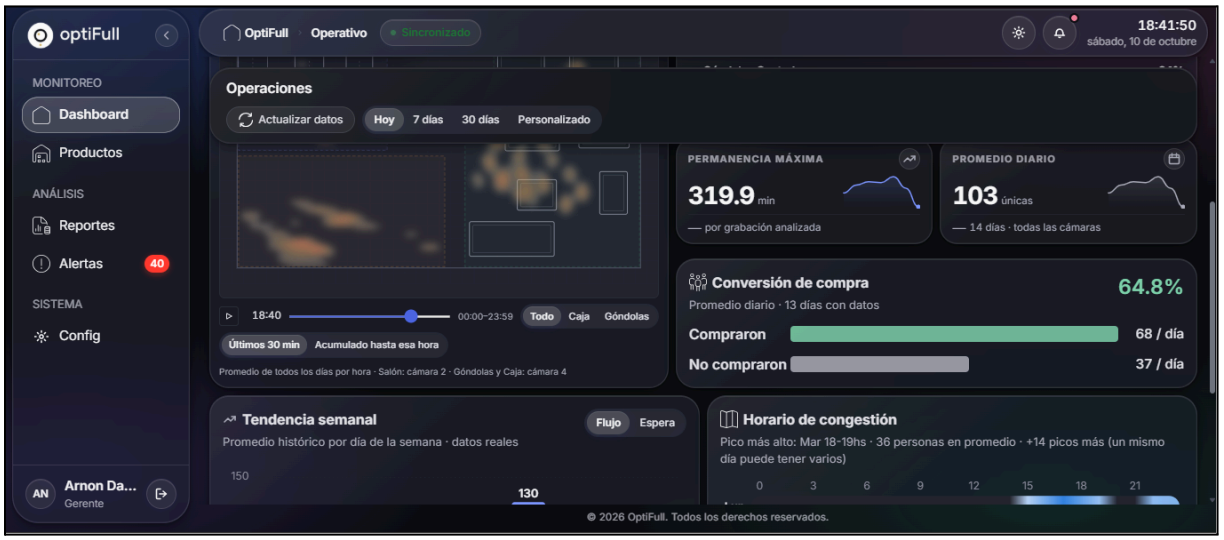


Figura 9: Dashboard operativo con indicadores principales y consola espacial en modo Calor.
Fuente: elaboración propia.

Productos (punto de venta)

Es la pantalla de uso del cajero para el reconocimiento de productos en caja (RF-21 a RF-25). Como se observa en la Figura 10, se compone de:

- **Indicadores de la sesión:**
  - transacciones confirmadas;
  - confianza promedio del modelo de visión;
  - cantidad de productos reconocidos sin necesidad de elegir entre candidatos;
  - estado de la cámara (encendida, iniciando o apagada).
- **Vista de caja:** muestra la imagen en vivo de la cámara del mostrador y permite seleccionar la fuente de video, así como iniciar y detener el reconocimiento.
- **Panel de producto detectado:** varía según el resultado del reconocimiento. Si el producto se reconoció con alta confianza, se muestra para su confirmación con la cantidad correspondiente. Si existen candidatos ambiguos, se presentan las opciones para que el cajero elija la correcta. Si el producto no se reconoció, se habilita la carga manual. En todos los casos es posible cancelar, y el stock se descuenta únicamente después de la confirmación (RF-24).
- **Ticket de la sesión:** lista los productos confirmados durante la jornada de caja en curso.

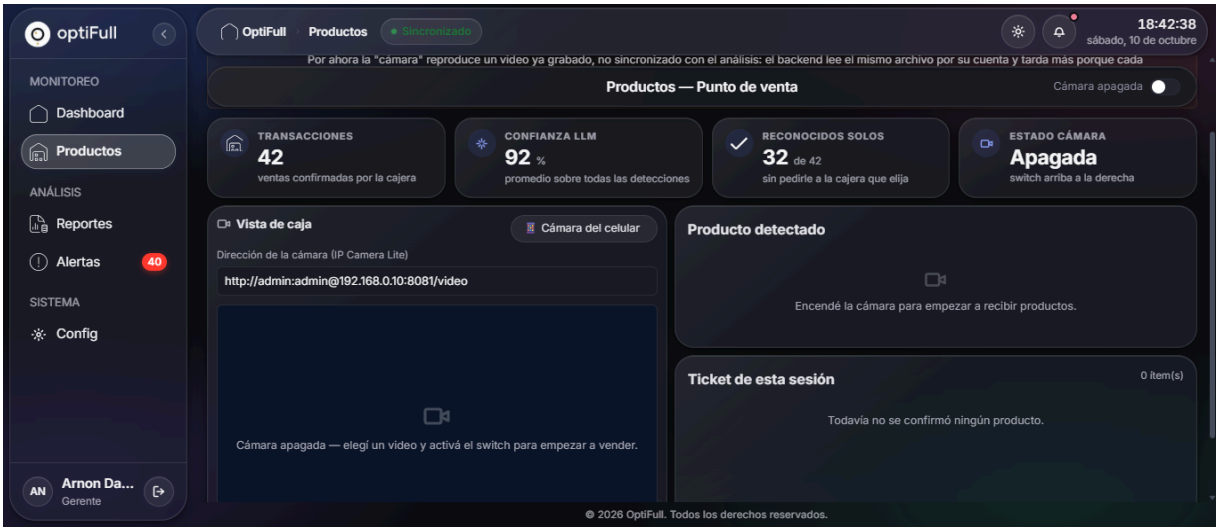


Figura 10: Pantalla de reconocimiento de productos en caja con un producto pendiente de confirmación.
Fuente: elaboración propia.

Alertas

Centraliza los eventos detectados por el sistema de visión que requieren atención del personal (RF-18 a RF-20). Como se observa en la Figura 11, se organiza en tres partes:

- **Resumen:** totales de alertas abiertas y resueltas, con el porcentaje de resolución.
- **Barra de filtros:** permite filtrar por severidad (crítica, advertencia o informativa), estado (abierta o resuelta) y zona del local.
- **Listado de alertas:** cada fila indica la severidad, el tipo de evento, la zona y el tiempo transcurrido, y señala si la alerta cuenta con evidencia. Al expandir una alerta de posible hurto, el usuario accede a la evidencia visual, compuesta por fotogramas clave y un clip breve con la persona señalada (RF-19), y puede marcarla como resuelta.

El listado también incluye las alertas de persona posiblemente empleada, generadas cuando el sistema detecta un patrón de permanencia propio del personal. En estos casos, la pantalla muestra una fotografía de la persona y ofrece las opciones “Es empleado” y “No es empleado”, que implementan la confirmación manual prevista en el RF-09.

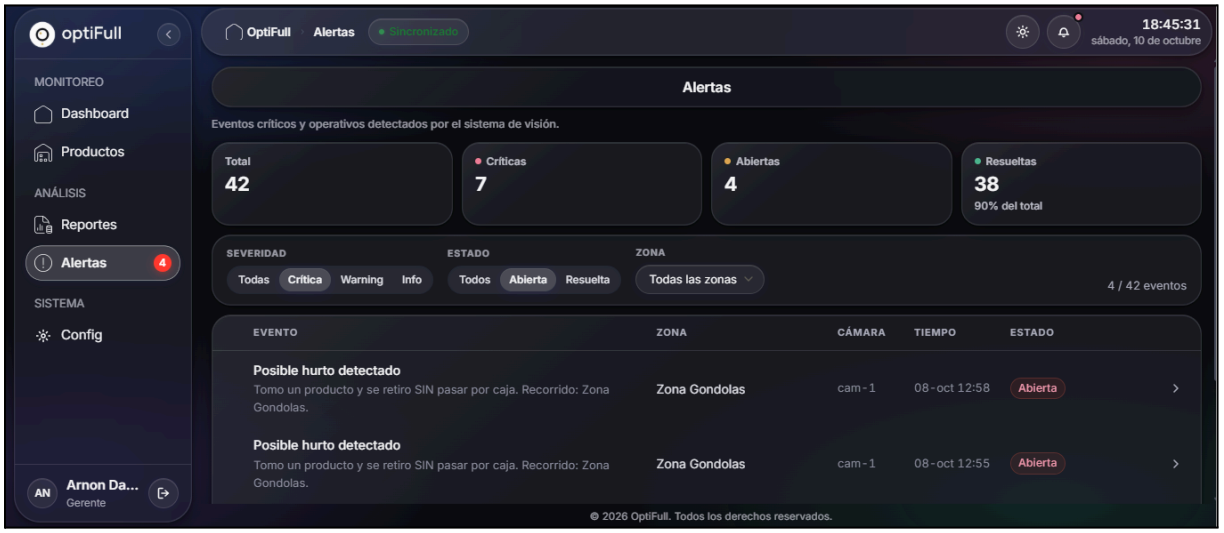


Figura 11: Listado de alertas con filtros por severidad, estado y zona.
Fuente: elaboración propia.

Reportes

Permite al administrador construir y descargar reportes a medida (RF-27 y RF-28). Como se observa en la Figura 12, el usuario configura el reporte en cuatro pasos:

1. Selecciona las métricas a incluir, agrupadas por categoría (flujo, permanencia, congestión, caja, zonas y stock), con un contador de las elegidas en cada grupo.
2. Define el período de análisis.
3. Elige las cámaras a considerar.
4. Selecciona el formato de exportación: PDF, Excel, CSV o imagen PNG.

A diferencia del Dashboard, esta sección no muestra cifras en vivo, sino que genera documentos para el análisis posterior o para compartir fuera del sistema.

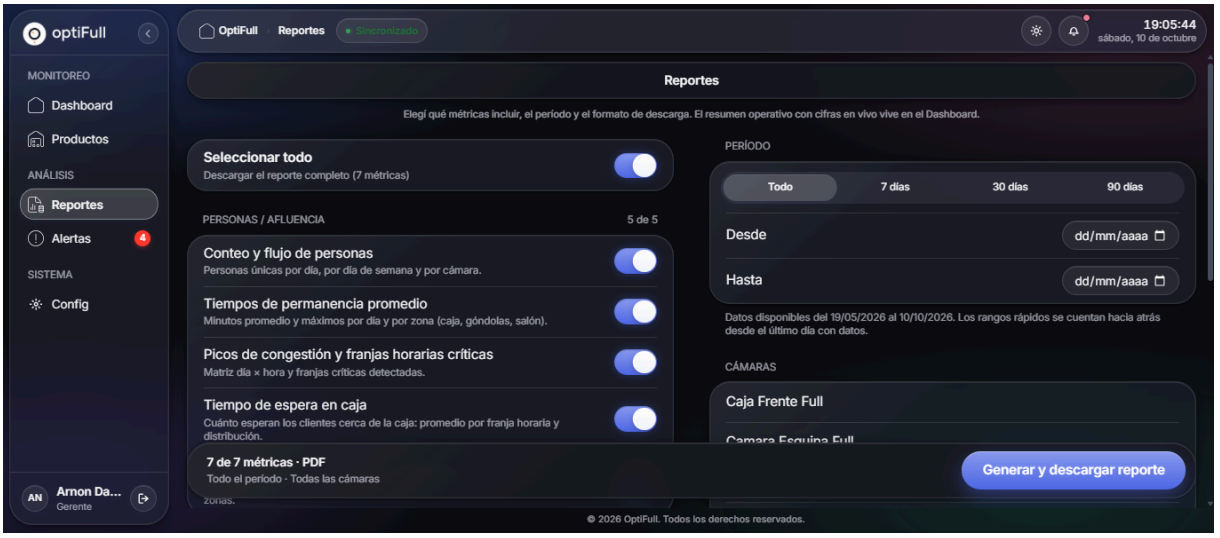


Figura 12: Configuración de un reporte: selección de métricas, período, cámaras y formato de exportación.
Fuente: elaboración propia.

Configuración

Reúne las preferencias de visualización del sistema, entre ellas la apariencia de la interfaz (modo claro, oscuro o según la configuración del sistema operativo). Las restantes opciones de configuración (umbrales de alertas, cámaras, canales de notificación y gestión de usuarios) se presentan en esta versión como un prototipo de interfaz para su desarrollo futuro.

Diagramas

Con el fin de representar la estructura del sistema y la colaboración entre sus componentes, se elaboraron diagramas basados en el Lenguaje Unificado de Modelado (UML). Todos ellos fueron construidos a partir del código fuente del sistema, de modo que reflejan la implementación efectivamente realizada y no un modelo idealizado. Se presentan:

- un diagrama de casos de uso;
- dos diagramas de clases, uno por cada proceso de análisis;
- tres diagramas de secuencia, correspondientes a los flujos más relevantes;
- un diagrama entidad-relación del modelo de datos.

Diagrama de casos de uso

El diagrama de casos de uso sintetiza las interacciones entre los actores identificados en el Alcance Funcional y el sistema. Como se observa en la Figura 13, el administrador accede a la totalidad de las funcionalidades de consulta y análisis. El usuario operativo, en cambio, interactúa únicamente con los casos vinculados a la atención de alertas y a la confirmación de productos en caja. El sistema de análisis figura como un actor automático, responsable de la detección y el seguimiento de personas, la clasificación de las visitas y el reconocimiento de productos. Las relaciones de inclusión expresan los comportamientos que siempre forman parte de otro caso: toda confirmación de un producto implica el descuento del stock. Las relaciones de extensión representan comportamientos opcionales, como la visualización de la evidencia de una alerta o la carga manual de un producto no reconocido.

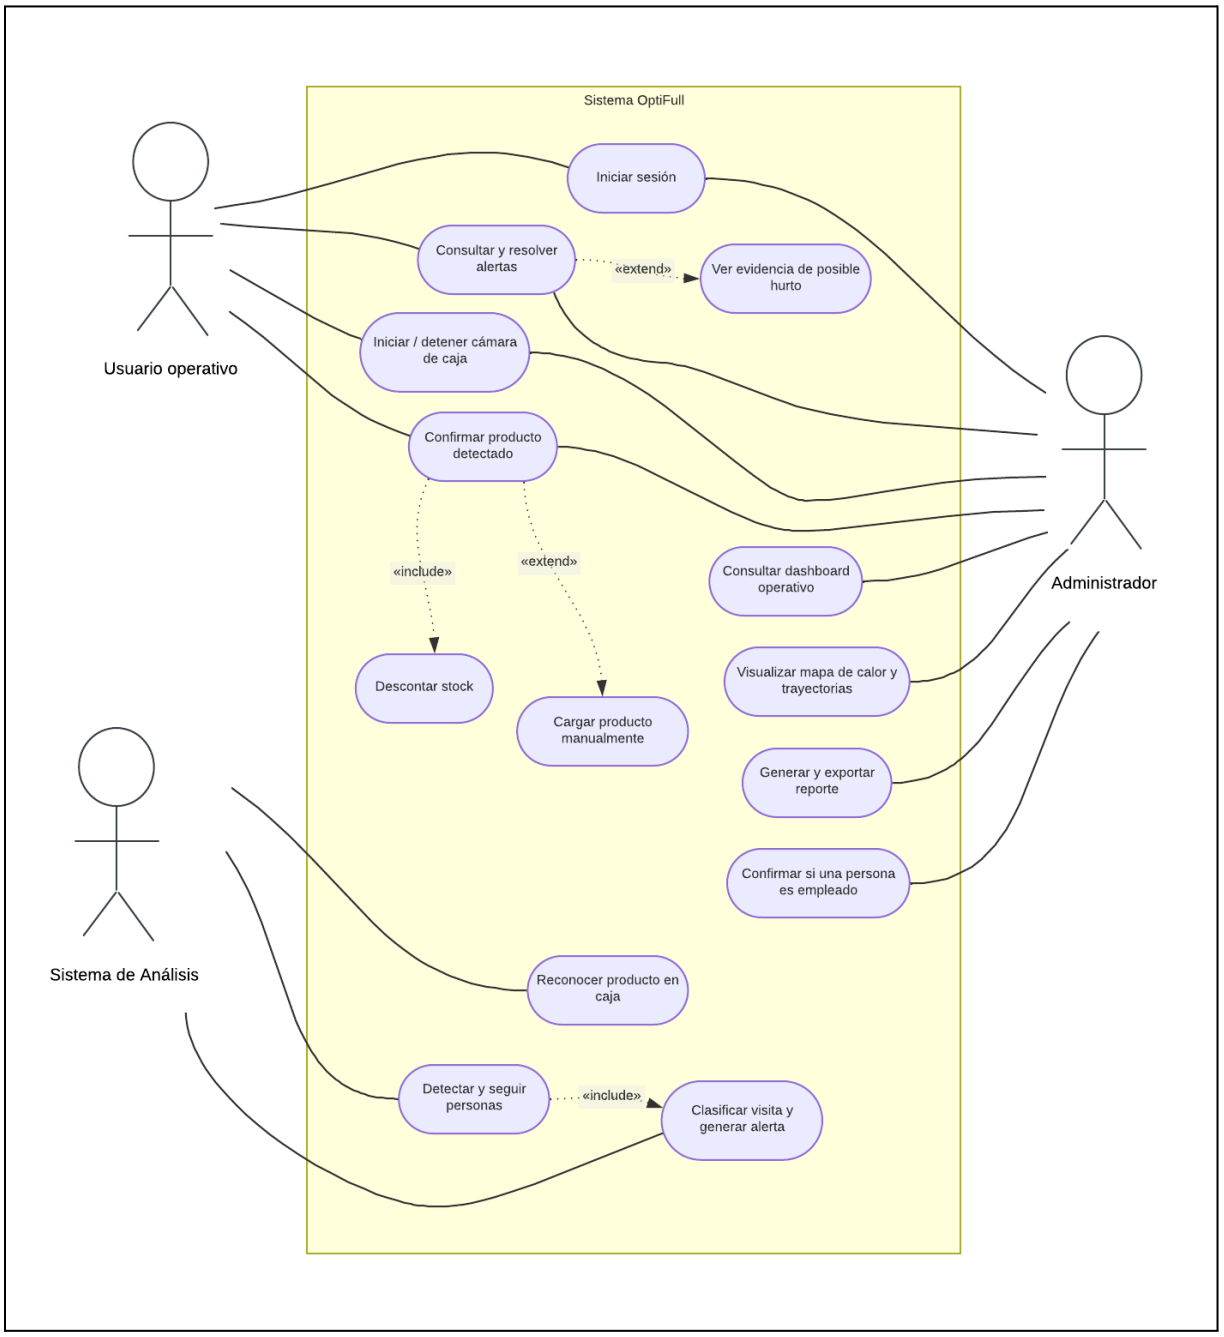


Figura 13: Diagrama de casos de uso del sistema OptiFull.
Fuente: elaboración propia.

Diagrama de clases del pipeline de video

El pipeline de análisis del salón se estructura en torno a la clase PersonTracker, que mantiene la identidad estable de cada persona a lo largo del video. Como se observa en la Figura 14, esta clase se relaciona con los demás componentes de cuatro maneras:

- **Fuentes de video:** las fuentes se modelan mediante la clase abstracta VideoSource, especializada en tres implementaciones: archivos de video, cámaras RTSP o

webcams, y captura de pantalla. De este modo, el resto del pipeline procesa los fotogramas sin depender de su origen.

- **Reidentificación:** ante una identidad que no puede resolverse con las heurísticas locales, PersonTracker delega la reidentificación en un proveedor de visión en la nube. Los tres proveedores implementados (ClaudeReID, GeminiReID y GroqReID) exponen los mismos métodos, por lo que resultan intercambiables. El diagrama representa este contrato común como la interfaz ProveedorReID. En el código, esta interfaz es implícita: se trata de un contrato por convención de métodos y no de una clase abstracta declarada.
- **Persistencia:** PersonTracker no accede directamente a la base de datos, sino que notifica los acontecimientos relevantes (nueva persona, visita cerrada) mediante funciones de retorno (callbacks) que la clase Persistencia transforma en registros.
- **Mapas de calor, clasificación y evidencia:**
    - HeatmapBuilder acumula la densidad de circulación.
    - El módulo eventos clasifica cada visita finalizada.
    - GrabadorEvidencia conserva en memoria los últimos segundos de video, con el fin de armar la evidencia de las alertas.

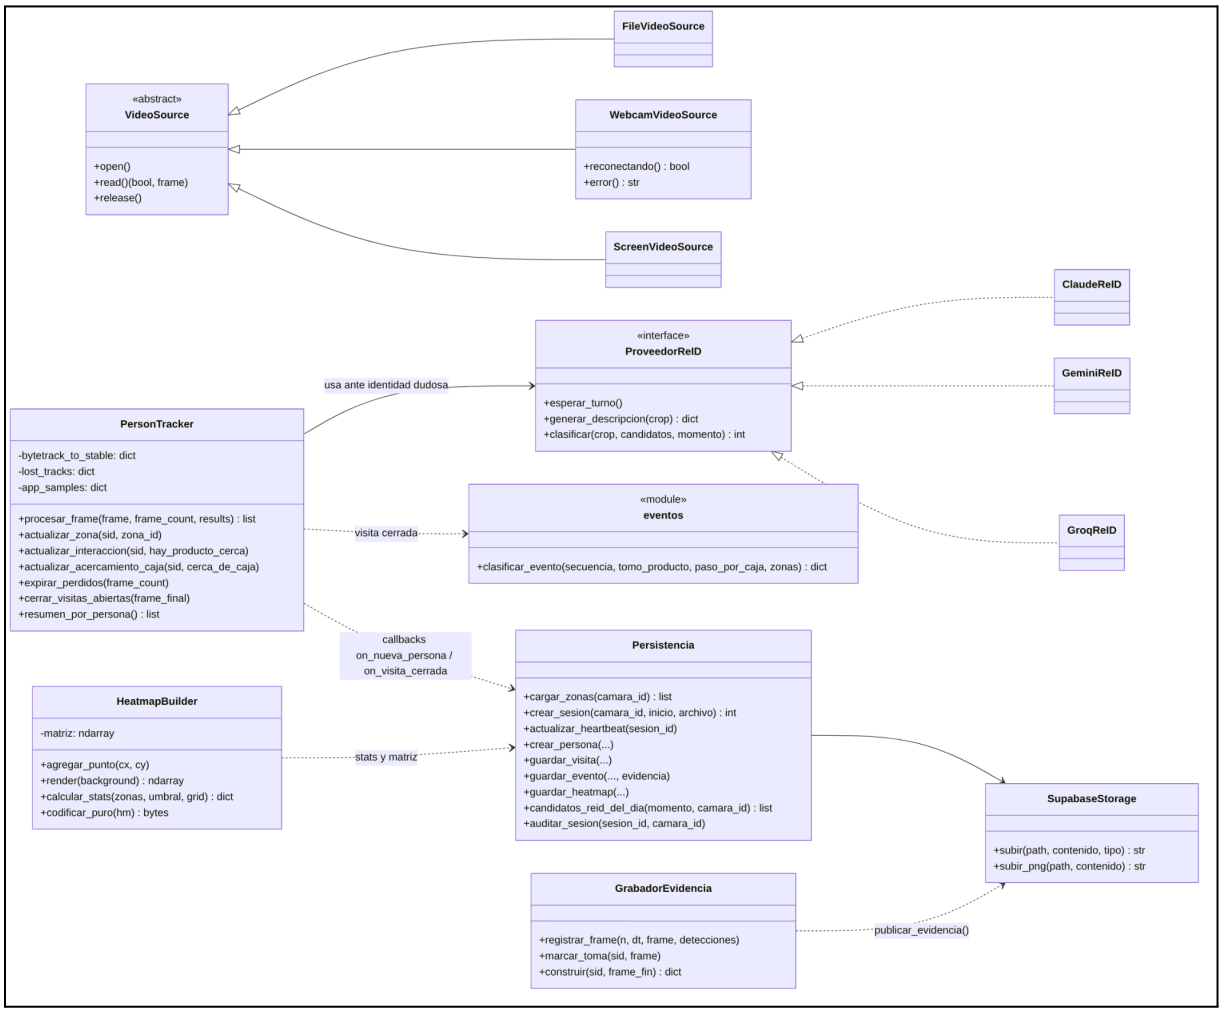


Figura 14: Diagrama de clases del pipeline de análisis de video del salón.
Fuente: elaboración propia.

Diagrama de clases del pipeline de caja

El pipeline de reconocimiento de productos se organiza como una cadena de componentes coordinados por la clase CheckoutOrchestrator. Como se observa en la Figura 15, el orquestador se compone de cinco agentes con responsabilidades únicas:

- **CaptureAgent:** obtención de fotogramas.
- **MotionAgent:** detección de escena estable y nueva.
- **VisionAgent:** extracción de los datos del producto mediante el modelo Claude Haiku 4.5.
- **MatchingAgent:** búsqueda del producto en el catálogo.
- **StockAgent:** descuento del stock y registro de la transacción.

La interacción con el cajero se abstrae mediante la interfaz InterfazCajera, que admite dos implementaciones intercambiables. CashierInterfaceAgent opera por consola y

se utilizó en las pruebas locales. DbCashierInterfaceAgent opera a través de la tabla caja_estado de la base de datos y permite resolver las decisiones desde el navegador. Al igual que en el pipeline de video, la interfaz se representa de forma explícita en el diagrama, aunque en el código ambas clases comparten el mismo contrato de métodos sin una clase base declarada.

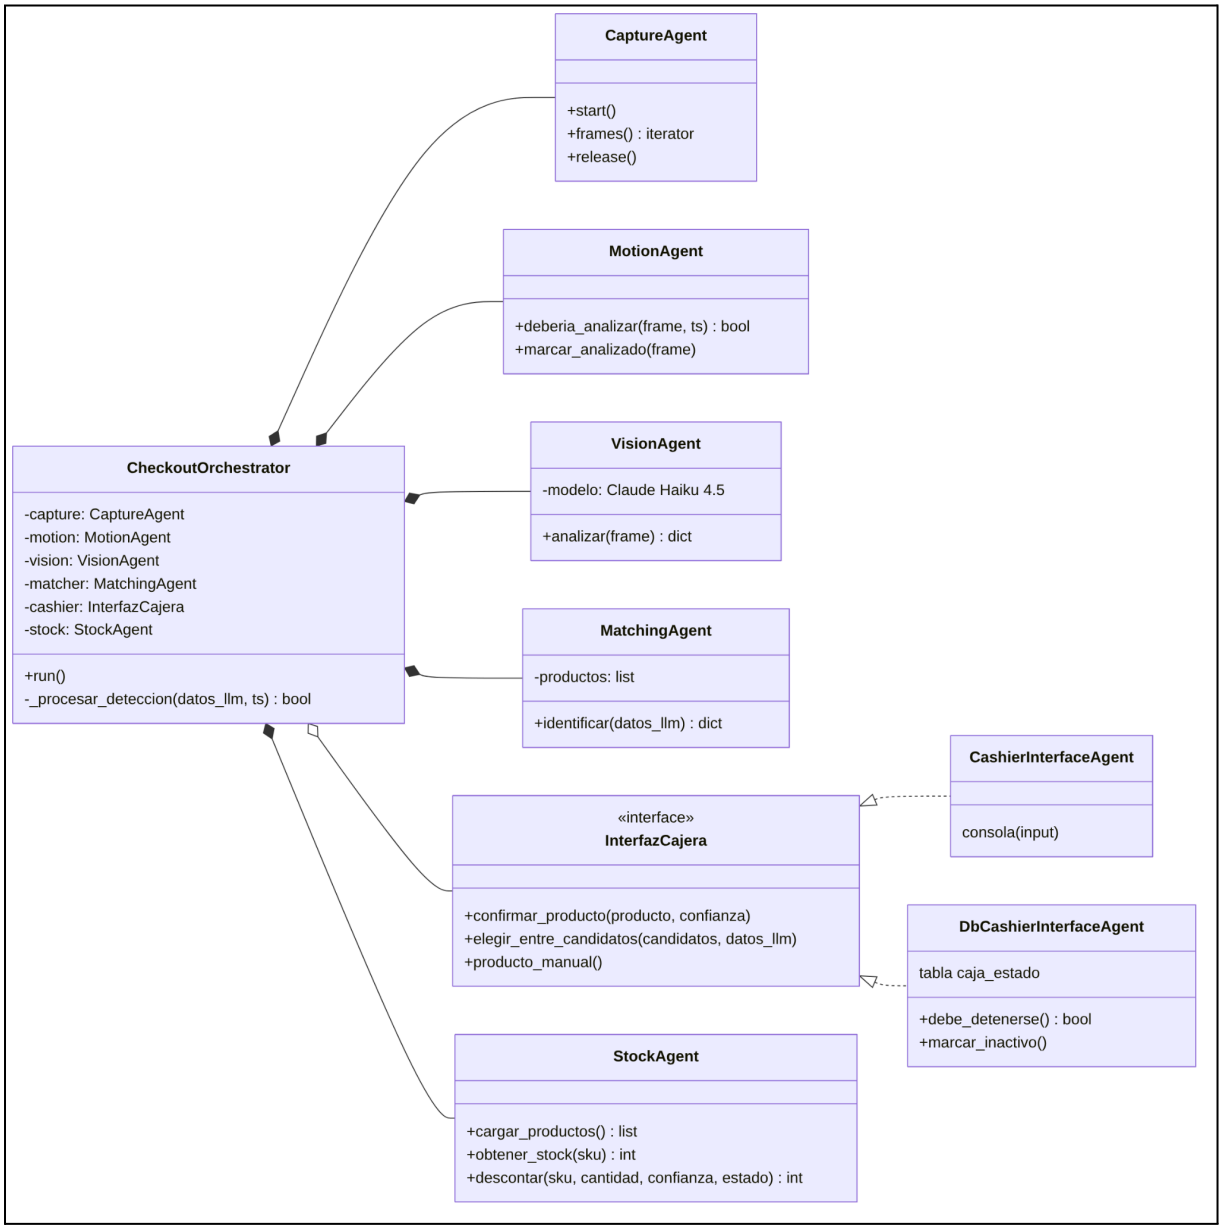


Figura 15: Diagrama de clases del pipeline de reconocimiento de productos en caja.
Fuente: elaboración propia.

Diagrama de secuencia: detección de posible hurto

Este diagrama describe el flujo completo desde la captura del video hasta la presentación de la alerta al personal. Como se observa en la Figura 16, el proceso se divide

en tres etapas:

1. **Procesamiento de cada fotograma:** la detección de YOLOv8 y ByteTrack entrega cajas delimitadoras con identificadores de corto plazo, que PersonTracker resuelve contra una identidad estable. El proveedor de reidentificación en la nube se invoca solo cuando la posición y la apariencia no alcanzan para determinar la identidad. En cada fotograma se actualizan la zona de la persona, su interacción con productos y su proximidad a la caja.
2. **Cierre de la visita:** cuando la persona deja de ser visible, la función clasificar_evento determina el resultado de la visita en forma determinista. Si el resultado es posible hurto, se construye la evidencia y se registran el evento y la alerta en la base de datos. La subida de la evidencia al almacenamiento se realiza en un hilo independiente, para no demorar el análisis.
3. **Consulta desde la interfaz:** el frontend consulta las alertas cada 20 segundos y presenta la nueva alerta junto con su evidencia.

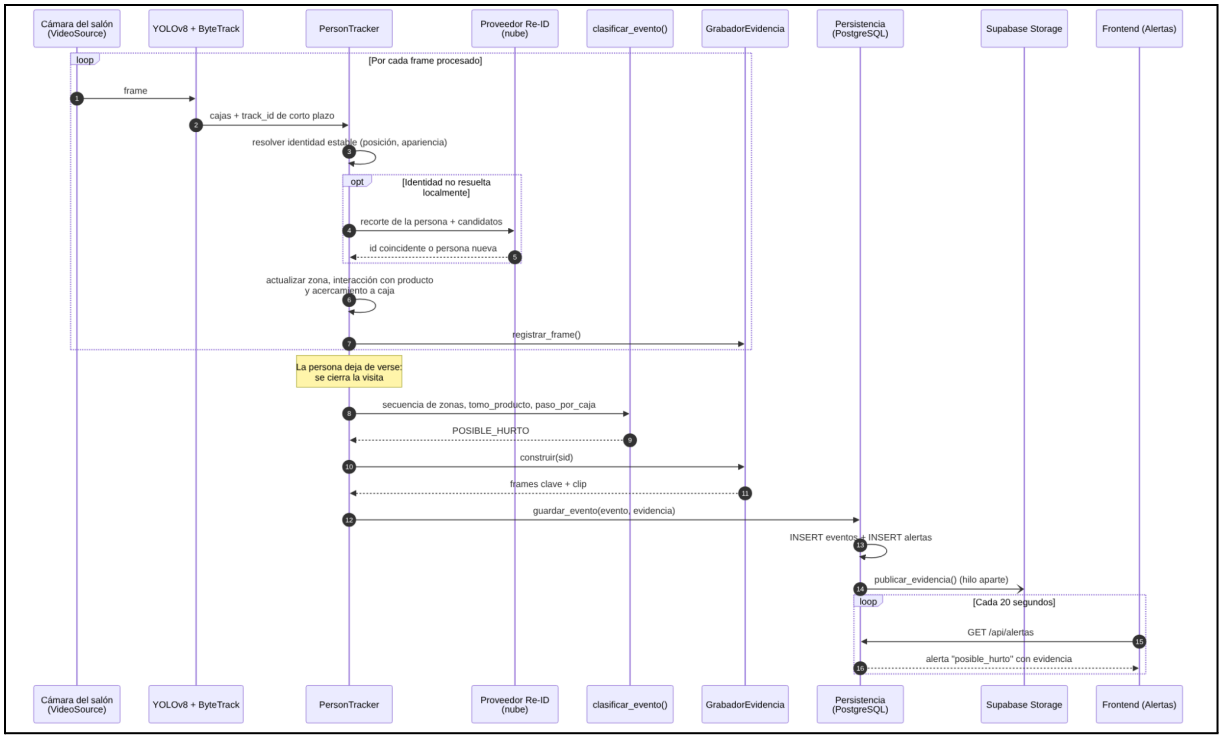


Figura 16: Diagrama de secuencia de la detección de un posible hurto.
Fuente: elaboración propia.

Diagrama de secuencia: reconocimiento de producto en caja

Este diagrama muestra la interacción entre el cajero, la interfaz web y el pipeline de caja. Como se observa en la Figura 17, el reconocimiento se inicia desde el navegador: el

servidor web lanza el pipeline como un proceso independiente. Por cada fotograma, MotionAgent determina si la escena se encuentra estable y difiere de la última analizada. El modelo de lenguaje se invoca únicamente cuando se cumplen ambas condiciones, lo que reduce el costo y la latencia del sistema. El resultado del reconocimiento se escribe como una decisión pendiente en la tabla caja_estado, que la interfaz consulta periódicamente. La respuesta del cajero sigue el camino inverso, y solo una vez recibida se descuenta el stock y se registra la transacción. De este modo, el servidor web y el pipeline se coordinan exclusivamente a través de la base de datos, sin comunicación directa entre procesos.

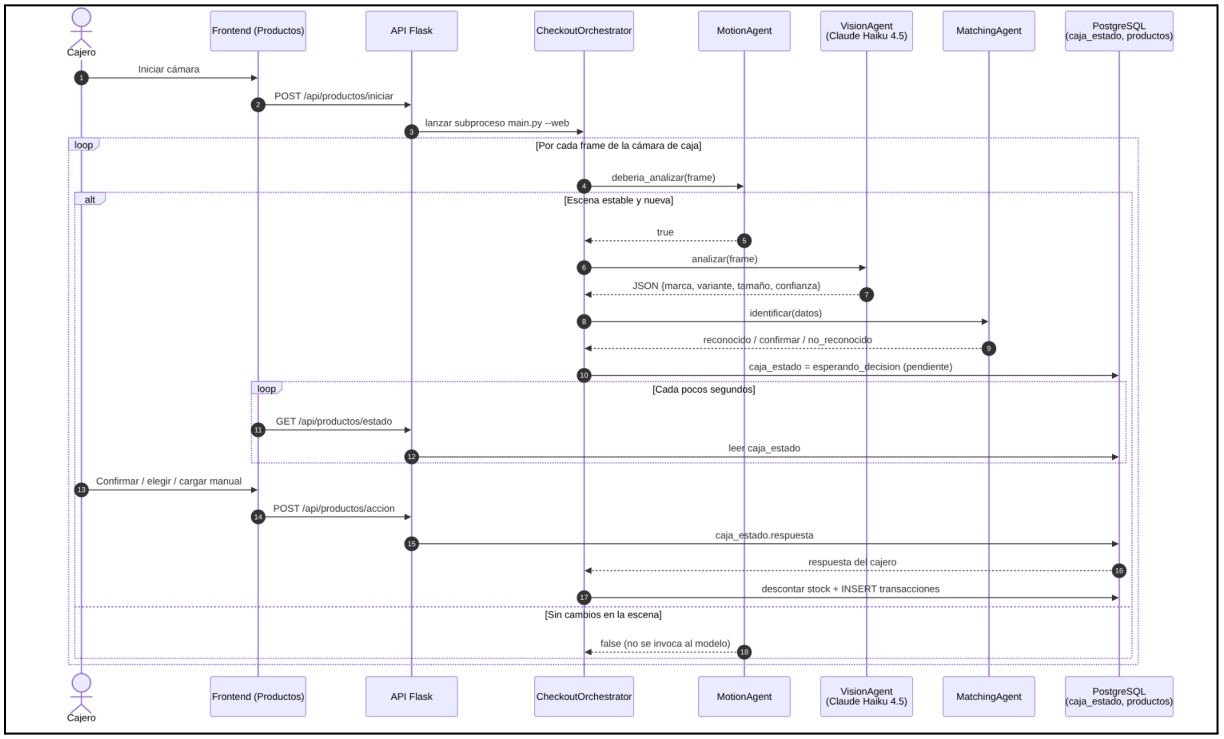


Figura 17: Diagrama de secuencia del reconocimiento de un producto en caja.
Fuente: elaboración propia.

Diagrama de secuencia: inicio de sesión

Como se observa en la Figura 18, el proceso de autenticación contempla cuatro respuestas posibles:

- **Campos incompletos:** error con el detalle de cada campo.
- **Cuenta bloqueada:** el bloqueo se produce tras una serie de intentos fallidos consecutivos.
- **Credenciales válidas:** se devuelven el nombre y el rol del usuario, con los que la interfaz dirige al usuario a su sección inicial.
- **Credenciales inválidas:** se devuelve un mensaje genérico.

La contraseña nunca se compara en texto plano, sino contra su valor cifrado mediante una función de hash almacenado en la base de datos.

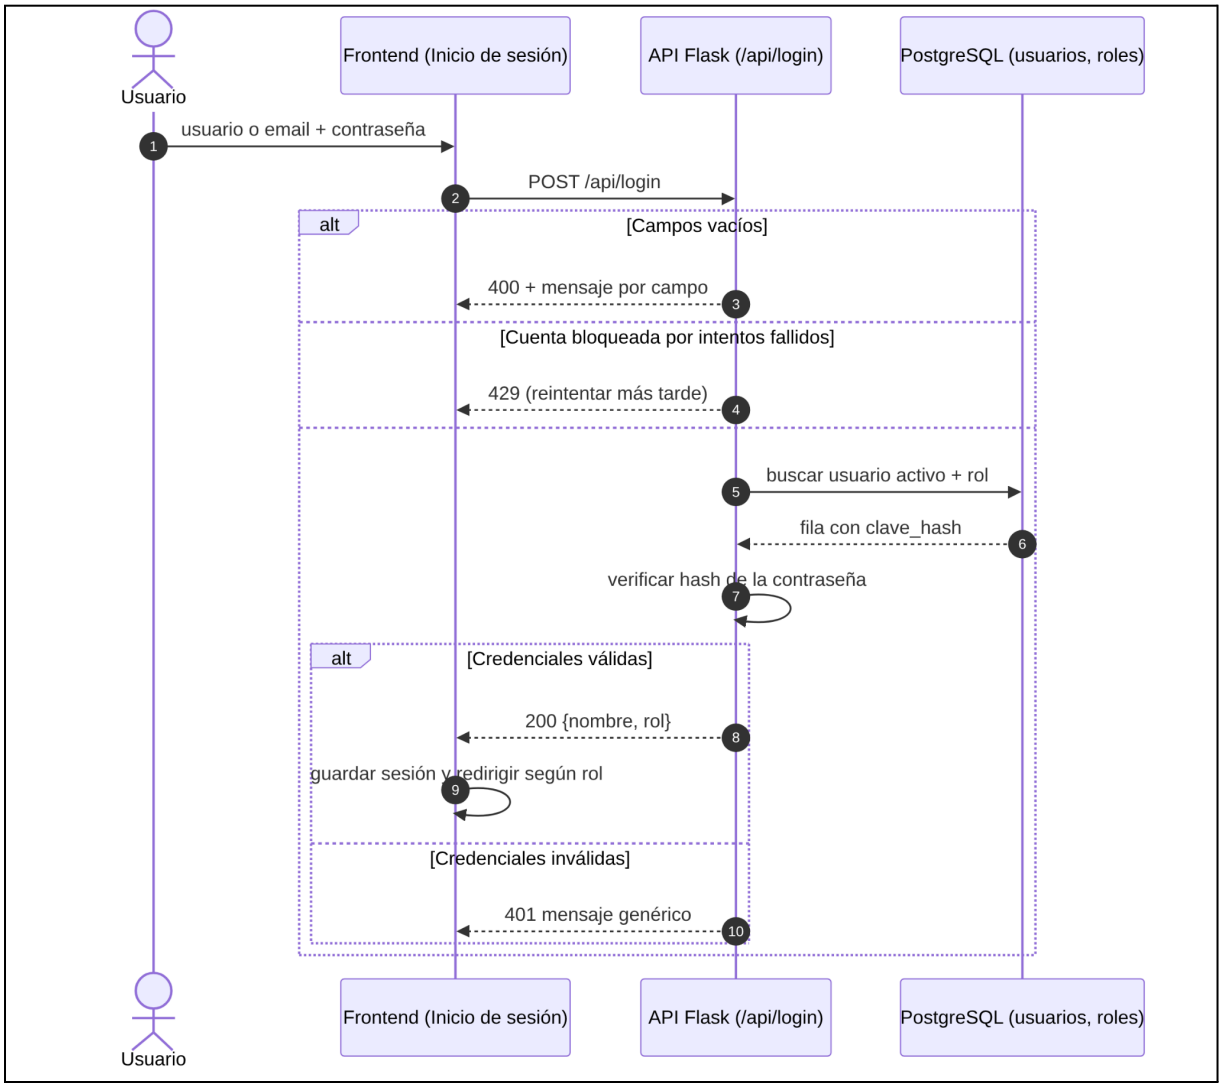


Figura 18: Diagrama de secuencia del inicio de sesión.
Fuente: elaboración propia.

Modelo de datos

Dado que la base de datos constituye el único punto de integración entre los módulos del sistema, su estructura resulta central para el diseño. Como se observa en la Figura 19, el modelo se organiza en cuatro grupos de entidades:

- **Análisis de video:** cámaras, sesiones de video, zonas, personas, trayectorias, visitas, eventos, alertas y mapas de calor.
- **Caja:** productos y transacciones.
- **Control de acceso:** usuarios, roles y sucursales.
- **Identificación de empleados:** la tabla de empleados.

La relación de la tabla personas consigo misma, a través del campo cliente_id, permite unificar bajo una misma identidad las detecciones de una persona en distintas cámaras o sesiones, como resultado del proceso de reidentificación. La tabla caja_estado no figura en el diagrama porque no se relaciona con otras entidades: contiene un único registro que actúa como canal de comunicación entre la interfaz web y el pipeline de caja.

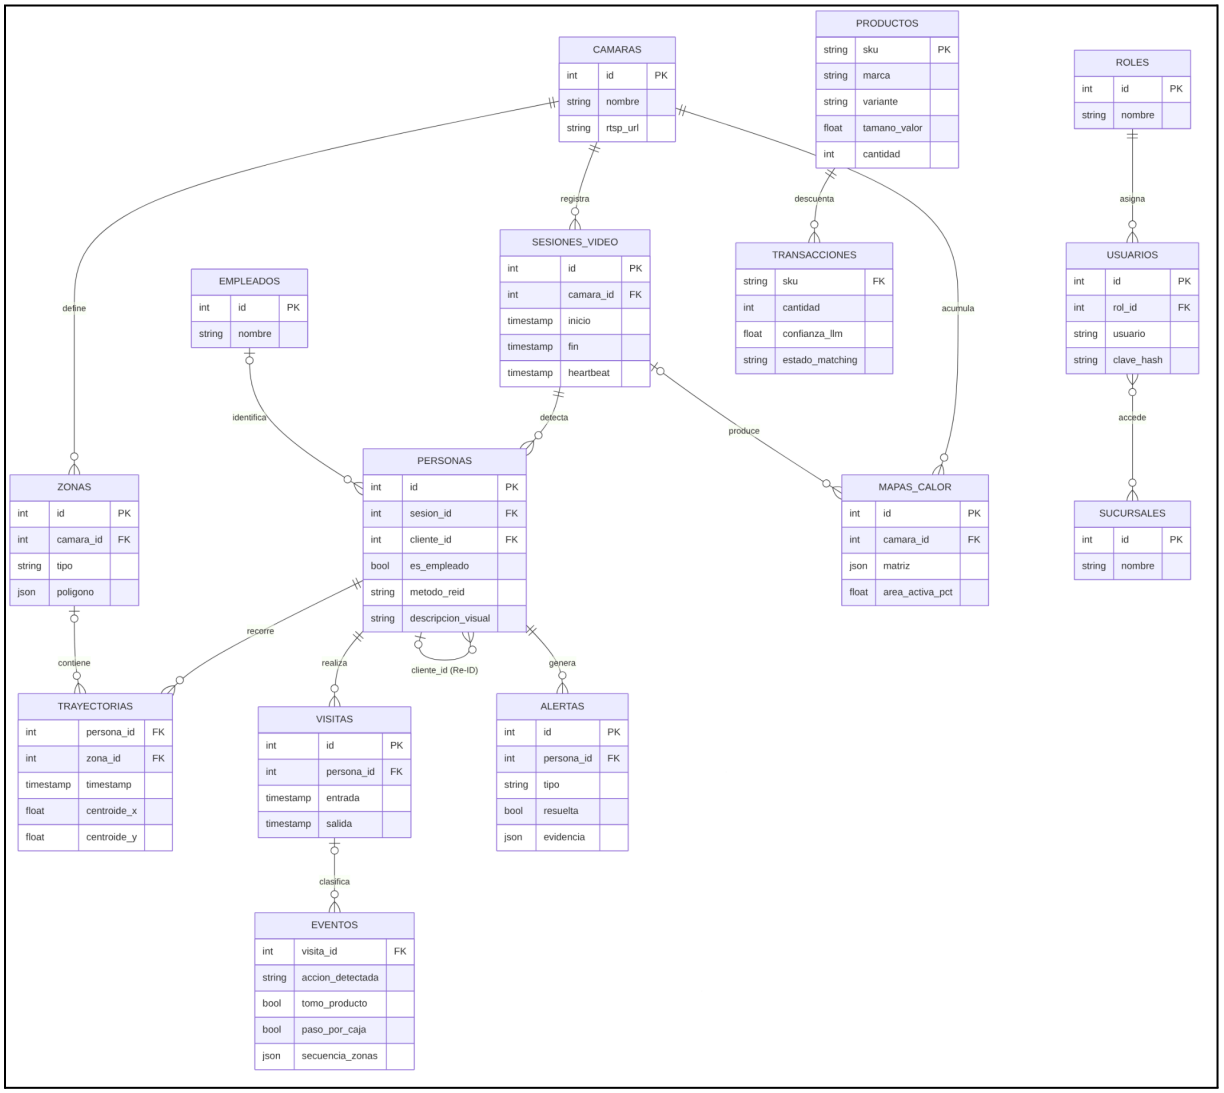


Figura 19: Diagrama entidad-relación simplificado del modelo de datos.

Fuente: elaboración propia

Arquitectura

OptiFull adopta una arquitectura cliente-servidor organizada en capas. Su rasgo distintivo es que los procesos de análisis se encuentran desacoplados entre sí: el pipeline de video, el pipeline de caja y el servidor web no se comunican por invocación directa ni por mensajería, sino exclusivamente a través de una base de datos compartida. Cada proceso escribe sus resultados en la base y los demás los leen desde allí. Esta decisión permitió desarrollar, calibrar, reiniciar y desplegar cada componente de forma independiente (RNF-03), de modo que la falla o la indisponibilidad de uno no afecta al resto. Por ejemplo, el agotamiento de la cuota de un proveedor de inteligencia artificial no impide que el tablero web continúe mostrando la información ya almacenada.

Como se observa en la Figura 20, el sistema se organiza en cuatro capas.

1. Capa de origen de datos (tienda)

Comprende los dispositivos ubicados físicamente en el establecimiento, que generan el video a analizar. Se distinguen dos fuentes con características técnicas diferentes:

- **Cámaras del salón:** las cámaras existentes se conectan al grabador Hikvision (NVR), que expone cada canal mediante el protocolo RTSP. Dado que el grabador solo es accesible desde la red local de la tienda, se incorporó un nodo de captura dedicado: una tableta Microsoft Surface Pro 3 con Ubuntu, conectada por cable a esa red. El nodo ejecuta dos servicios:
    - **MediaMTX:** retransmite el flujo secundario (substream) de cada cámara y mantiene una única conexión con el grabador, aunque varios equipos consuman el mismo flujo.
    - **Tailscale:** establece un túnel cifrado basado en WireGuard, a través del cual los equipos de análisis acceden a esos flujos desde fuera del establecimiento, sin exponer el grabador a internet ni abrir puertos en el router (RNF-05).
- Ambos servicios se configuraron para iniciarse automáticamente con el sistema operativo, lo que permite la operación desatendida del nodo (RNF-06).
- **Cámara de caja**: dado que el circuito existente no cuenta con una cámara orientada al mostrador con la resolución suficiente para leer los envases de los productos, se utilizó un iPhone ubicado sobre el mostrador. El dispositivo ejecuta la aplicación IP Camera Lite, que lo convierte en una cámara IP y transmite su imagen en formato MJPEG por HTTP a través de la red Wi-Fi local. El video es recibido por el puesto de caja, un equipo Mac que ejecuta [aplicación macOS]. Esta solución evitó adquirir hardware adicional y permite reubicar la

cámara con facilidad durante la calibración.

2. Capa de captura y análisis

Está formada por dos procesos Python independientes, que concentran todo el cómputo intensivo del sistema:

- **Pipeline de video** (deteccion/):
  - Recibe los flujos RTSP a través del túnel o, alternativamente, procesa grabaciones exportadas del NVR.
  - Ejecuta la detección de personas con YOLOv8 y el seguimiento con ByteTrack.
  - Resuelve la identidad estable de cada persona, asigna zonas, clasifica las visitas y construye los mapas de calor.
  - Invoca los servicios de reidentificación en la nube solo cuando las heurísticas locales no alcanzan.

- **Pipeline de caja** (deteccion_productos/):
  - Se ejecuta en el puesto de caja, ya que debe acceder a la cámara del iPhone dentro de la red local.
  - Su arranque y detención se controlan desde la interfaz web: el servidor lo lanza como un subproceso.
  - Invoca el modelo Claude Haiku 4.5 únicamente cuando la escena del mostrador está estable y difiere de la última analizada.

3. Capa de persistencia y servicios en la nube

Supabase provee la base de datos PostgreSQL, que constituye la única fuente de verdad del sistema, y el almacenamiento de objetos para las imágenes de los mapas de calor y la evidencia de las alertas. Además de almacenar los datos, la base cumple una función de integración. La tabla caja_estado, en particular, actúa como canal de comunicación entre la interfaz web y el pipeline de caja: el pipeline escribe allí la decisión pendiente y la interfaz devuelve la respuesta del cajero.

En esta capa se ubican también las APIs de inteligencia artificial multimodal (Anthropic Claude, Google Gemini y Groq). Su invocación se limita a tareas puntuales y se controla mediante intervalos mínimos entre llamadas, con el fin de acotar el costo operativo (RNF-02).

4. Capa de presentación

Comprende la API REST desarrollada en Flask y la aplicación web en React. La API no

ejecuta lógica de visión por computadora: se limita a consultar y agregar la información ya persistida por los pipelines. Esta separación estricta entre el cómputo pesado y el servicio web permite que el servidor responda con baja latencia y funcione en una instancia de recursos reducidos.

La aplicación se empaqueta en una imagen Docker que incluye la API y la interfaz ya compilada, y se despliega en la plataforma Render en dos entornos, Calidad (QA) y Producción. El despliegue lo dispara un pipeline de integración continua en GitHub Actions. Este pipeline ejecuta las siguientes etapas:

1. compila el backend;
2. ejecuta las pruebas unitarias;
3. verifica el formato del código del frontend y lo compila;
4. comprueba la conexión con la base de datos;
5. levanta el sistema completo en un contenedor para ejecutar las pruebas de integración.

Solo si todas las etapas resultan exitosas, el pipeline despliega ese mismo commit. De este modo, los entornos de calidad y de producción ejecutan siempre una versión ya validada.

Los usuarios acceden al sistema desde cualquier navegador a través de HTTPS. La única excepción es la pantalla de Productos durante la operación de caja: dado que debe mostrar el video en vivo del iPhone y controlar el pipeline local, se utiliza desde el puesto de caja dentro de la red del establecimiento. Por razones de seguridad, el servidor solo acepta retransmitir cámaras ubicadas en direcciones de red privadas.

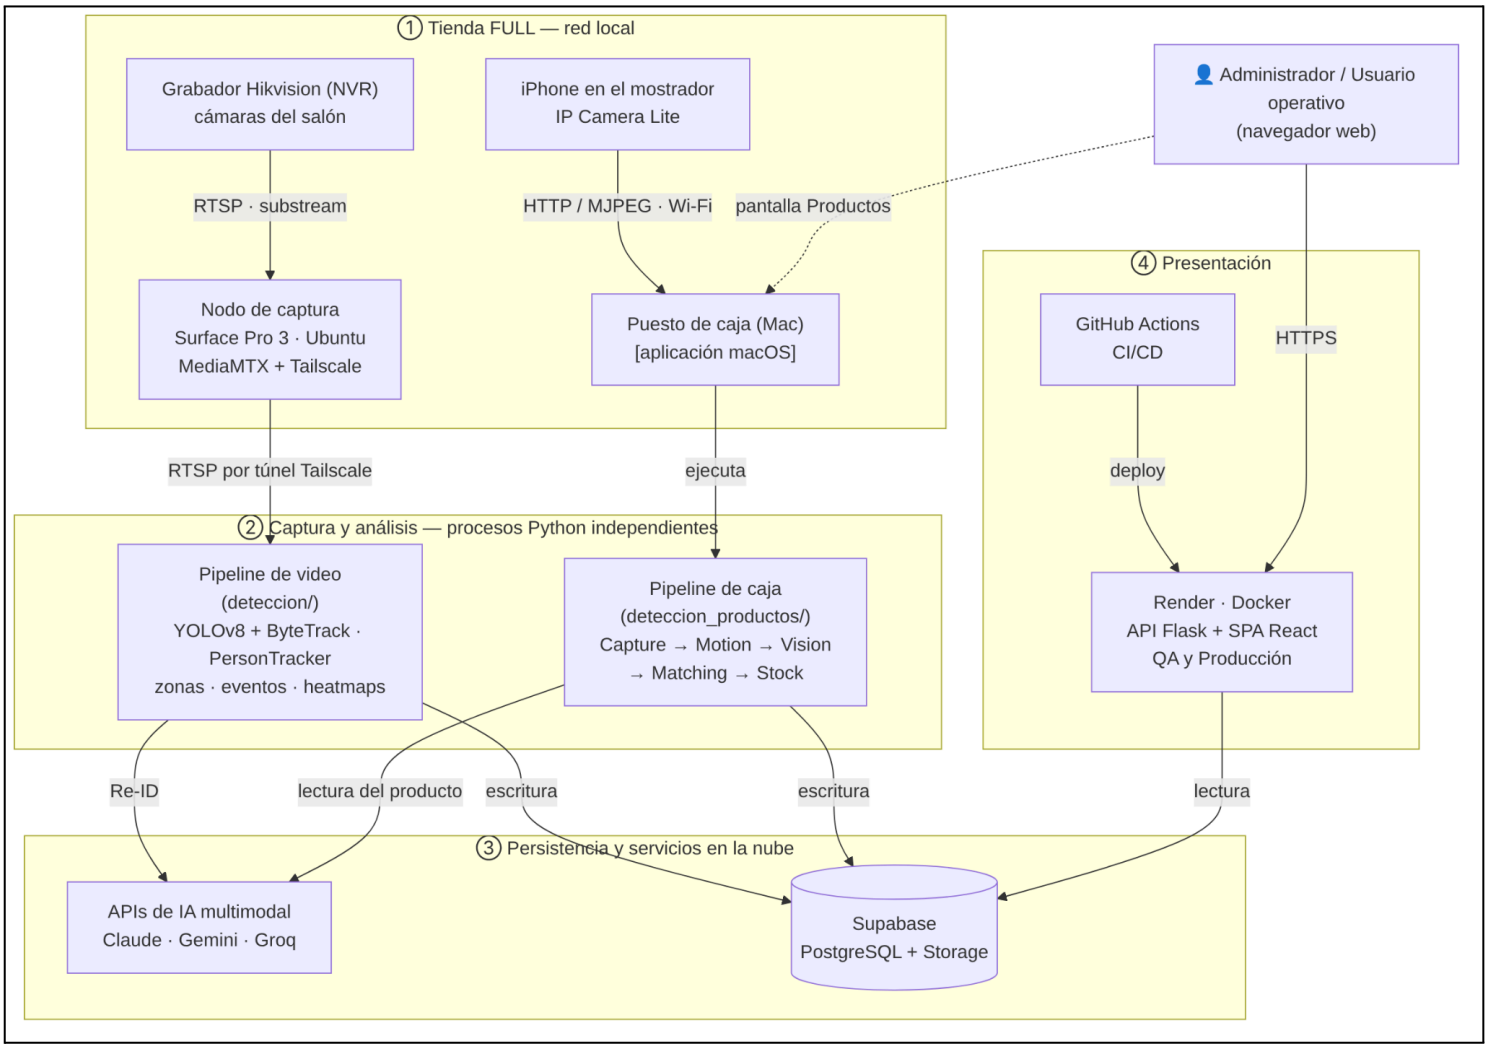


Figura 20: Arquitectura general del sistema OptiFull: capas, componentes e infraestructura. Fuente: elaboración propia.

Patrones de diseño

En el desarrollo de OptiFull se aplicaron patrones de diseño, es decir, soluciones reconocidas y reutilizables a problemas recurrentes en la construcción de software (Gamma et al., 1994). Su adopción respondió a necesidades concretas del proyecto y no a una elección previa al desarrollo:

- intercambiar proveedores de inteligencia artificial sin modificar el resto del sistema;
- probar los componentes sin depender de una cámara real;
- mantener los módulos desacoplados.

Los patrones se presentan en tres niveles: arquitectónico, de diseño de componentes y de interfaz de usuario. Al final se resumen en la Tabla 6.

Patrones arquitectónicos

- **Cliente-servidor en capas.** Como se describió en el apartado de Arquitectura, el sistema separa el origen de los datos, el análisis, la persistencia y la presentación. Cada capa solo depende de la inmediatamente inferior, lo que permite modificar una sin afectar a las demás.

- **Integración mediante base de datos compartida.** Los pipelines de video y de caja y el servidor web no se importan entre sí ni intercambian mensajes directos: se integran exclusivamente leyendo y escribiendo en la misma base de datos. La tabla caja_estado lleva este enfoque al extremo, ya que funciona como un buzón con un único registro, en el que el pipeline de caja deposita la decisión pendiente y la interfaz web deposita la respuesta del cajero. La principal ventaja de este patrón es la independencia de despliegue y de ciclo de vida de cada proceso. Como contrapartida, la interfaz debe consultar periódicamente la base para detectar novedades (Hohpe & Woolf, 2003).

- **Modelo-Vista-Controlador (MVC) distribuido.** A nivel macro, la separación de responsabilidades responde al patrón MVC, distribuido entre procesos:

    - **Modelo:** el esquema relacional en PostgreSQL y las reglas que lo mantienen consistente.

    - **Controlador:** la API REST en Flask, que recibe las peticiones, consulta y agrega los datos y devuelve respuestas en formato JSON.

    - **Vista:** la aplicación React, que se limita a presentar esa información e invocar acciones.

- A diferencia de una implementación MVC clásica, la vista no comparte memoria con el controlador, sino que se comunica con él a través de HTTP.

Patrones de diseño de componentes

- **Strategy (estrategia).** Se aplica cuando existe una familia de algoritmos intercambiables detrás de un mismo contrato, y es el patrón con mayor presencia en el sistema:

    - *Proveedores de reidentificación:* ClaudeReID, GeminiReID y GroqReID exponen los mismos métodos (generar_descripcion, clasificar, esperar_turno). El proveedor activo se selecciona mediante el parámetro de configuración REID_PROVIDER, sin modificar la clase PersonTracker que los utiliza. Esto permitió cambiar de proveedor cada vez que alguno agotaba su cuota gratuita (`deteccion/reid/`).

    - *Fuentes de video:* la clase abstracta VideoSource define el contrato open, read y release, implementado por FileVideoSource (grabaciones), WebcamVideoSource

(cámaras RTSP y webcams) y ScreenVideoSource (captura de pantalla). El pipeline procesa los fotogramas sin conocer su origen (deteccion/pipeline/video_source.py).

  - *Interfaz con el cajero:* CashierInterfaceAgent (consola) y DbCashierInterfaceAgent (navegador, a través de la base de datos) responden a los mismos métodos. Gracias a ello, el pipeline de caja se desarrolló y probó por consola y luego se integró a la interfaz web sin modificar la lógica del orquestador (`deteccion_productos/agents/`).

  - *Formatos de exportación:* los generadores de reportes en PDF, Excel, CSV y PNG reciben los mismos datos y se seleccionan desde un diccionario según el formato solicitado. Agregar un formato nuevo solo requiere registrar una nueva función (frontend/api/reportes_formatos.py).

- **Pipeline (tubería).** El pipeline de caja encadena cinco etapas con una única responsabilidad cada una: captura, detección de movimiento, visión, matching y descuento de stock. Cada etapa solo se ejecuta si la anterior lo habilita. En particular, VisionAgent, la única etapa que invoca un modelo de lenguaje y la más costosa, solo se ejecuta cuando MotionAgent confirma una escena estable y nueva. El orden de las etapas no es arbitrario: los filtros más económicos se ubican antes que los más costosos.

- **Mediator (mediador).** La clase CheckoutOrchestrator coordina a los cinco agentes del pipeline de caja, que no se conocen entre sí. Cada agente recibe datos del orquestador y le devuelve un resultado, y es el orquestador quien decide el paso siguiente según el estado del matching (reconocido, a confirmar o no reconocido). Esta centralización permitió probar cada agente de forma aislada (deteccion_productos/main.py).

- **Observer (observador) mediante funciones de retorno.** PersonTracker no conoce la base de datos. En su lugar, expone puntos de notificación (on_nueva_persona, on_descripcion, on_visita_cerrada) a los que el programa principal suscribe las operaciones de persistencia, clasificación y generación de evidencia. De este modo, la lógica de seguimiento permanece independiente de lo que se haga con sus resultados y puede ejecutarse en pruebas sin efectos secundarios (deteccion/pipeline/tracking.py).

- **Repository (repositorio).** La clase Persistencia centraliza todo el acceso de escritura del pipeline de video a la base de datos: sesiones, personas, trayectorias, visitas, eventos y mapas de calor. Esto evita que las sentencias SQL queden dispersas en la lógica de detección. Esta clase incorpora además dos comportamientos de resiliencia. Ante una conexión interrumpida, reconecta y reintenta la operación. Si no existe conexión, todos

sus métodos se comportan como operaciones nulas, lo que permite ejecutar el análisis en modo “solo consola” (deteccion/persistencia.py) (Fowler, 2002).

- **Productor-consumidor con búfer de un solo elemento.** En las fuentes de video en vivo, un hilo dedicado lee continuamente la cámara y conserva únicamente el fotograma más reciente, mientras el ciclo principal consume a su propio ritmo. Dado que la inferencia es más lenta que la tasa de la cámara, una cola tradicional acumularía fotogramas atrasados. Con un único espacio sobrescrito, el sistema siempre analiza la imagen más actual y descarta las intermedias. El mismo principio de procesamiento en segundo plano se aplica a la subida de la evidencia de las alertas, que se realiza en un hilo aparte para no demorar el análisis (deteccion/pipeline/video_source.py, deteccion/pipeline/evidencia.py).

- **Regla de decisión determinista en lugar de inteligencia artificial.** La clasificación de cada visita (compra normal, posible hurto o tránsito sin compra) se resuelve con una función pura de Python a partir de tres señales ya calculadas, sin invocar un modelo de lenguaje. Esta decisión de diseño es deliberada. Una vez conocidas la secuencia de zonas, la interacción con un producto y el acercamiento a caja, la clasificación es un problema estructurado y determinista. Invocar un modelo en la nube agregaría latencia, costo y variabilidad sin aportar precisión, en coherencia con las desventajas señaladas en la sección 4.3.6. La inteligencia artificial generativa se reserva para las tareas que realmente requieren interpretar imágenes: la reidentificación y la lectura de productos (deteccion/pipeline/eventos.py).

- **Blueprint (enrutamiento modular).** En la API REST, cada dominio funcional define sus propias rutas en un módulo independiente: estadísticas, reportes, exportación, video, mapas de calor, alertas, productos, inicio de sesión y estado del servicio. Todos se registran sobre un Blueprint común con el prefijo /api. Esta organización evita un archivo de rutas monolítico y facilita localizar cada endpoint (frontend/api/blueprint.py).

Patrones de interfaz de usuario

- **Hooks personalizados.** La obtención de datos se encapsula en funciones reutilizables de React, como useAlertas, useApiStats, useZonasPermanencia y useConversionCompra. Cada una gestiona la petición a la API, el estado de carga y la actualización periódica. Los componentes visuales solo reciben datos ya preparados, lo que separa la lógica de acceso a datos de la presentación.
- **Provider (proveedor de contexto).** Las notificaciones breves de la interfaz se gestionan con un proveedor de contexto (ToastProvider) que envuelve a toda la aplicación. Cualquier componente puede emitir una notificación sin recibirla como parámetro desde

sus componentes superiores.

La Tabla 6 resume los patrones aplicados, el problema que resuelve cada uno y su ubicación en el código.

Patrón	**Problema que resuelve**	**Ubicación**
Cliente-servidor en capas	Separar el análisis, la persistencia y la presentación	Sistema completo
Base de datos compartida	Desacoplar procesos independientes	PostgreSQL / caja_estado
MVC distribuido	Separar datos, lógica de acceso y vista	PostgreSQL / Flask / React
Strategy	Intercambiar proveedores de IA, fuentes de video, interfaces de cajero y formatos de reporte	reid/, video_source.py, agents/, reportes_formatos.py
Pipeline	Ordenar etapas de costo creciente	deteccion_productos/
Mediator	Coordinar agentes que no se conocen entre sí	CheckoutOrchestrator
Observer (funciones de retorno)	Independizar el seguimiento de la persistencia	PersonTracker
Repository	Centralizar el acceso a datos y tolerar fallos de conexión	Persistencia
Productor-consumidor	Analizar siempre el fotograma más reciente	WebcamVideoSource
Regla determinista	Evitar costo y latencia innecesarios	eventos.py
Blueprint	Modularizar las rutas de la API	frontend/api/
Hooks y Provider	Separar datos de presentación en la interfaz	frontend/src/

Tabla 6: Patrones de diseño aplicados en OptiFull.

Fuente: elaboración propia.

Implementación

OptiFull no se implementó como una aplicación monolítica, sino como un conjunto de módulos agrupados en tres procesos independientes: el pipeline de video, el pipeline de caja y la aplicación web (backend y frontend). Estos procesos se comunican exclusivamente a través de la base de datos compartida, sin importar código entre sí. Esta decisión permitió desarrollar, probar y calibrar cada módulo de forma aislada y ensamblarlos gradualmente, sin que un cambio en uno obligara a modificar los demás.

Todos los procesos de análisis se desarrollaron en Python 3.12, y la interfaz web en JavaScript con React. Los parámetros de calibración de cada pipeline (umbrales, intervalos y modelos) se centralizaron en archivos de configuración propios (deteccion/config.py y deteccion_productos/config.py). Gracias a ello, el ajuste del sistema a las condiciones reales de la tienda no requirió modificar el código de los módulos.

A continuación se describen los módulos que componen el sistema, su responsabilidad y su forma de interactuar con el resto.

Módulo 1: Autenticación y control de acceso

Responsabilidad: validar la identidad de los usuarios y restringir las secciones de la interfaz según su rol.

Implementación:

- **Inicio de sesión:** el endpoint /api/login valida las credenciales contra la tabla usuarios. Acepta tanto el nombre de usuario como el correo electrónico, sin distinguir mayúsculas.
- **Almacenamiento de contraseñas:** las contraseñas nunca se almacenan en texto plano, sino como hash generado con las funciones de seguridad de la biblioteca Werkzeug.
- **Mitigación de ataques:** ante un usuario inexistente, una contraseña incorrecta o una cuenta desactivada, el sistema responde con el mismo código y el mismo mensaje. Además, cuando el usuario no existe, se verifica la contraseña contra un hash de relleno, de modo que el tiempo de respuesta tampoco revele qué cuentas existen.
- **Limitación de intentos:** tras cinco intentos fallidos consecutivos, la cuenta se

bloquea durante cinco minutos.

- **Permisos por rol:** en el frontend, el módulo de permisos define qué secciones corresponden a cada rol (administrador o usuario) y cuál es la sección inicial de cada uno. Ante un rol desconocido, se deniega el acceso a todas las secciones. La sesión se conserva en el almacenamiento del navegador, con la opción de recordarla entre visitas.

Módulo 2: Captura de video

Responsabilidad: proveer los fotogramas a analizar, abstrayendo su origen.

Cámaras del salón: el acceso a las cámaras se resolvió mediante el nodo de captura instalado en la tienda, cuya configuración completa se detalla en los Anexos.

- **Retransmisión con MediaMTX:** se define una ruta por cámara que apunta al flujo secundario del grabador Hikvision. Este flujo es de menor resolución y reduce el consumo de ancho de banda. Con la opción de conexión bajo demanda, el video solo se solicita al grabador cuando existe un consumidor.

- **Acceso remoto con Tailscale:** los equipos de análisis acceden a esos flujos a través de la red privada, sin modificar la configuración de red de la estación de servicio.

- **Operación desatendida:** ambos servicios se registraron como servicios del sistema operativo con reinicio automático, y se deshabilitaron la suspensión y la caducidad de las claves del nodo.

Abstracción del origen: dentro del pipeline, el origen del video se abstrae mediante la clase VideoSource y sus implementaciones:

- **FileVideoSource:** procesa grabaciones exportadas del NVR, con duración conocida, y permite el análisis diferido y la calibración repetible sobre un mismo material.

- **WebcamVideoSource:** procesa flujos en vivo (RTSP o cámaras locales). Utiliza un hilo de captura que conserva solo el fotograma más reciente y reconecta automáticamente ante cortes del flujo.

- **ScreenVideoSource:** captura una región de la pantalla. Se utilizó para pruebas con fuentes de video que no exponen un protocolo estándar.

Cámara de caja: la cámara de caja se implementó con un iPhone que ejecuta la aplicación IP Camera Lite, la cual publica la imagen de la cámara como un flujo MJPEG por HTTP dentro de la red Wi-Fi local. Este flujo se recibe en el puesto de caja, un equipo Mac que ejecuta [aplicación macOS]. Dado que la aplicación exige usuario y contraseña, y los navegadores bloquean las imágenes con credenciales incluidas en la dirección, el backend expone el endpoint /api/productos/camara, que retransmite el flujo hacia la interfaz web. Por seguridad, este endpoint solo acepta direcciones de red privadas, con el fin de evitar que el servidor pueda utilizarse para solicitar recursos arbitrarios de internet.

Módulo 3: Detección y seguimiento de personas

Responsabilidad: detectar a las personas en cada fotograma, asignarles una identidad estable a lo largo del tiempo (incluso ante oclusiones, cambios de cámara o reapariciones) y registrar su recorrido.

Detección y seguimiento local: se utiliza la biblioteca Ultralytics con modelos YOLOv8 preentrenados sobre el conjunto de datos COCO (Lin et al., 2014), filtrando únicamente la clase persona. El seguimiento entre fotogramas se resuelve con ByteTrack, mediante un archivo de configuración propio ajustado a este escenario. La variante del modelo se seleccionó según la fuente de video:

- **Grabaciones exportadas:** YOLOv8n (Nano), con un umbral de confianza de 0,7 y el procesamiento de uno de cada cinco fotogramas.
- **Flujos RTSP en vivo:** YOLOv8s (Small), con una resolución de inferencia de 960 píxeles y un umbral de confianza de 0,35. El flujo secundario tiene menor resolución (640 × 360) y las cámaras observan desde un ángulo elevado, por lo que las personas aparecen más pequeñas y requieren un modelo de mayor capacidad. Para acotar el costo de cómputo, se procesan dos fotogramas por segundo.

Clase PersonTracker: los identificadores que asigna ByteTrack se pierden y se regeneran ante oclusiones breves. Por ese motivo, la clase PersonTracker (deteccion/pipeline/tracking.py) los resuelve contra un identificador estable, aplicando criterios en orden creciente de costo:

1. proximidad de la posición entre fotogramas consecutivos;
2. similitud de apariencia, calculada mediante histogramas de color HSV del torso y

comparada con la distancia de Bhattacharyya;

3. reidentificación en la nube, cuando los dos criterios locales no alcanzan.

Además, se exige un mínimo de fotogramas consecutivos para confirmar una nueva persona, lo que descarta como falsos positivos los reflejos y los errores momentáneos del detector.

PersonTracker mantiene también el estado de cada visita: zona actual, interacción con productos y acercamiento a la caja. Cierra una visita solo ante ausencias prolongadas, no ante oclusiones breves.

Reidentificación en la nube: cuando la identidad no puede resolverse localmente, por ejemplo porque la persona pasó de una cámara a otra, se recorta su imagen y se envía a un modelo multimodal. El modelo devuelve un descriptor estructurado con cinco atributos no biométricos: color de la prenda superior, color de la prenda inferior, complexión, cabello y accesorios. Ese descriptor se compara contra los candidatos vistos recientemente por cámaras del mismo sector físico, dentro de una ventana horaria acotada. Para aceptar una coincidencia, se exige que el color de la prenda superior coincida y que se cumpla un mínimo de coincidencias entre los demás atributos, lo que evita fusionar a personas distintas.

Se implementaron tres proveedores intercambiables (Claude, Gemini y Groq), seleccionables por configuración. Cada uno incorpora:

- un limitador de frecuencia de llamadas, con pausas adicionales ante ráfagas de eventos;
- un tratamiento defensivo de la respuesta, que repara JSON truncado y normaliza comillas tipográficas. En el caso de Claude, el esquema de salida se impone desde la propia API, lo que garantiza una respuesta estructurada válida.

Módulo 4: Zonificación y clasificación de comportamiento

Responsabilidad: interpretar el recorrido de cada persona en términos de negocio.

Zonas: se definen como polígonos sobre la imagen de cada cámara, con un tipo asignado (entrada, salida, caja, góndola, depósito u otro), y se cargan desde la base de datos al iniciar el análisis. En cada fotograma se determina la zona en la que se encuentran los pies de cada persona.

Detección de interacción con productos: se utiliza un segundo modelo YOLO que

busca objetos de clases COCO afines a la mercadería de un minimercado, como botellas, vasos y alimentos, en las cercanías de la caja delimitadora de cada persona. La interacción se confirma solo si persiste durante al menos tres fotogramas consecutivos.

Acercamiento a la caja: la zona de caja corresponde al lado del mostrador ocupado por el empleado, por lo que un cliente que paga se acerca a ella, pero rara vez la pisa. Por este motivo, el acercamiento se determina por proximidad al polígono (8 % del ancho de la imagen) y no por inclusión estricta. Además, se exige que la persona permanezca cerca de la zona de caja durante al menos tres segundos consecutivos, lo que permite distinguir a quien se detiene a pagar o a esperar su pedido de quien solo pasa caminando cerca del mostrador. Inicialmente se evaluó exigir la presencia simultánea de otra persona en la zona de caja, pero el criterio se descartó porque, con personal permanente en el mostrador, se cumplía casi siempre y no permitía discriminar.

Clasificación de la visita: al cerrarse cada visita, la función clasificar_evento (deteccion/pipeline/eventos.py) aplica una regla determinista:

- **Compra normal:** la persona se acercó a la caja, con independencia de si se detectó o no la toma de un producto. Este criterio cubre los productos que el cajero entrega directamente en el mostrador y los pedidos de cafetería.
- **Posible hurto:** la persona tomó un producto y se retiró sin acercarse a pagar.
- **Tránsito sin compra:** la persona no realizó ninguna de las dos acciones anteriores.

Como se justificó en Patrones de diseño, esta etapa no invoca modelos de lenguaje.

Módulo 5: Alertas y evidencia

Responsabilidad: notificar al personal los eventos que requieren atención y respaldarlos con evidencia visual.

Registro de la alerta: cuando una visita se clasifica como posible hurto, el evento se registra en la tabla eventos y se crea una alerta asociada en la tabla alertas.

Construcción de la evidencia: en el análisis en vivo no existe un archivo del cual recortar un fragmento. Por ello, la clase GrabadorEvidencia mantiene en memoria los últimos segundos de imágenes y, ante una alerta, arma la evidencia con los fotogramas de dos momentos: cuando la persona tomó el producto y cuando se retiró del local. Cada imagen se rotula con la cámara, la hora y el motivo, y la persona involucrada se señala con un recuadro. Con esos fotogramas se genera además un clip breve mediante FFmpeg. La subida al

almacenamiento se ejecuta en un hilo independiente, para no interrumpir el análisis.

Alertas de posible empleado: el backend genera alertas de este tipo cuando una persona presenta un patrón de permanencia característico del personal. Estas alertas se resuelven desde la interfaz con la confirmación del administrador.

Módulo 6: Mapas de calor

Responsabilidad: construir la representación visual y estadística de la circulación dentro del local.

Acumulación: la clase HeatmapBuilder (deteccion/pipeline/heatmap.py) suma, por cada centroide detectado, un núcleo gaussiano de 60 píxeles de radio sobre una matriz del tamaño del fotograma.

Estadísticas: al finalizar cada sesión se calculan:

- el punto de máxima concentración;
- el porcentaje de área activa, es decir, la proporción de píxeles que supera el 5 % del valor máximo;
- la zona de mayor circulación;
- el nivel de concentración.

Almacenamiento: la matriz se reduce a una grilla de 64 × 64 celdas y se guarda en la base de datos. La imagen resultante se almacena en Supabase Storage y, si este no estuviera disponible, en el disco local.

Mapa acumulado: las grillas de las sesiones sucesivas de una misma cámara se combinan en un mapa acumulado histórico. Además, la API proyecta la circulación sobre el plano del local y la agrega por franja horaria para el reproductor cronológico del Dashboard.

Módulo 7: Persistencia y auditoría

Responsabilidad: aislar el acceso a la base de datos y garantizar la consistencia de los datos ante interrupciones o fuentes múltiples.

Clase Persistencia: centraliza la escritura de sesiones, personas, trayectorias, visitas, eventos y mapas de calor (deteccion/persistencia.py), con dos comportamientos de resiliencia:

- reconecta y reintenta las operaciones ante cortes de conexión;
- se comporta como una operación nula cuando no hay base de datos disponible, lo que permite ejecutar el pipeline en modo de solo consola.

Las trayectorias se escriben en bloques periódicos, en lugar de hacerlo fotograma a fotograma, para reducir la carga sobre la base.

Latido por sesión: se implementó un mecanismo de latido (heartbeat) por sesión, que permite distinguir un análisis realmente interrumpido (por ejemplo, por un corte de energía) de uno que otra máquina está procesando en paralelo contra la misma base. De este modo se evita que un proceso elimine por error la sesión en curso de otro.

Auditoría posterior al análisis: al finalizar cada análisis se ejecuta una auditoría que actúa como red de seguridad sobre las decisiones tomadas en tiempo real:

- recalcula las zonas;
- reclasifica empleados por mayoría de posición en su recorrido;
- fusiona las detecciones de una misma persona realizadas por cámaras del mismo sector casi en el mismo instante;
- une las trayectorias que quedaron divididas por el corte de archivo del grabador entre videos consecutivos.

Complementariamente, un conjunto de scripts de mantenimiento (deteccion/mantenimiento/) permite reprocesar datos ya existentes sin volver a analizar el video original.

Módulo 8: Reconocimiento de productos en caja

Responsabilidad: identificar el producto que el cajero presenta ante la cámara del mostrador y descontar el stock correspondiente, sin fotografiar ni entrenar un modelo por cada producto del catálogo.

Justificación del enfoque: se evaluó entrenar un modelo de detección propio, por ejemplo una variante de YOLO ajustada con imágenes etiquetadas en Roboflow. Este enfoque fue descartado por tres razones:

1. requiere un conjunto de imágenes etiquetadas por cada SKU;
2. debe reentrenarse cada vez que se incorpora un producto o cambia un envase;
3. su desempeño se degrada entre variantes visualmente similares de una misma

marca, que es precisamente el caso más frecuente en la tienda.

En su lugar, se optó por un modelo multimodal capaz de leer el envase sin entrenamiento previo (zero-shot) y por un algoritmo de coincidencia contra el catálogo. Con este enfoque, incorporar un producto nuevo solo requiere darlo de alta en la base de datos.

Etapas del pipeline: el pipeline (deteccion_productos/) encadena cinco componentes coordinados por la clase CheckoutOrchestrator.

- **CaptureAgent:** obtiene fotogramas de la cámara del iPhone, de un flujo RTSP o de un archivo de video, a una tasa de 15 fotogramas por segundo.
- **MotionAgent:** decide cuándo vale la pena invocar al modelo. Evalúa dos condiciones sin utilizar inteligencia artificial:
    - *Estabilidad:* la escena debe permanecer quieta durante al menos 150 milisegundos. Este criterio se mide en tiempo y no en cantidad de fotogramas, para adaptarse a cajeros rápidos y lentos por igual.
    - *Novedad:* la imagen debe diferir de la última analizada en más de 25 niveles de intensidad promedio.

    El análisis se dispara solo cuando ambas condiciones se cumplen. Este filtro es el que hace económicamente viable el enfoque, ya que evita invocar al modelo en cada fotograma.

- **VisionAgent:** reduce la imagen a un máximo de 1024 píxeles por lado y la envía al modelo Claude Haiku 4.5, que devuelve un JSON con la marca, la variante, el tamaño y su nivel de confianza. Para reducir la latencia, la conexión con la API se mantiene abierta entre productos.
- **MatchingAgent:** busca el producto en el catálogo tolerando los errores de lectura del modelo. En lugar de exigir una coincidencia exacta, calcula un puntaje ponderado de 0 a 100: marca 40 %, variante 25 % y tamaño 35 %.
    - La similitud de texto tolera una cantidad absoluta de ediciones según la longitud de la palabra (una, dos o tres letras). Este criterio se prefirió porque un porcentaje de similitud genérico penaliza en exceso los nombres cortos.
    - La similitud de tamaño es proporcional a la diferencia relativa entre el valor leído y el del catálogo, previa normalización de las unidades de peso y volumen.
    - La marca actúa como umbral mínimo de entrada, para que un tamaño coincidente por casualidad no favorezca un producto de otra marca.

    Según el resultado, el producto queda en uno de tres estados:

- *Reconocido:* el mejor candidato supera los 82 puntos y aventaja al segundo por al menos 12.
- *A confirmar:* se presentan entre dos y tres candidatos.
- *No reconocido:* se habilita la carga manual. Si el modelo no detectó ningún producto con claridad, el fotograma simplemente se ignora.

- **StockAgent:** descuenta el stock y registra la transacción con la confianza del modelo y el estado del matching. Esta operación se ejecuta siempre después de la confirmación del cajero: el sistema nunca modifica el inventario de forma automática.

Los componentes se nombran “agentes” por convención, pero solo VisionAgent invoca efectivamente un modelo de lenguaje; los demás son componentes deterministas. Se trata, por lo tanto, de un pipeline modular con una única etapa basada en inteligencia artificial, y no de un sistema multiagente en sentido estricto.

Interacción con el cajero: se definieron dos implementaciones intercambiables. La versión por consola se utilizó en las pruebas locales. La versión web escribe la decisión pendiente en la tabla caja_estado y espera la respuesta que la interfaz registra tras la acción del cajero. Esta tabla admite un único registro y modela tres estados: inactivo, esperando decisión y detener. El estado de detención permite finalizar el pipeline de forma ordenada desde el navegador.

Módulo 9: Backend web y reportes

Responsabilidad: exponer como API REST la información generada por los pipelines y orquestar el pipeline de caja.

Organización: la API se implementó con Flask y se organizó en Blueprints por dominio:

- inicio de sesión;
- estado del servicio;
- estadísticas generales;
- reportes;
- exportación;
- alertas;
- mapas de calor;
- video y seguimiento;
- productos.

Las conexiones a la base de datos se administran mediante un pool, para evitar abrir una

conexión por cada petición.

Reportes: los indicadores se calculan mediante consultas SQL de agregación sobre los datos persistidos:

- tendencia semanal;
- permanencia por día y por zona;
- congestión por día y hora;
- tiempo de espera en caja por franja horaria;
- tasa de conversión de compra;
- personas por zona;
- rotación de productos.

Exportación: el módulo de exportación genera los reportes en PDF, Excel, CSV o PNG, con gráficos producidos con Matplotlib (Hunter, 2007), según las métricas, el período y las cámaras elegidos por el usuario.

Orquestación del pipeline de caja: el módulo de productos expone el ciclo completo de la caja: lanzar el pipeline como subproceso, consultar la decisión pendiente, registrar la acción del cajero, detener el proceso y servir las métricas de matching. Al igual que los pipelines, el backend no importa código de los otros módulos: lee y escribe en la misma base de datos.

Módulo 10: Interfaz web

Responsabilidad: traducir los datos estructurados generados por los módulos anteriores en información comprensible y accionable para el personal de la tienda.

Tecnologías: la interfaz se implementó con React 19 y se compiló con Vite.

Organización: se compone de las páginas descritas en Pantallas (bienvenida, inicio de sesión, Dashboard, Productos, Alertas, Reportes y Configuración) y de componentes reutilizables: la barra lateral, el plano interactivo del local, las tarjetas de indicadores y los gráficos de tendencia. La obtención de datos se encapsula en hooks personalizados que gestionan la petición a la API, el estado de carga y la actualización periódica de cada indicador:

- alertas: cada 20 segundos;
- personas en tienda: cada 5 segundos;
- decisión pendiente de caja: cada 250 milisegundos, para que la confirmación del

cajero resulte inmediata.

Accesibilidad y adaptación: la interfaz ofrece modo claro y oscuro, y se adapta a pantallas de computadora, tableta y teléfono móvil.

Módulo 11: Integración y despliegue continuo

Responsabilidad: garantizar que cada versión publicada del sistema haya sido compilada y probada.

Empaquetado: la aplicación web se empaqueta en una imagen Docker de dos etapas. La primera compila el frontend con Node.js. La segunda instala el backend sobre una imagen liviana de Python y sirve ambos con el servidor Gunicorn, ejecutado con un usuario sin privilegios de administrador.

Pipeline de integración continua: el repositorio cuenta con un pipeline de GitHub Actions que se ejecuta en cada cambio y comprende cuatro etapas:

1. compilación del backend, ejecución de las pruebas unitarias con medición de cobertura, análisis estático y compilación del frontend;
2. verificación de la base de datos y ejecución del sistema completo en un contenedor para las pruebas de integración;
3. despliegue en el entorno de calidad (QA);
4. ejecución de las pruebas de integración sobre el entorno de QA;
5. despliegue en producción y prueba básica de funcionamiento (*smoke test*).

El detalle de cada etapa se presenta en el Anexo J.

El despliegue se dispara desde el pipeline con el identificador exacto del commit validado, de modo que ambos entornos ejecutan siempre la misma versión ya probada.

Estrategia de ensamblado incremental

El sistema no se construyó de una sola vez, sino en etapas que se integraron progresivamente, validando cada una antes de incorporar la siguiente:

1. **Detección y seguimiento local** sobre grabaciones exportadas del NVR, en modo consola y sin persistencia, para validar la calidad del seguimiento y la resolución de identidades por posición y apariencia.
2. **Capa de persistencia**, con el comportamiento de operación nula sin conexión, que

permitió continuar desarrollando el resto del pipeline aun sin credenciales de base de datos configuradas.

3. **Reidentificación en la nube**, incorporada como recurso opcional y activable por configuración, una vez comprobado que el seguimiento local no alcanzaba para recorridos largos ni cambios de cámara.
4. **Zonificación, clasificación de visitas y alertas**, montadas sobre la información de posición ya disponible, sin modificar los módulos anteriores.
5. **Mapas de calor y auditoría posterior**, como pasos finales del pipeline de video, una vez estabilizado el resto.
6. **Pipeline de caja**, desarrollado en paralelo y de forma completamente independiente. Se validó primero con pruebas sin conexión, que simulan las respuestas del modelo y generan fotogramas sintéticos sin gastar cuota de la API, luego con video grabado y finalmente con el iPhone en el mostrador. Se integró a la aplicación web mediante la tabla caja_estado.
7. **Backend, frontend y autenticación**, construidos como consumidores de la información ya generada. Al apoyarse solo en la base de datos, pudieron desarrollarse contra datos reales sin coordinarse con el código de los pipelines.
8. **Infraestructura de captura remota**, que reemplazó la exportación manual de grabaciones por el acceso en vivo a las cámaras a través del nodo instalado en la tienda.
9. **Integración y despliegue continuo**, que automatizó la verificación y la publicación de cada nueva versión.

Esta estrategia, basada en módulos desacoplados, comunicados únicamente a través de un esquema de base de datos compartido y probados de forma aislada, permitió que el desarrollo avanzara sin que la inestabilidad o el costo de un componente bloqueara el avance del resto. Un ejemplo de ese tipo de inestabilidad es el agotamiento de la cuota gratuita de un proveedor de inteligencia artificial.

Pruebas

Se espera encontrar referencias a:

- Plan de pruebas
- Pruebas funcionales
- Pruebas unitarias
- Pruebas de integración
- Pruebas de aceptación

Pruebas unitarias (test/unitarios/):
test_eventos.py: valida la máquina de estados de clasificar_evento() para las combinaciones de paso_por_caja/tomo_producto (Escenarios A/B/C).
test_tracking_eventos.py: valida el cierre de visita y la construcción de la secuencia de zonas en PersonTracker.
test_calcular_stats.py: valida los cálculos agregados de reportes (permanencia, KPIs).
test_utils.py: valida funciones puras de soporte (parseo de nombre de cámara/fecha, geometría de zonas).
En deteccion_productos/: test_matching.py (20/20 casos simulados de matching sin gastar cuota de API real, vía fallback a CSV), test_motion.py (5/5 casos sintéticos de detección de estabilidad de escena sin cámara real).
Pruebas de integración: test/conftest.py habilita la importación cruzada entre deteccion/ y frontend/api/ sin empaquetar el proyecto, permitiendo probar la interacción entre el pipeline de persistencia y las consultas de la API sobre una base de test.
Pruebas funcionales/de aceptación: validación manual contra grabaciones reales exportadas del NVR de la tienda (procedimiento documentado en Anexos), corriendo main.py en modo SOLO_LEER_ZONAS=True para no escribir sobre datos de producción durante la calibración de umbrales (UMBRAL_ESTABILIDAD, CONF, APPEARANCE_THRESH, etc.).

Pruebas de integración de la infraestructura de captura remota: de manera complementaria a las pruebas de integración entre módulos de software, se validó la cadena completa de transmisión de video en vivo, desde el grabador de la tienda hasta los equipos de análisis remotos, a través del nodo de captura. Las pruebas ejecutadas se detallan en la Tabla 7.Después va la **tabla** que te pasé antes, con su pie "Tabla 7 / Pruebas de la infraestructura de captura remota. / Fuente: elaboración propia.", y el párrafo del monitoreo térmico. Eso no cambia.

Plan de pruebas: se recomienda documentar aquí, antes de la entrega final, una tabla de casos de aceptación por objetivo específico (ver Tabla de Trazabilidad, sección 22), por ejemplo: "RF-08

clasificación de comportamiento → test_eventos.py + validación manual sobre 3 videos reales con hurto simulado".

Prueba	Procedimiento	Resultado esperado	Resultado obtenido
Acceso local al grabador	Reproducir en VLC, desde el nodo, la URL RTSP del canal 102	Video en vivo de la cámara	[completar]
Retransmisión local	Reproducir en VLC, desde el nodo, rtsp://localhost:8554/<cámara>	Video en vivo retransmitido por MediaMTX	[completar]
Conectividad VPN	Ejecutar tailscale ping entre el nodo y un equipo remoto	Respuesta del nodo a través del túnel	Respuesta exitosa
Administración remota	Conectarse por AnyDesk desde un equipo externo con la contraseña de acceso desatendido	Control del nodo sin confirmación presencial	Conexión exitosa
Acceso remoto al video	Reproducir en VLC, desde una red externa (datos móviles), rtsp://<IP_Tailscale>:8554/<cámara>	Video en vivo desde fuera del establecimiento	[completar]
Acceso concurrente	Dos o más integrantes consumen el mismo flujo en simultáneo	Reproducción sin cortes en todos los equipos	[completar]
Recuperación ante reinicio	Reiniciar el nodo y verificar el estado de los servicios	Servicios activos sin intervención manual	[completar]
Monitoreo térmico	Ejecutar el comando sensors en el nodo	Temperatura del procesador por debajo del umbral alto	59 °C (umbral 100 °C)

BENEFICIOS POST-IMPLEMENTACIÓN

Aquí se deben enumerar los beneficios que se esperan obtener después de la implementación del proyecto. Estos beneficios pueden ser tangibles o intangibles.

Ejemplo:

- Aumento en la eficiencia operativa en x% debido a la automatización de procesos manuales.
- Reducción en los costos asociados a errores humanos en el manejo del inventario.
- Mejora en la toma de decisiones mediante el uso de análisis predictivo basado en datos históricos.

IMPACTO ECONÓMICO (estudio de costos)

El Impacto Económico debe detallar todos los costos y beneficios relacionados con la implementación de la solución. Incluye los costos de implementación, los ahorros potenciales para los afectados y (si hubiese) el retorno de inversión.

El informe de impacto económico debe ser serio y completo, varía dependiendo de cada tema (no puede ser algo superficial)

IMPACTO SOCIAL

El Impacto Social de un proyecto refleja los beneficios o cambios positivos que genera en la sociedad, más allá de los aspectos técnicos o económicos. Esta sección es clave para destacar cómo el proyecto puede contribuir a mejorar la calidad de vida de las personas, generar bienestar social, o atender necesidades de segmentos específicos de la población, especialmente aquellos en situación de vulnerabilidad

Algunos títulos disparadores de esta sección serian:

- Beneficio o Impacto Positivo General
- Segmentos de la Población Beneficiados
- Solidaridad y Apoyo a Segmentos Vulnerables
- Inclusión y Reducción de Brechas

IMPACTO MEDIOAMBIENTAL (opcional)

Se debe considerar tanto los efectos directos como indirectos que el proyecto pueda tener sobre los recursos naturales, el uso de energía, y la generación de residuos. El objetivo es garantizar que la solución propuesta no solo sea eficiente desde el punto de vista técnico y económico, sino también respetuosa con el medio ambiente.

Algunos títulos disparadores de esta sección serian:

- Reducción de Consumo de Recursos
- Minimización de Residuos y Desperdicios
- Uso Eficiente de Energía
- Sostenibilidad a Largo Plazo
- Impacto Indirecto en la Conciencia Ambiental

CONCLUSIÓN

Esta sección es el cierre del proyecto. Incluye los aprendizajes durante el desarrollo, los objetivos cumplidos y no cumplidos, y reflexiones personales (en caso de haber).

BIBLIOGRAFÍA / REFERENCIAS

Aharon, N., Orfaig, R., & Bobrovsky, B.-Z. (2022). *BoT-SORT: Robust associations multi-pedestrian tracking* (arXiv:2206.14651). arXiv. https://doi.org/10.48550/arXiv.2206.14651

Angular. (s. f.). *Angular documentation*. Recuperado el 12 de octubre de 2026, de https://angular.dev

Anthropic. (s. f.). *Models overview*. Recuperado el 12 de octubre de 2026, de https://docs.claude.com/en/docs/about-claude/models/overview ⚠️

Antonakakis, M., April, T., Bailey, M., Bernhard, M., Bursztein, E., Cochran, J., Durumeric, Z., Halderman, J. A., Invernizzi, L., Kallitsis, M., Kumar, D., Lever, C., Ma, Z., Mason, J., Menscher, D., Seaman, C., Sullivan, N., Thomas, K., & Zhou, Y. (2017). Understanding the Mirai botnet. En *Proceedings of the 26th USENIX Security Symposium* (pp. 1093–1110). USENIX Association.

AnyDesk Software GmbH. (s. f.). *AnyDesk*. Recuperado el 12 de octubre de 2026, de https://anydesk.com

Bachmann, M. (s. f.). *RapidFuzz* [Software]. GitHub. Recuperado el 12 de octubre de 2026, de https://github.com/rapidfuzz/RapidFuzz

Bhattacharyya, A. (1943). On a measure of divergence between two statistical populations defined by their probability distributions. *Bulletin of the Calcutta Mathematical Society, 35*, 99–109.

bluenviron. (s. f.). *MediaMTX* [Software]. GitHub. Recuperado el 12 de octubre de 2026, de https://github.com/bluenviron/mediamtx

Bradski, G. (2000). The OpenCV library. *Dr. Dobb's Journal of Software Tools, 25*(11), 120–125.

Cavoukian, A. (2009). *Privacy by design: The 7 foundational principles*. Information and Privacy Commissioner of Ontario.

Código Civil y Comercial de la Nación [CCyCN]. Ley 26.994 de 2014. Arts. 52 y 53. Boletín Oficial de la República Argentina.

Cohn, M. (2004). *User stories applied: For agile software development*. Addison-Wesley.

Constitución de la Nación Argentina [Const.]. (1994). Art. 43.

Dirección Nacional de Protección de Datos Personales. (2015). *Disposición 10/2015*. Boletín Oficial de la República Argentina.

Docker Inc. (s. f.). *Docker documentation*. Recuperado el 12 de octubre de 2026, de https://docs.docker.com

Donenfeld, J. A. (2017). WireGuard: Next generation kernel network tunnel. En *Proceedings of the Network and Distributed System Security Symposium (NDSS)*. Internet Society. https://doi.org/10.14722/ndss.2017.23160

Everseen. (s. f.). *Evercheck*. Recuperado el 11 de octubre de 2026, de https://everseen.com

Expo. (s. f.). *Expo documentation*. Recuperado el 12 de octubre de 2026, de https://docs.expo.dev

FFmpeg. (s. f.). *FFmpeg documentation*. Recuperado el 12 de octubre de 2026, de https://ffmpeg.org/documentation.html

Fowler, M. (2002). *Patterns of enterprise application architecture*. Addison-Wesley.

Gamma, E., Helm, R., Johnson, R., & Vlissides, J. (1994). *Design patterns: Elements of reusable object-oriented software*. Addison-Wesley.

Gemma Team. (2024). *Gemma: Open models based on Gemini research and technology* (arXiv:2403.08295). arXiv. https://doi.org/10.48550/arXiv.2403.08295

GitHub. (s. f.). *GitHub Actions documentation*. Recuperado el 12 de octubre de 2026, de https://docs.github.com/actions

Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press.

Google. (s. f.). *Gemini API: Rate limits*. Recuperado el 12 de octubre de 2026, de https://ai.google.dev/gemini-api/docs/rate-limits ⚠️

Groq. (s. f.). *GroqCloud documentation: Supported models*. Recuperado el 12 de octubre de 2026, de https://console.groq.com/docs/models ⚠️

Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., Wieser, E., Taylor, J., Berg, S., Smith, N. J., Kern, R., Picus, M., Hoyer, S., van Kerkwijk, M. H., Brett, M., Haldane, A., del Río, J. F., Wiebe, M., Peterson, P., … Oliphant, T. E. (2020). Array programming with NumPy. *Nature, 585*(7825), 357–362.

https://doi.org/10.1038/s41586-020-2649-2

Hernández Sampieri, R., & Mendoza Torres, C. P. (2018). *Metodología de la investigación: Las rutas cuantitativa, cualitativa y mixta*. McGraw-Hill.

Hikvision. (s. f.). *Heat mapping*. Recuperado el 11 de octubre de 2026, de https://www.hikvision.com/ca-en/solution/solutions-by-function/heat-mapping

Hohpe, G., & Woolf, B. (2003). *Enterprise integration patterns: Designing, building, and deploying messaging solutions*. Addison-Wesley.

Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., & Chen, W. (2021). *LoRA: Low-rank adaptation of large language models* (arXiv:2106.09685). arXiv. https://doi.org/10.48550/arXiv.2106.09685

Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering, 9*(3), 90–95. https://doi.org/10.1109/MCSE.2007.55

Jocher, G., Chaurasia, A., & Qiu, J. (2023). *Ultralytics YOLOv8* (Versión 8.0.0) [Software]. GitHub. https://github.com/ultralytics/ultralytics

Levenshtein, V. I. (1966). Binary codes capable of correcting deletions, insertions, and reversals. *Soviet Physics Doklady, 10*(8), 707–710.

Ley 20.744 de 1974. Ley de Contrato de Trabajo. Art. 70. Boletín Oficial de la República Argentina.

Ley 25.326 de 2000. Protección de los Datos Personales. Boletín Oficial de la República Argentina.

Ley 27.483 de 2018. Aprobación del Convenio para la Protección de las Personas con respecto al Tratamiento Automatizado de Datos de Carácter Personal (Convenio 108). Boletín Oficial de la República Argentina.

Lin, T.-Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollár, P., & Zitnick, C. L. (2014). Microsoft COCO: Common objects in context. En D. Fleet, T. Pajdla, B. Schiele y T. Tuytelaars (Eds.), *Computer Vision – ECCV 2014* (pp. 740–755). Springer. https://doi.org/10.1007/978-3-319-10602-1_48

Meta Open Source. (s. f.). *React documentation*. Recuperado el 12 de octubre de 2026, de https://react.dev

National Retail Federation. (2023). *National Retail Security Survey 2023*. https://nrf.com ⚠️

Pallets. (s. f.). *Flask documentation*. Recuperado el 12 de octubre de 2026, de https://flask.palletsprojects.com

Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., Killeen, T., Lin, Z., Gimelshein, N., Antiga, L., Desmaison, A., Köpf, A., Yang, E., DeVito, Z., Raison, M., Tejani, A., Chilamkurthy, S., Steiner, B., Fang, L., … Chintala, S. (2019). PyTorch: An imperative style, high-performance deep learning library. En *Advances in Neural Information Processing Systems 32* (pp. 8024–8035). Curran Associates.

Perreault, S., Yamagata, I., Miyakawa, S., Nakagawa, A., & Ashida, H. (2013). *Common requirements for carrier-grade NATs (CGNs)* (RFC 6888). Internet Engineering Task Force. https://doi.org/10.17487/RFC6888

Plotly Technologies. (s. f.). *Heatmaps in Python*. Recuperado el 12 de octubre de 2026, de https://plotly.com/python/heatmaps/

Pressman, R. S., & Maxim, B. R. (2020). *Software engineering: A practitioner's approach* (9.ª ed.). McGraw-Hill Education.

Redmon, J., Divvala, S., Girshick, R., & Farhadi, A. (2016). You only look once: Unified, real-time object detection. En *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 779–788). IEEE. https://doi.org/10.1109/CVPR.2016.91

Render. (s. f.). *Render documentation*. Recuperado el 12 de octubre de 2026, de https://render.com/docs

RetailNext. (s. f.). *Aurora*. Recuperado el 11 de octubre de 2026, de https://retailnext.net/product/aurora

Roboflow. (s. f.). *Roboflow documentation*. Recuperado el 12 de octubre de 2026, de https://docs.roboflow.com

Russell, S., & Norvig, P. (2021). *Artificial intelligence: A modern approach* (4.ª ed.). Pearson.

Schulzrinne, H., Rao, A., & Lanphier, R. (1998). *Real Time Streaming Protocol (RTSP)* (RFC 2326). Internet Engineering Task Force. https://doi.org/10.17487/RFC2326

Sensormatic Solutions. (s. f.). *Shopper insights*. Recuperado el 11 de octubre de 2026, de https://www.sensormatic.com/shopper-insights

Shi, W., Cao, J., Zhang, Q., Li, Y., & Xu, L. (2016). Edge computing: Vision and challenges. *IEEE Internet of Things Journal, 3*(5), 637–646. https://doi.org/10.1109/JIOT.2016.2579198

Sommerville, I. (2016). *Software engineering* (10.ª ed.). Pearson.

Supabase. (s. f.). *Supabase documentation*. Recuperado el 12 de octubre de 2026, de https://supabase.com/docs

Swain, M. J., & Ballard, D. H. (1991). Color indexing. *International Journal of Computer Vision, 7*(1), 11–32. https://doi.org/10.1007/BF00130487

Szeliski, R. (2022). *Computer vision: Algorithms and applications* (2.ª ed.). Springer.

Tailscale. (s. f.). *Tailscale documentation*. Recuperado el 12 de octubre de 2026, de https://tailscale.com/kb

TeamViewer. (s. f.). *TeamViewer*. Recuperado el 12 de octubre de 2026, de https://www.teamviewer.com

Trax. (s. f.). *Trax image recognition*. Recuperado el 11 de octubre de 2026, de https://traxretail.com

Ultralytics. (s. f.). *Ultralytics licensing*. Recuperado el 12 de octubre de 2026, de https://www.ultralytics.com/license ⚠️

Underhill, P. (2009). *Why we buy: The science of shopping* (Ed. actualizada). Simon & Schuster.

Veesion. (s. f.). *Veesion*. Recuperado el 11 de octubre de 2026, de https://veesion.io/en/

Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., Burovski, E., Peterson, P., Weckesser, W., Bright, J., van der Walt, S. J., Brett, M., Wilson, J., Millman, K. J., Mayorov, N., Nelson, A. R. J., Jones, E., Kern, R., Larson, E., … SciPy 1.0 Contributors. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods, 17*(3), 261–272. https://doi.org/10.1038/s41592-019-0686-2

Visual Studio Code. (s. f.). *Documentation for Visual Studio Code*. Recuperado el 12 de octubre de 2026, de https://code.visualstudio.com/docs

Vite. (s. f.). *Vite documentation*. Recuperado el 12 de octubre de 2026, de https://vite.dev

Ye, M., Shen, J., Lin, G., Xiang, T., Shao, L., & Hoi, S. C. H. (2022). Deep learning for person re-identification: A survey and outlook. *IEEE Transactions on Pattern Analysis and Machine*

Intelligence, 44(6), 2872–2893. https://doi.org/10.1109/TPAMI.2021.3054775

Zhang, Y., Sun, P., Jiang, Y., Yu, D., Weng, F., Yuan, Z., Luo, P., Liu, W., & Wang, X. (2022). ByteTrack: Multi-object tracking by associating every detection box. En S. Avidan, G. Brostow, M. Cissé, G. M. Farinella y T. Hassner (Eds.), *Computer Vision – ECCV 2022* (pp. 1–21). Springer. https://doi.org/10.1007/978-3-031-20047-2_1

- Normativas.
- Imágenes, gráficos o tablas tomadas de terceros.
- Comparaciones con soluciones existentes.

Se recomienda priorizar fuentes confiables: documentación oficial, libros, artículos académicos, normas técnicas e informes institucionales.

Cuando armemos la bibliografía conviene citar la documentación oficial de Ultralytics, ByteTrack, Supabase y Tailscale.

ANEXOS

Anexo A: Registro de la entrevista inicial

A.1 Datos generales

Aspecto	Detalle
Fecha	24 de abril de 2026
Lugar	Tienda FULL de una estación de servicio YPF, localidad de Piquillín, provincia de Córdoba
Técnica	Entrevista semiestructurada presencial, complementada con un recorrido de observación por el salón, la caja, la cocina, el depósito y el patio de descarga
Entrevistadores	Los tres integrantes del equipo de proyecto
Entrevistados	Gerente de la tienda y propietarios de la estación de servicio
Registro	Notas de campo y transcripción de la conversación, consolidadas en un documento de trabajo del equipo

A.2 Guía de preguntas

La guía se organizó en bloques temáticos. Se utilizó como orientación y no como un cuestionario cerrado, lo que permitió profundizar en los temas que surgieron durante la conversación.

1. Objetivo del proyecto y necesidades. ¿Qué problemas operativos encuentran actualmente en la tienda? ¿Cómo detectan hoy un problema y cuánto tardan en hacerlo? ¿Con qué frecuencia ocurren incidentes? ¿Hay métricas que quieran medir? Si contaran con datos automáticos sobre circulación, stock y

comportamiento de clientes, ¿qué decisiones les ayudarían a tomar?

2. Infraestructura de cámaras. ¿Cuántas cámaras hay en la estación y cuántas dentro de la tienda? ¿Qué resolución tienen? ¿Cuentan con visión nocturna y audio? ¿Permiten acceder al video mediante RTSP? ¿Qué sistema de grabación (DVR/NVR) y qué programa utilizan? ¿Quién administra el sistema?

3. Ubicación y cobertura. ¿Dónde están ubicadas las cámaras y qué sector cubre cada una? ¿Hay zonas sin cobertura que deberían cubrirse?

4. Red y conectividad. ¿Las cámaras se conectan por cable o por Wi-Fi? ¿La conexión a internet es estable?

5. Almacenamiento. ¿Dónde y por cuánto tiempo se conservan las grabaciones? ¿Es posible obtener grabaciones históricas para el desarrollo?

6. Espacio físico. ¿Existe un plano del local? ¿Qué sectores son los más importantes para las ventas? ¿La disposición de las góndolas cambia con frecuencia?

7. Control de stock. ¿Cómo se realiza actualmente el control y la reposición? ¿Dónde se almacena la mercadería? ¿Qué problemas existen con el inventario? ¿Qué productos tienen mayor rotación?

8. Operación diaria. ¿Cuántas personas trabajan en la tienda y cuántas cajas hay? ¿Cómo se decide abrir una caja adicional?

9. Playa de carga (exploratorio). ¿Hay cámaras orientadas a la playa? ¿Sería útil identificar automáticamente vehículos?

10. Escalabilidad e integración. ¿Estarían dispuestos a agregar cámaras o a integrar el sistema con otros sistemas?

Además, se definió una lista de aspectos a observar durante el recorrido: iluminación, zonas oscuras, reflejos en vidrios y heladeras, objetos que obstruyen la visión, altura y ángulo de las cámaras, ubicación de góndolas y cajas, y zonas cubiertas por cada cámara.

A.3 Síntesis de las respuestas

A.3.1 Control de stock y circuito de la mercadería

- Las compras ingresan al depósito interno mediante factura o remito. Luego, la mercadería se traslada al salón y el traspaso se registra en el sistema con una tablet y un escáner de códigos de barras.

- La salida de mercadería se registra únicamente por factura de venta o por un remito interno, utilizado para roturas, vencimientos u obsequios. Según la entrevistada, para que el stock se mantenga correcto, toda salida debe registrarse en el sistema.
- El control se realiza por conteo manual. La reposición se basa en la observación visual de los faltantes en góndola, no en los datos del sistema.
- Los cortes de conectividad o las fallas de la tablet pueden impedir el registro de algunos traspasos.
- Se producen descuadres entre variedades de un mismo producto. Ocurre sobre todo en los combos: se factura una bebida y el cliente retira otra del mismo precio. También ocurre con productos de envase similar (por ejemplo, variedades de una misma gaseosa que solo difieren en el color de la etiqueta, o snacks de presentación parecida). El total de unidades coincide, pero no la cantidad por variedad.
- Los hurtos se detectan después del hecho, al controlar el stock. Los productos más vulnerables son los de alto valor y fácil acceso, como las papas fritas en tubo.
- En los momentos de mucha afluencia, el personal no puede supervisar al mismo tiempo la caja y las góndolas.

A.3.2 Planogramas y objetivos comerciales

- La ubicación de los productos en góndolas, heladeras y exhibidores está definida por YPF mediante planogramas, que incluyen acuerdos con las marcas (por ejemplo, una puerta completa de heladera asignada a una marca de bebidas).
- Los planogramas se actualizan cuando se dan de baja productos, manteniendo la misma marca en la misma ubicación. El franquiciado no puede reubicar productos libremente.
- Ante la falta de un producto, el espacio se completa con productos de la misma marca o con los adyacentes, para evitar el impacto visual de una góndola vacía.
- Los productos de mayor rentabilidad son los de cafetería y cocina (por ejemplo, hamburguesas). Además, la tienda tiene como objetivo comercial alcanzar un porcentaje de ventas de los productos de marca propia FULL dentro del rubro kiosco.

A.3.3 Afluencia de clientes y picos de demanda

- Los momentos de mayor afluencia se dan al mediodía y durante los fines de semana largos.
- La tienda recibe colectivos con contingentes de alrededor de 40 personas. Las temporadas más intensas son noviembre y diciembre (viajes de estudio) y marzo y abril (contingentes de jubilados). Algunos coordinadores avisan con anticipación, lo que permite prever la mercadería necesaria.
- El salón cuenta con aproximadamente 60 lugares sentados en el interior y unos 20 en el exterior.
- El personal habitual es de dos personas (excepcionalmente tres), una de ellas en la cocina. Cuando la persona de caja también debe preparar cafetería, se forman demoras.
- La mayor impaciencia de los clientes no se produce al esperar para pagar, sino al esperar un pedido ya abonado (café o comida).
- Se observa que mayor movimiento de personas no implica mayores ventas. Por eso, la entrevistada consideró útil conocer la proporción entre ingresos de personas y compras, y el gasto promedio.

A.3.4 Uso del salón

- Hay clientes que utilizan el salón como espacio de trabajo o de espera (viajantes, transportistas, trabajadores de la zona). Permanecen varias horas con un consumo mínimo, ocupan mesas y usan la conectividad del local.
- La entrevistada consideró útil medir los tiempos de permanencia. También mencionó que una permanencia prolongada sin consumo puede, en algunos casos, ser una señal de alerta.

A.3.5 Uso actual de las cámaras

- No existe un centro de monitoreo ni una pantalla de visualización permanente. Las cámaras se consultan desde una aplicación en el celular, solo cuando ocurre un incidente.
- Los motivos de consulta más frecuentes son: objetos olvidados por clientes (carteras, billeteras, tarjetas, celulares; aproximadamente una vez al mes), errores de cobro con tarjeta que deben vincularse con un cliente y, eventualmente, caídas de personas.

- En esas revisiones, la nitidez de las imágenes resultó a veces insuficiente.
- Cámaras informadas: cuatro en el salón y dos en la cocina. El depósito interno no tiene cámaras; hay una en el patio de descarga de mercadería.
- La administración del sistema de cámaras está a cargo de un proveedor técnico externo. Las cámaras no registran audio.
- Según la entrevistada, la conexión a internet es actualmente más estable que en el pasado.

A.3.6 Faltantes de efectivo y consumos no facturados

- Al cierre de caja suelen existir pequeñas diferencias.
- En la cafetería pueden prepararse productos para clientes habituales que se cobran sin emitir el ticket correspondiente. Esto genera sobrantes de efectivo sin respaldo en el sistema. La entrevistada sugirió que sería útil estimar la cantidad de cafés preparados por turno.

A.3.7 Expectativas sobre la herramienta

- No se espera que el personal monitoree el sistema de forma permanente. Lo que se espera es que el sistema emita alertas ante situaciones relevantes y que genere un registro o informe (diario, semanal o por filtro). Así, ante un faltante o una diferencia de caja, se podría consultar en qué horario ocurrieron situaciones sospechosas y revisar la grabación puntual.
- Se valoró que la información se presente en forma simple: cantidades, porcentajes y gráficos.
- Se mencionó como alternativa recibir las notificaciones en el celular.

A.3.8 Ideas adicionales surgidas en la entrevista

Durante la conversación se mencionaron otras aplicaciones posibles, que quedaron fuera del alcance del proyecto: el registro de patentes en la playa de carga para identificar clientes frecuentes, el conteo de ingresos a los sanitarios para programar su limpieza, la detección del medio de pago utilizado, la detección de caídas y la de objetos olvidados.

A.4 Hallazgos y su relación con el proyecto

Hallazgo	Tratamiento en OptiFull
Descuadre entre stock físico y stock en sistema (combos y productos similares)	Abordado parcialmente: reconocimiento del producto real en caja (Módulo 8)
Hurtos detectados recién al controlar el stock	Abordado: clasificación de visitas y alertas con evidencia (Módulos 4 y 5)
Mucho movimiento de personas sin ventas proporcionales	Abordado: flujo de personas y tasa de conversión (RF-26, RF-27)
Colas y demoras en momentos pico	Abordado parcialmente: congestión por día y hora, y tiempo de espera en caja (RF-27)
Uso prolongado del salón con bajo consumo	Abordado parcialmente: permanencia por zona (RF-27)
Decisiones de reposición y de personal basadas en la intuición	Abordado: Dashboard y reportes (Módulos 9 y 10)
Cámaras utilizadas solo de forma reactiva	Abordado: objetivo central del proyecto
Desconocimiento de zonas de mayor circulación	Abordado: mapas de calor (Módulo 6)
Consumos de cafetería no facturados	Fuera de alcance
Predicción de picos y comparación entre sucursales	Fuera de alcance (trabajo futuro)
Patentes, sanitarios, medios de pago, caídas y objetos olvidados	Fuera de alcance

Fuente: elaboración propia a partir de la entrevista realizada.

Anexo B: Procedimiento de exportación de grabaciones del NVR

El siguiente procedimiento se aplicó durante la segunda visita al establecimiento para exportar, desde la interfaz local del grabador de video en red (NVR) Hikvision, las grabaciones utilizadas en el desarrollo y la calibración del sistema. Requiere acceso físico al grabador, un monitor y un mouse conectados a él, y una unidad de almacenamiento externa conectada a uno de sus puertos USB.

B.1 Búsqueda de las grabaciones

1. Hacer clic en el botón **“Search”** de la barra superior (el tercer botón desde la izquierda, con el ícono de una lupa sobre un documento).
2. Configurar la hora de inicio y de fin en los campos de la sección **“Time”**.
3. Seleccionar las cámaras deseadas en el cuadro de canales. Para desmarcar todas las cámaras a la vez, desmarcar la casilla **“[All] Cameras”**. Las cámaras seleccionadas aparecen con un borde azul.
4. Hacer clic en **“Search”**.
5. Marcar, en la lista de resultados, la casilla de cada clip que se desea exportar.

B.2 Exportación

6. Hacer clic en **“Export”**.
7. Marcar la opción **“Video and log”** y hacer clic en **“OK”**.
8. Verificar que la unidad de almacenamiento externa esté seleccionada en el campo **“Device Name”** y hacer clic en **“OK”**.
9. Aguardar a que finalice la copia de los archivos.
10. Hacer clic nuevamente en **“Export”**, marcar la opción **“Player”** y hacer clic en **“OK”**, para incluir en la unidad el reproductor necesario para abrir el formato nativo del grabador.
11. Repetir los pasos 1 a 10 para cada cámara.

B.3 Finalización

12. Hacer clic en el botón de vista en vivo (**“Live View”**), el primero de la barra superior, para volver a las imágenes en tiempo real.

Las grabaciones exportadas se encuentran en el formato nativo del firmware del grabador, por lo que posteriormente se convirtieron a contenedores de video estándar mediante FFmpeg para su procesamiento (ver sección 2.11).

Anexo C: Configuración del nodo de captura remota

El siguiente procedimiento detalla la configuración aplicada sobre la Microsoft Surface Pro 3 con Ubuntu para su operación desatendida en la tienda. Los comandos se ejecutan desde la terminal del nodo.

C.1 Deshabilitar la suspensión y la hibernación

```
sudo systemctl mask sleep.target suspend.target hibernate.target hybrid-sleep.target
```

En el archivo /etc/systemd/logind.conf se establecieron los siguientes valores, y luego se reinició el servicio:

```
HandleLidSwitch=ignore
HandleLidSwitchExternalPower=ignore
HandleLidSwitchDocked=ignore
```

```
sudo systemctl restart systemd-logind
```

C.2 Configurar el inicio de sesión

1. En Configuración → Usuarios, activar el inicio de sesión automático.
2. En la pantalla de inicio de sesión, seleccionar la sesión “Ubuntu on Xorg” desde el ícono de engranaje, ya que Wayland impide la captura de pantalla de AnyDesk.

C.3 Configurar AnyDesk para acceso desatendido

1. En AnyDesk, ingresar a Configuración → Seguridad y desbloquear la configuración de seguridad.
2. Habilitar el acceso desatendido y definir una contraseña fija.

Por razones de seguridad, la contraseña de acceso no se incluye en este documento y se compartió únicamente entre los integrantes del equipo.

3. Asignar un perfil de permisos completo (teclado, mouse y portapapeles).
4. Registrar el identificador numérico del puesto de trabajo.
5. Habilitar el servicio para que se inicie con el sistema:

```
sudo systemctl enable --now anydesk
```

C.4 Instalar y vincular Tailscale

```
curl -fsSL https://tailscale.com/install.sh | sh
sudo tailscale up
tailscale ip -4
```

Luego, en el panel de administración de Tailscale, se seleccionó la opción “Disable key expiry” sobre el nodo para evitar su desconexión periódica.

C.5 Configurar MediaMTX

En el archivo mediamtx.yml se definió una ruta por cámara, apuntando al flujo secundario del grabador:

```
paths:
  camara1:
    source: rtsp://<usuario>:<contraseña>@<IP_grabador>:554/Streaming/Channels/102/
    sourceOnDemand: yes
  camara2:
    source: rtsp://<usuario>:<contraseña>@<IP_grabador>:554/Streaming/Channels/202/
    sourceOnDemand: yes
```

Se definió una ruta por cada una de las cámaras analizadas, siguiendo el mismo esquema. El identificador del canal se compone del número de cámara seguido de “02”, que corresponde al flujo secundario (por ejemplo, 302 para la cámara 3 y 402 para la cámara 4).

C.6 Registrar MediaMTX como servicio del sistema

Se creó el archivo /etc/systemd/system/mediamtx.service con el siguiente contenido:

```
[Unit]
Description=MediaMTX RTSP Gateway
After=network.target tailscaled.service

[Service]
Type=simple
ExecStart=<ruta>/mediamtx <ruta>/mediamtx.yml
Restart=always
RestartSec=5
User=root
```

```
[Install]
WantedBy=multi-user.target
```

Y se habilitó con los siguientes comandos:

```
sudo systemctl daemon-reload
sudo systemctl enable --now mediamtx
sudo systemctl status mediamtx
```

C.7 Verificación desde un equipo remoto

Desde un equipo con Tailscale activo y fuera de la red del establecimiento, abrir en VLC la dirección rtsp://<IP_Tailscale_del_nodo>:8554/camara1 y comprobar la reproducción en vivo.

Anexo D: Plano del local y ubicación de las cámaras

Este anexo presenta la distribución física del salón de ventas de la tienda relevada y la ubicación de las cámaras utilizadas por el sistema. La información se obtuvo durante el recorrido de observación realizado en la primera visita al establecimiento (ver sección 2.5) y sirvió de base para la definición de las zonas de interés de cada cámara y para la proyección de la circulación sobre el plano del local en el Dashboard.

Como se observa en la Figura D1, el salón se organiza en tres sectores principales. En el sector izquierdo se ubican la heladera exhibidora y dos góndolas, junto al ingreso del local. En el sector inferior izquierdo se encuentra la línea de caja, con la cocina inmediatamente detrás. En el sector derecho se ubica el área de mesas, con diez mesas destinadas al consumo en el local. Las cámaras 1 y 2 se encuentran en las esquinas superiores del salón, mientras que las cámaras 3 y 4 se ubican en los extremos de la línea de caja y observan el salón desde detrás del mostrador.

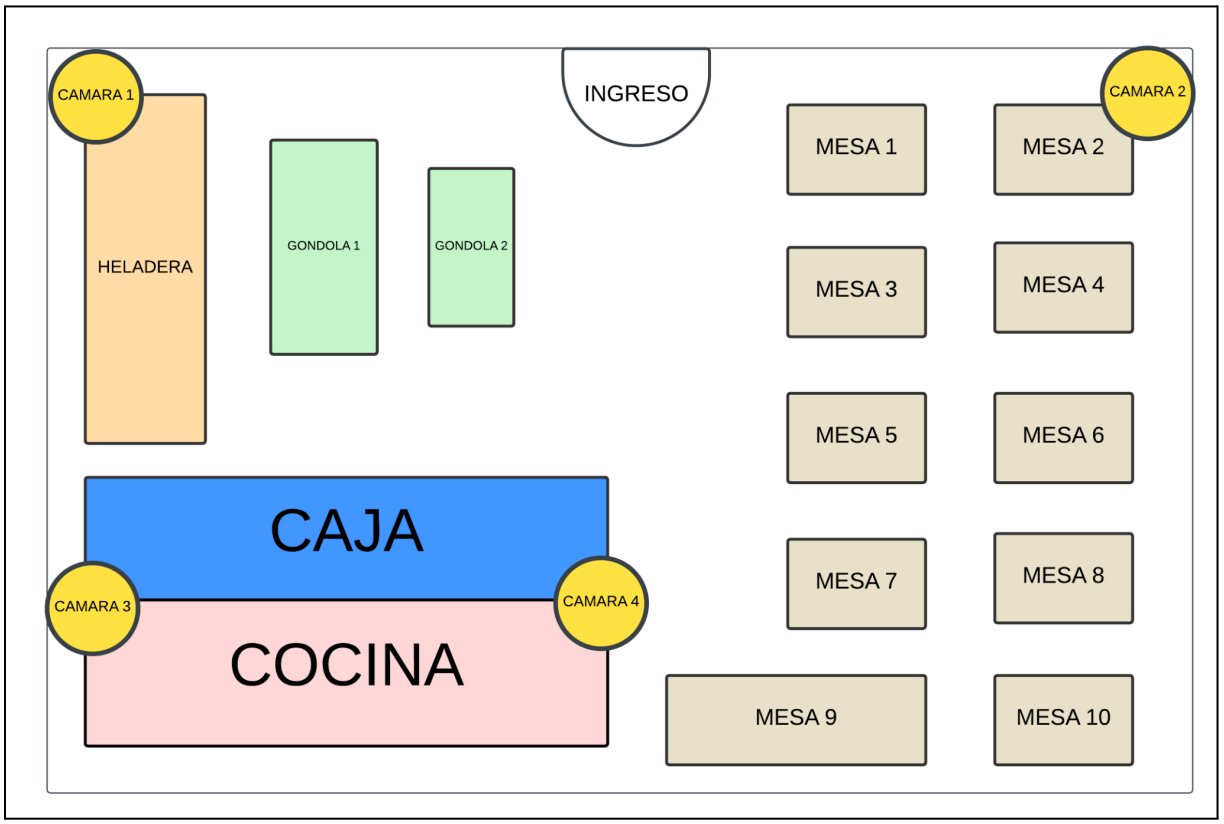


Figura D1: Croquis del salón de ventas de la tienda FULL relevada, con la ubicación de las cuatro cámaras analizadas.

Fuente: elaboración propia a partir del relevamiento realizado en el establecimiento.

Nota. El croquis es esquemático y no está a escala.

Tabla D1

Ubicación y cobertura de las cámaras del salón

Cámara	**Ubicación**	**Sector observado**
Cámara 1	Esquina superior izquierda, sobre la heladera	Mostrador de caja, exhibidores frente al mostrador y área de mesas
Cámara 2	Esquina superior derecha, sobre el área de mesas	Área de mesas y, en segundo plano, la caja y los exhibidores
Cámara 3	Extremo izquierdo de la línea de caja	Mostrador de caja, góndola de snacks, freezer exhibidor y, al fondo, el área de mesas

Cámara 4	Extremo derecho de la línea de caja	Mostrador de caja, heladeras exhibidoras, góndola y freezer

Fuente: elaboración propia.

Además de las cámaras del salón, el establecimiento cuenta con dos cámaras en la cocina y una en el patio de descarga de mercadería, que no forman parte del análisis por no corresponder al área de atención al público. El depósito interno no cuenta con cobertura de cámaras (ver sección 2.10).

Anexo E: Definición de las zonas de interés por cámara

Las zonas de interés constituyen la base de la clasificación de comportamiento y de las métricas por sector (ver Módulo 4). Cada zona es un polígono definido sobre la imagen de una cámara, al que se le asigna un tipo. En cada fotograma, el sistema determina en qué zona se encuentran los pies de cada persona detectada.

E.1 Herramienta utilizada

Para definir las zonas se desarrolló una herramienta auxiliar web, el *Editor de zonas*, construida con asistencia de un modelo de lenguaje (ver sección 4.4.1). La herramienta presenta una fotografía fija del local tomada desde cada una de las cuatro cámaras analizadas y permite dibujar sobre ella los polígonos de cada zona, marcando sus vértices con el cursor. Su funcionamiento se resume en los siguientes pasos:

1. Seleccionar la cámara en la barra superior.
2. Elegir el tipo de zona a dibujar.
3. Marcar los vértices del polígono sobre la imagen (mínimo tres puntos) y cerrar la zona.
4. Repetir el procedimiento para cada zona y cada cámara.
5. Exportar el resultado como sentencias SQL y ejecutarlas en la base de datos.

Dado que las fotografías de fondo tienen una resolución distinta de la de los videos analizados, la herramienta convierte automáticamente cada punto marcado a la escala real del video (1920 × 1080 píxeles). De este modo, las coordenadas almacenadas coinciden con las que utiliza el pipeline de detección.

E.2 Tipos de zona

El esquema de la base de datos admite seis tipos de zona: entrada, salida, caja, góndola, depósito y otro. Para el establecimiento relevado se utilizaron tres, que se

corresponden con los sectores del local descritos en el Anexo D:

Tabla E1

Tipos de zona definidos en el establecimiento

Zona	Tipo en la base de datos	Sector del local	Uso en el sistema
Zona Caja	caja	Línea de caja y mostrador	Determina el acercamiento de cada persona a la caja y el tiempo de espera
Zona Góndolas	gondola	Heladera y góndolas	Asocia la interacción con productos a un sector y mide la permanencia frente a la mercadería
Zona Salón	otro	Circulación general y área de mesas	Mide la permanencia en el salón y el uso del área de mesas

Fuente: elaboración propia.

E.3 Zonas definidas en cada cámara

Las Figuras E1 a E4 muestran las zonas definidas sobre la imagen de cada cámara.



Figura E1: Zonas definidas sobre la imagen de la cámara 1.

Fuente: elaboración propia.

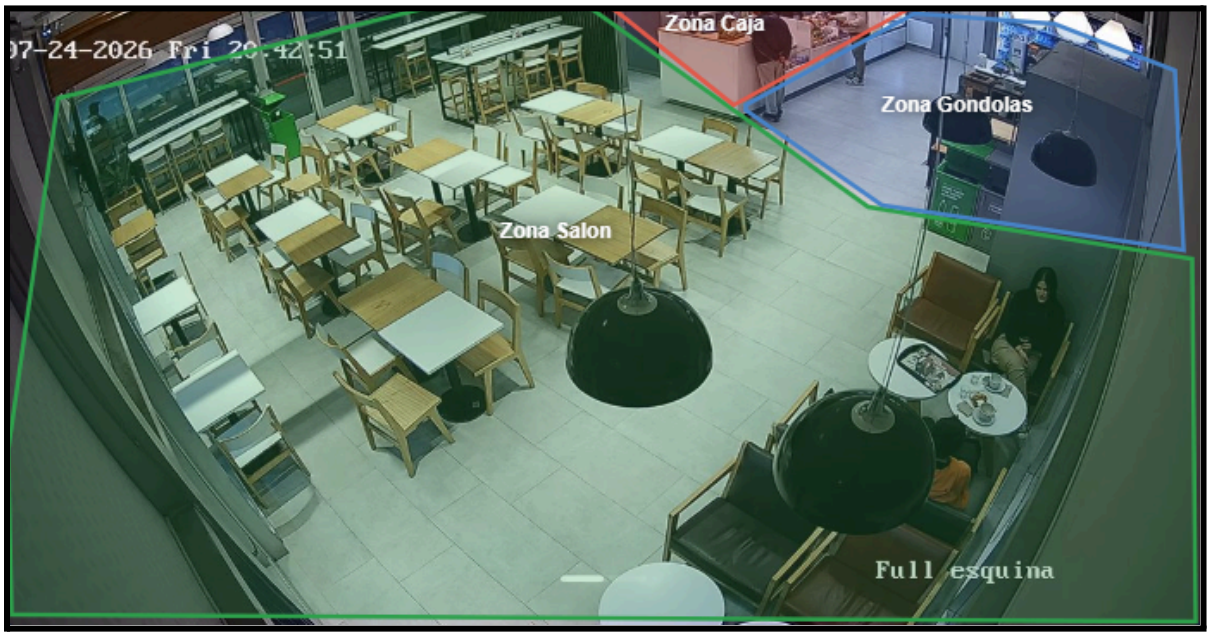


Figura E2: Zonas definidas sobre la imagen de la cámara 2.

Fuente: elaboración propia.



Figura E3: Zonas definidas sobre la imagen de la cámara 3.

Fuente: elaboración propia.



Figura E4: Zonas definidas sobre la imagen de la cámara 4.
Fuente: elaboración propia.

Anexo F: Modelo de datos completo

Este anexo complementa el diagrama entidad-relación simplificado de la Figura 19 con el detalle de todas las tablas de la base de datos. El esquema se implementó en PostgreSQL, sobre la plataforma Supabase, y se encuentra definido en el archivo db/schema.sql del repositorio. Las tablas se presentan agrupadas según el módulo del sistema que las utiliza.

Tabla F1

Tablas de infraestructura y análisis de video

Tabla	Descripción	Campos principales	Relaciones
camaras	Cámaras del establecimiento que el sistema puede analizar	nombre, ubicación, URL del flujo, activa	—
sesiones_video	Cada análisis de un video o de un flujo en vivo de una cámara	inicio, fin, duración (calculada), resolución del fotograma, latido (*heartbeat*)	camaras

zonas	Regiones de interés definidas sobre la imagen de cada cámara	nombre, tipo (entrada, salida, caja, góndola, depósito u otro), polígono	camaras
personas	Cada aparición de una persona detectada en una sesión	primera y última detección, duración, método de reidentificación, descripción visual, identidad unificada (`cliente_id`), es empleado, foto	sesiones_video, personas (autorreferencia), empleados
trayectorias	Posiciones registradas de cada persona a lo largo del tiempo	marca de tiempo, coordenadas del punto de referencia, caja delimitadora, zona, cámara	personas, zonas, camaras
visitas	Segmentos de presencia continua de una persona frente a las cámaras	entrada, salida, duración (calculada)	personas
eventos	Clasificación de cada visita finalizada	acción detectada (compra normal, posible hurto, tránsito sin compra), tomó producto, pasó por caja, secuencia de zonas	personas, visitas
alertas	Situaciones que requieren la atención del personal	tipo, descripción, resuelta, evidencia (fotogramas y clip)	personas

Fuente: elaboración propia.

Tabla F2

Tablas de mapas de calor y métricas

Tabla	Descripción	Campos principales	Relaciones

mapas_calor	Mapa de calor de cada sesión de análisis	matriz de 64 × 64 celdas, imagen, punto máximo, porcentaje de área activa, concentración, zona más concurrida	camaras, sesiones_video, zonas
mapas_calor_camara	Mapa de calor acumulado histórico de cada cámara	matriz combinada, cantidad de sesiones combinadas, fecha de actualización	camaras, zonas
metricas_flujo	Estructura prevista para almacenar métricas agregadas por hora, día o semana	personas únicas, máximo simultáneo, permanencia promedio, tiempo de espera en caja	camaras, zonas

Fuente: elaboración propia.

Tabla F3

Tablas del módulo de caja

Tabla	Descripción	Campos principales	Relaciones
productos	Catálogo de productos de la tienda	SKU (clave primaria), nombre, marca, variante, tamaño y unidad, categoría, cantidad en stock, precio	—
transacciones	Cada producto confirmado por el cajero	SKU, cantidad, confianza del modelo, estado del *matching*, respuesta original del modelo	productos
caja_estado	Canal de comunicación entre la interfaz web y el pipeline de caja (registro único)	estado (inactivo, esperando decisión, detener), decisión pendiente, respuesta del cajero	—

Fuente: elaboración propia.

Tabla F4

Tablas de control de acceso e identificación de empleados

Tabla	Descripción	Campos principales	Relaciones
roles	Perfiles de acceso al sistema	nombre (administrador o usuario), descripción	—
usuarios	Cuentas habilitadas para iniciar sesión	usuario, correo electrónico, nombre, contraseña cifrada (*hash*), cargo (dueño, gerente o empleado), activo, último acceso	roles
sucursales	Locales registrados en el sistema	nombre, dirección, localidad, provincia	—
usuarios_sucursales	Asignación de usuarios a sucursales (relación de muchos a muchos)	usuario, sucursal	usuarios, sucursales
empleados	Personal real del local, utilizado como referencia	nombre, activo	—
empleados_descripciones	Descriptores de apariencia de referencia de cada empleado	descripción (color de ropa, complexión, cabello, accesorios)	empleados

Fuente: elaboración propia.

Algunos aspectos del modelo merecen destacarse:

- **Identidad unificada:** cada fila de la tabla `personas` representa una aparición en una sesión. El campo `cliente_id` agrupa todas las apariciones que el proceso de reidentificación atribuyó a una misma persona, apuntando a la primera aparición de la cadena.
- **Permanencia real:** el tiempo de permanencia se calcula sumando la duración de las `visitas` de una misma identidad, y no a partir de la primera y la última detección, que pueden incluir períodos en los que la persona estuvo fuera del local.
- **Clasificación completa:** la tabla `eventos` registra todas las visitas finalizadas, y no solo las sospechosas, para que el historial de recorridos quede disponible para su auditoría.
- **Campos calculados:** las duraciones de las sesiones, las personas y las visitas se calculan automáticamente en la base de datos a partir de sus marcas de tiempo.

Anexo G: Endpoints de la API REST

La API REST se implementó con Flask y sus rutas se organizaron en *Blueprints* por dominio funcional, todas bajo el prefijo `/api`. La Tabla G1 detalla cada endpoint, el método HTTP que acepta y la sección de la interfaz que lo consume. Además de estas rutas, el servidor entrega los archivos compilados de la aplicación React para cualquier otra dirección.

Tabla G1

Endpoints de la API REST de OptiFull

Método	**Ruta**	**Descripción**	**Sección que lo usa**
Autenticación y servicio			
POST	/api/login	Valida las credenciales y devuelve el nombre y el rol del usuario	Inicio de sesión
GET	/api/health	Verifica que el servicio esté activo (utilizado por la plataforma de despliegue)	—
POST	/api/leads	Registra una solicitud de demostración	Página de bienvenida
Estadísticas y personas			
GET	/api/stats	Indicadores generales del período	Dashboard
GET	/api/en-tienda	Cantidad de clientes presentes en el local en este momento	Dashboard
GET	/api/personas	Listado de personas detectadas	Dashboard
POST	/api/personas/{id}/empleado	Confirma o revierte que una persona es empleada	Alertas
Reportes			

GET	/api/reportes/tendencia-semanal	Promedio de personas únicas por día de la semana	Dashboard
GET	/api/reportes/permanencia-semanal	Permanencia promedio por día de la semana	Dashboard
GET	/api/reportes/congestion-horaria	Afluencia por día y franja horaria	Dashboard
GET	/api/reportes/promedio-diario	Promedio de personas únicas por día	Dashboard
GET	/api/reportes/conversion-compra	Proporción de clientes que compraron y que no compraron	Dashboard
GET	/api/reportes/permanencia-por-zona	Permanencia promedio en cada zona del local	Dashboard
GET	/api/reportes/posibles-empleados	Candidatos a empleado según su permanencia diaria	Alertas
GET	/api/reportes/opciones	Métricas, cámaras y formatos disponibles para exportar	Reportes
POST	/api/reportes/exportar	Genera un reporte en PDF, Excel, CSV o PNG	Reportes
GET	/api/export/csv	Exportación directa en CSV	Reportes
GET	/api/export/pdf	Exportación directa en PDF	Reportes
Alertas			
GET	/api/alertas	Listado de alertas con su evidencia	Alertas
POST	/api/alertas/{id}/resolver	Marca una alerta como resuelta o la reabre	Alertas

GET	/api/evidencias/{archivo}	Entrega un archivo de evidencia almacenado localmente	Alertas
Mapas de calor			
GET	/api/heatmap/latest	Último mapa de calor generado	Dashboard
GET	/api/heatmap/camara/{id}	Mapa de calor acumulado de una cámara	Dashboard
GET	/api/cameras/{id}/heatmaps	Mapas de calor de cada sesión de una cámara	Dashboard
GET	/api/heatmap/plano	Circulación proyectada sobre el plano del local, por tipo de zona	Dashboard
GET	/api/heatmap/plano/tiempo	Circulación sobre el plano agrupada en bloques de 5 minutos	Dashboard (reproductor cronológico)
GET	/api/heatmap/plano/flujo	Recorridos de clientes entre zonas	Dashboard (modo Trayectorias)
GET	/api/heatmap/image/{archivo}	Imagen de un mapa de calor	Dashboard
GET	/api/heatmap/fondo/{id}	Fotografía de fondo del local para una cámara	Dashboard
Video y seguimiento			
GET	/api/sessions	Sesiones de análisis registradas	Dashboard
GET	/api/sessions/{id}/video	Video original de una sesión	Dashboard
GET	/api/sessions/{id}/clip	Fragmento de video convertido a H.264	Dashboard

GET	/api/sessions/{id}/tracking	Personas y trayectorias de una sesión	Dashboard
GET	/api/cameras/{id}/tracking	Personas y trayectorias de todas las sesiones de una cámara	Dashboard
GET	/api/videos	Videos disponibles para análisis	Dashboard
GET	/api/video/{archivo}	Entrega un archivo de video	Dashboard
Caja			
POST	/api/productos/iniciar	Inicia el pipeline de caja como subproceso	Productos
POST	/api/productos/detener	Detiene el pipeline de caja de forma ordenada	Productos
GET	/api/productos/estado	Decisión pendiente del pipeline (producto reconocido, candidatos o no reconocido)	Productos
POST	/api/productos/accion	Registra la acción del cajero (confirmar, elegir candidato, cargar manualmente o cancelar)	Productos
GET	/api/productos/camara	Retransmite el video en vivo de la cámara de caja (solo direcciones de red privadas)	Productos
GET	/api/productos/stock	Catálogo de productos con su stock	Productos
GET	/api/productos/metricas	Indicadores de la sesión de caja	Productos

Fuente: elaboración propia.

Anexo H: Instrucciones (prompts) de los modelos de IA y formato de respuesta

Este anexo documenta las instrucciones (*prompts*) enviadas a los modelos

multimodales y el formato de las respuestas esperadas, con el fin de permitir la reproducibilidad de los resultados. Los textos de las instrucciones se transcriben de manera literal, tal como se encuentran en el código fuente.

H.1 Reidentificación de personas

Se utiliza la misma instrucción para los tres proveedores (Claude, Gemini y Groq), junto con el recorte de la imagen de la persona. Se encuentra en el directorio `deteccion/reid/`.

Instrucción enviada al modelo:

"Actuas como un sistema de Re-Identificacion de personas (Person Re-ID) para tracking multi-camara en un local comercial, SIN reconocimiento facial (esta prohibido por privacidad). El objetivo NO es describir la moda de la persona, sino extraer caracteristicas visuales ESTABLES que permitan reconocerla mas adelante si sale de cuadro, queda oculta detras de otra persona o gondola, o reaparece en otra camara minutos despues. Otra parte del sistema va a comparar este JSON contra descripciones generadas en otros momentos de la MISMA persona, asi que los valores tienen que ser SIMPLES y GENERALES, no un detalle exacto que probablemente cambie entre una descripcion y otra.

Completa estos campos:

- color_ropa_superior / color_ropa_inferior: SOLO el color predominante y basico ('azul', 'negro', 'rojo', 'blanco', 'gris', 'verde', etc.), sin matices ni tonos especificos (NO 'azul marino con reflejos claros', SI 'azul'). Unicamente si la prenda combina dos colores bien diferenciados en partes similares, indica ambos separados por '/' (ej. 'rojo/negro').
- complexion: delgada, media o robusta.
- cabello: color y largo aproximado, en pocas palabras (ej. 'corto oscuro', 'largo claro', 'calvo').
- accesorios: mochila, cartera, gorra, lentes, ninguno, etc. (el mas notorio).
  Si algun campo no se puede determinar desde la imagen, usa 'no visible'. No inventes datos."

Formato de respuesta: un objeto JSON con cinco campos de texto obligatorios. En el caso de Claude, el esquema se impone desde la propia API, lo que garantiza una respuesta válida:

{ "color_ropa_superior": "azul",
"color_ropa_inferior": "negro",
"complexion": "media",
"cabello": "corto oscuro",
"accesorios": "mochila" }

Regla de comparación: el modelo no decide si dos personas son la misma; solo genera la descripción. La comparación la realiza el sistema de forma determinista:

1. Si el color de la prenda superior es visible en ambas descripciones y no coincide, el candidato se descarta.
2. Se cuentan las coincidencias entre los campos visibles en ambas descripciones. Los campos “no visible” no suman ni restan.
3. Se suma un punto adicional si ambas apariciones ocurrieron en cámaras del mismo sector con menos de 90 segundos de diferencia.
4. Se acepta el candidato con mayor puntaje, siempre que alcance un mínimo de tres coincidencias (o la cantidad de campos comparables, si es menor).

La comparación con un empleado de referencia es más estricta: exige que coincidan tanto el color de la prenda superior como el de la inferior, ya que el uniforme es una señal más confiable.

Tabla H1

Configuración de los proveedores de reidentificación

Proveedor	**Modelo**	**Intervalo mínimo entre llamadas**	**Pausa adicional ante ráfagas**
Anthropic (Claude)	claude-haiku-4-5	2,5 s	6 s
Google (Gemini)	gemini-flash-latest	4 s	8 s
Groq	qwen/qwen3.6-27b	2,5 s	6 s

Nota. Se considera ráfaga la ocurrencia de tres o más eventos dentro de una ventana de 10 segundos, por ejemplo, el ingreso de un grupo de personas.

Fuente: elaboración propia.

H.2 Reconocimiento de productos en caja

Se utiliza el modelo Claude Haiku 4.5 (versión `claude-haiku-4-5-20251001`). La imagen se recorta a la región del mostrador, se reduce a un máximo de 1024 píxeles por lado y se envía en formato JPEG, acompañada del mensaje “Analizá el producto en la imagen y devolveme el JSON.” La instrucción de sistema se encuentra en `deteccion_productos/agents/vision_agent.py`Esta sesión no se está ejecutando, por lo que no se pueden abrir sus archivos. Envía un mensaje para volver a iniciarla..

Instrucción de sistema:

“Sos un analizador de productos para el sistema de caja de una tienda de conveniencia en una estación de servicio YPF de Argentina.
Recibís una imagen tomada desde una cámara en la zona de escaneo de la caja. Tenés que identificar el producto que se ve y devolver sus datos en JSON.
Reglas:

- Solo respondé con el JSON, sin texto adicional, sin backticks, sin markdown.
- Si no ves un producto claro (solo mano, fondo, o imagen borrosa), devolvé: {“producto_detectado”: false}
- Si ves un producto, devolvé el JSON con este formato EXACTO: [ver formato de respuesta]
  Definición de cada campo (para NO confundirlos):
- “marca”: el nombre de fabricante/marca impreso en el envase (ej: “Coca-Cola”, “Tofi”, “Milka”, “Lays”, “Guaymallen”). NUNCA pongas acá el tipo genérico de producto (alfajor, gaseosa, snack, chocolate, golosina, agua) — eso va en “categoria”.
- “nombre_producto”: el nombre comercial completo tal como aparece en el envase (ej: “Alfajor Tofi Negro”). Esto NO reemplaza a “marca”: la marca va igual en su propio campo, aunque se repita.
- “categoria”: el tipo genérico de producto (alfajor, gaseosa, snack, chocolate, agua, energizante, etc.).
- “tamaño”: preferí SIEMPRE el peso o volumen neto real impreso en el envase (ej: “Contenido neto 46 g”), incluso en productos que se venden como pieza entera (alfajores, chocolates, snacks). Usá “unidades” solo si genuinamente no hay ningún peso/volumen legible en el envase.
  Ejemplos (marca real vs. categoría, no los confundas):
  Coca-Cola Zero 500ml -> {“marca”: “Coca-Cola”, “nombre_producto”: “Coca-Cola Zero”, “variante”: “Zero”, “tamano”: {“valor”: 500, “unidad”: “ml”}, “categoria”:

"gaseosa"}

Alfajor Tofi Negro -> {"marca": "Tofi", "nombre_producto": "Alfajor Tofi Negro", "variante": "Chocolate Negro", "tamano": {"valor": 46, "unidad": "g"}, "categoria": "alfajor"}

Sé preciso con la variante y el tamaño: esos son los campos que distinguen productos similares (Coca 500ml vs Coca 1.5L, Coca Original vs Coca Zero, Ades Manzana vs Ades Naranja).

Si no podés leer un campo con certeza, ponelo como null y bajá la confianza.

Devolvé el JSON en UNA sola línea, sin espacios ni saltos de línea extra."

Formato de respuesta:

```
{ "producto_detectado": true,
  "marca": "string",
  "nombre_producto": "string",
  "variante": "string o null",
  "tamano": {"valor": number, "unidad": "ml|l|g|kg|cc|unidades"},
  "categoria": "string",
  "confianza": number }
```

Con esta respuesta, el componente de *matching* calcula el puntaje de coincidencia contra el catálogo de la tienda (marca 40 %, variante 25 % y tamaño 35 %), según lo descrito en el Módulo 8.

Anexo I: Parámetros de calibración del sistema

Los parámetros que regulan el comportamiento de cada pipeline se centralizaron en dos archivos de configuración: `deteccion/config.py` para el análisis del salón y `deteccion_productos/config.py` para el reconocimiento en caja. De este modo, el sistema se ajustó a las condiciones reales de la tienda sin modificar el código de los módulos. Las tablas siguientes presentan los parámetros principales, el valor adoptado y el motivo de su elección.

Tabla I1

Parámetros de detección y seguimiento de personas

Parámetro	**Valor**	**Descripción y justificación**

Modelo para grabaciones	YOLOv8n	Variante liviana, suficiente para videos de 1920 × 1080
Umbral de confianza (grabaciones)	0,70	Exigente, porque la resolución alta permite detecciones claras y así se reducen los falsos positivos
Fotogramas procesados (grabaciones)	1 de cada 5	Reduce el costo de cómputo sin perder continuidad en el seguimiento
Modelo para flujos en vivo	YOLOv8s	Mayor capacidad, necesaria para el flujo secundario de 640 × 360
Resolución de inferencia (en vivo)	960 px	Amplía la imagen para detectar personas que se ven pequeñas desde las cámaras elevadas
Umbral de confianza (en vivo)	0,35	Más permisivo, porque con baja resolución las personas obtienen puntajes menores
Fotogramas por segundo procesados (en vivo)	2	Equilibrio entre resolución temporal y uso de CPU en equipos sin GPU
Confirmación de una persona nueva	3 fotogramas consecutivos	Descarta reflejos y errores momentáneos del detector
Distancia máxima para reconexión por posición	15 % del ancho de la imagen	Permite recuperar la identidad tras una oclusión breve, cuando la persona reaparece cerca
Tiempo de reconexión por posición	15 s	Pasado este tiempo, la posición deja de ser un criterio confiable
Tiempo de reconexión por apariencia	30 min	Ventana para reconocer a una persona que reaparece dentro del mismo video
Umbral de similitud de apariencia	0,72	Similitud mínima entre histogramas de color para aceptar que se trata de la misma persona

Fuente: elaboración propia.

Tabla I2

Parámetros de reidentificación y fusión entre cámaras

Parámetro	**Valor**	**Descripción y justificación**
Proveedor de reidentificación	Claude	Configurable (Claude, Gemini o Groq) según la disponibilidad de cuota
Coincidencias mínimas del descriptor	3 de 5	Evita fusionar a personas distintas con ropa parecida
Ventana de búsqueda de candidatos	± 1 hora	Impide comparar a personas vistas en momentos muy distantes del día
Umbral de "mismo momento" entre cámaras	90 s	Aparecer casi a la vez en dos cámaras del mismo sector es evidencia fuerte de ser la misma persona
Ventana de continuidad entre archivos de video	60 s	Une las trayectorias cortadas por la división automática de archivos del grabador
Fusión en vivo entre cámaras	Cada 180 s	Unifica periódicamente a las personas vistas por distintas cámaras durante el análisis en vivo

Fuente: elaboración propia.

Tabla I3

Parámetros de clasificación de comportamiento, mapas de calor y evidencia

Parámetro	**Valor**	**Descripción y justificación**
Umbral de confianza para productos	0,40	Menor que para personas, porque los productos se ven pequeños y parcialmente tapados por la mano
Margen alrededor de la persona	20 px	El producto en la mano suele quedar apenas fuera de la caja delimitadora de la persona
Confirmación de interacción con producto	3 fotogramas consecutivos	Descarta coincidencias de un instante con productos que están en la góndola detrás de la persona

Distancia de acercamiento a la caja	8 % del ancho de la imagen	El cliente se acerca al mostrador desde el frente, pero casi nunca pisa la zona de caja
Permanencia mínima junto a la caja	3 s	Distingue a quien se detiene a pagar de quien pasa caminando cerca del mostrador
Radio del núcleo gaussiano	60 px	Suaviza cada posición para representar el área que ocupa una persona
Resolución de la grilla almacenada	64 × 64	Reduce el tamaño del mapa guardado en la base sin perder la distribución general
Umbral de área activa	5 % del máximo	Ignora las celdas con presencia insignificante
Intervalo de registro de trayectorias	10 s	Reduce la cantidad de registros sin perder el recorrido general
Memoria de evidencia	120 s	Segundos de imágenes recientes que se conservan para armar la evidencia de una alerta
Ventana de evidencia	6 s antes y 6 s después de tomar el producto; 10 s antes de retirarse	Captura los dos momentos relevantes de un posible hurto

Fuente: elaboración propia.

Tabla I4

Parámetros del reconocimiento de productos en caja

Parámetro	**Valor**	**Descripción y justificación**
Fotogramas por segundo capturados	15	Permite detectar las pausas cortas de un cajero rápido, con bajo costo de CPU
Tiempo de escena estable	150 ms	Duración mínima de quietud para analizar la imagen; medida en tiempo para adaptarse a cajeros rápidos y lentos

Velocidad máxima de cambio	40 niveles por segundo	Tolera vibraciones y cambios de luz sutiles
Umbral de escena nueva	25 niveles de intensidad promedio	Evita volver a analizar el mismo producto cuando solo rota levemente en la mano
Confianza mínima del modelo	0,70	Por debajo de este valor, la lectura no se procesa
Tolerancia de edición del texto	1, 2 o 3 letras, según la longitud	Evita penalizar en exceso los errores de lectura en marcas cortas
Pesos del puntaje combinado	Marca 40 %, variante 25 %, tamaño 35 %	La marca es el criterio principal; el tamaño distingue presentaciones de un mismo producto
Puntaje mínimo de marca	40	Impide que un tamaño coincidente por casualidad favorezca un producto de otra marca
Puntaje para aceptar sin preguntar	82	Por encima de este valor, solo se pide una confirmación simple
Margen sobre el segundo candidato	12 puntos	Si los dos mejores candidatos están más cerca, se le pide al cajero que elija
Puntaje mínimo de candidato	50	Por debajo de este valor, el producto no se ofrece como opción

Fuente: elaboración propia.

Anexo J: Pipeline de integración y despliegue continuo

El pipeline de integración y despliegue continuo se definió con GitHub Actions en el archivo `.github/workflows/pipeline.yml`. Se ejecuta ante cada cambio incorporado a la rama principal del repositorio; en las propuestas de cambio (*pull requests*) se ejecuta solo la primera etapa. Las etapas se encadenan: cada una se ejecuta únicamente si la anterior finalizó con éxito.

Tabla J1

Etapas del pipeline de integración y despliegue continuo

Etapa	Acciones	Resultado esperado
1. Compilación y pruebas	Instala las dependencias de Python 3.12, verifica que el backend compile, ejecuta las pruebas unitarias con medición de cobertura, instala las dependencias del frontend (Node.js 22), aplica el análisis estático y compila la interfaz	Pruebas aprobadas e interfaz compilada; se publican los resultados y el reporte de cobertura
2. Verificación del sistema	Comprueba la conexión y el esquema de la base de datos, construye la imagen Docker, ejecuta el sistema completo en un contenedor y corre las pruebas de integración contra él	El sistema responde en el endpoint de estado en menos de 60 segundos y supera las pruebas de integración
3. Despliegue en Calidad (QA)	Comprueba la base de datos de QA y solicita a Render el despliegue del mismo *commit* validado	El entorno de QA ejecuta la nueva versión
4. Pruebas en Calidad	Ejecuta las pruebas de integración contra el entorno de QA publicado, verificando que corresponda al *commit* esperado	Pruebas aprobadas sobre el entorno real
5. Despliegue en Producción	Comprueba la base de datos de producción, despliega el mismo *commit* y ejecuta una prueba básica de funcionamiento (*smoke test*)	Producción ejecuta la versión validada y responde correctamente

Fuente: elaboración propia.

Ambos entornos se definieron en Render a partir de la misma imagen Docker, con el despliegue automático desactivado. De este modo, los despliegues se realizan exclusivamente desde el pipeline y con el identificador exacto del *commit* que superó todas las verificaciones. Las credenciales de las bases de datos y las direcciones de despliegue se almacenan como secretos de cada entorno en GitHub y no forman parte del código. El entorno de producción admite, además, la configuración de una aprobación manual antes del despliegue.

Anexo K: Manual de uso

Este anexo describe brevemente el uso del sistema por parte de cada perfil de usuario y la puesta en marcha del análisis en vivo.

K.1 Acceso al sistema

1. Ingresar desde un navegador a la dirección del sistema y, en la página de bienvenida, seleccionar **"Ya soy cliente"**.
2. Ingresar el nombre de usuario o el correo electrónico y la contraseña.
3. El sistema dirige automáticamente al administrador al **Dashboard** y al usuario operativo a la sección **Productos**.

Tras cinco intentos fallidos consecutivos, la cuenta se bloquea durante cinco minutos.

K.2 Uso por parte del administrador

- **Dashboard:** seleccionar el período en la parte superior (hoy, últimos 7 días, últimos 30 días o un rango personalizado). En la consola espacial, alternar entre los modos Calor, Trayectorias y Zonas, y utilizar el reproductor cronológico para recorrer las franjas horarias del día.
- **Alertas:** filtrar por severidad, estado o zona. Expandir una alerta de posible hurto para ver los fotogramas y el clip de evidencia, y marcarla como resuelta una vez revisada. En las alertas de persona posiblemente empleada, indicar si se trata o no de un empleado.
- **Reportes:** elegir las métricas, el período, las cámaras y el formato (PDF, Excel, CSV o PNG) y descargar el reporte.
- **Configuración:** elegir la apariencia de la interfaz (modo claro, oscuro o según el sistema operativo).

K.3 Uso por parte del usuario operativo (caja)

1. En la sección **Productos**, seleccionar la fuente de video y presionar **Iniciar**. El indicador de estado de la cámara pasa a "encendida".
2. Presentar cada producto frente a la cámara del mostrador y mantenerlo quieto un instante.
3. Según el resultado:
    - *Producto reconocido:* verificar la cantidad y confirmar.
    - *Candidatos ambiguos:* elegir el producto correcto entre las opciones.
    - *Producto no reconocido:* buscarlo en el catálogo y cargarlo manualmente.
4. El producto confirmado se agrega al ticket de la sesión y el stock se descuenta.
5. Al finalizar la jornada, presionar **Detener**.

K.4 Puesta en marcha del análisis en vivo

El análisis de cada cámara se ejecuta desde un equipo con acceso a la red privada de Tailscale, desde la carpeta raíz del repositorio:

python -m deteccion.main --rtsp <número de cámara>

El número de cámara va de 1 a 4. La dirección de cada flujo se toma de las variables `RTSP_URL_1` a `RTSP_URL_4` del archivo de configuración `.env`. El análisis guarda sus resultados en la base de datos de forma continua y se detiene con **Ctrl + C**, momento en que se guardan los últimos datos y se ejecuta la auditoría posterior al análisis.